


**KARADENİZ TEKNİK ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**



**MOBİL DESTEKLİ HİYERARŞİK SEBZE HASTALIK TESPİT
SİSTEMİ**

BİTİRME PROJESİ

Esmâ Ece YILMAZ

**2025-2026 BAHAR DÖNEMİ
KARADENİZ TEKNİK ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**

**MOBİL DESTEKLİ HİYERARŞİK SEBZE HASTALIK TESPİT
SİSTEMİ**

BİTİRME PROJESİ

Esmâ Ece YILMAZ

Danışman: Prof. Dr. Vasif NABİYEV

2025-2026 BAHAR DÖNEMİ



IEEE Etik Kuralları IEEE Code of Ethics



Mesleğime karşı şahsi sorumluluğumu kabul ederek, hizmet ettiğim toplumlara ve üyelerine en yüksek etik ve mesleki davranışta bulunmaya söz verdiğimi ve aşağıdaki etik kurallarını kabul ettiğimi ifade ederim:

1. Kamu güvenliği, sağlığı ve refahı ile uyumlu kararlar vermenin sorumluluğunu kabul etmek ve kamu veya çevreyi tehdit edebilecek faktörleri derhal açıklamak;
2. Mümkün olabilecek çıkar çatışması, ister gerçekten var olması isterse sadece algı olması, durumlarından kaçınmak. Çıkar çatışması olması durumunda, etkilenen taraflara durumu bildirmek;
3. Mevcut verilere dayalı tahminlerde ve fikir beyan etmelerde gerçekçi ve dürüst olmak;
4. Her türlü rüşveti reddetmek;
5. Mütenasip uygulamalarını ve muhtemel sonuçlarını gözeterek teknoloji anlayışını geliştirmek;
6. Teknik yeterliliklerimizi sürdürmek ve geliştirmek, yeterli eğitim veya tecrübe olması veya işin zorluk sınırları ifade edilmesi durumunda ancak başkaları için teknolojik sorumlulukları üstlenmek;
7. Teknik bir çalışma hakkında yansız bir eleştiri için uğraşmak, eleştiriyi kabul etmek ve eleştiriyi yapmak; hatları kabul etmek ve düzeltmek; diğer katkı sunanların emeklerini ifade etmek;
8. Bütün kişilere adilane davranmak; ırk, din, cinsiyet, yaş, milliyet, cinsi tercih, cinsiyet kimliği, veya cinsiyet ifadesi üzerinden ayrımcılık yapma durumuna girişmemek;
9. Yanlış veya kötü amaçlı eylemler sonucu kimsenin yaralanması, mülklerinin zarar görmesi, itibarlarının veya istihdamlarının zedelenmesi durumlarının oluşmasından kaçınmak;
10. Meslektaşlara ve yardımcı personele mesleki gelişimlerinde yardımcı olmak ve onları desteklemek.

IEEE Yönetim Kurulu tarafından Ağustos 1990'da onaylanmıştır.

ÖNSÖZ

Bu çalışma, lisans eğitimim boyunca edindiğim bilgi ve beceriler doğrultusunda hazırlanmış olup, yaprak görüntülerinden bitki türü tespiti ve hastalık sınıflandırması yapılmasına yönelik derin öğrenme tabanlı bir karar destek sistemi geliştirmeyi amaçlamaktadır. Çalışma kapsamında bitki türü tanıma, hastalık sınıflandırma, açıklanabilir yapay zekâ ve mobil uygulama entegrasyonu konuları ele alınmıştır. Tez çalışmam süresince bilgi ve tecrübeleriyle bana yol gösteren danışman hocam Prof. Dr. Vasif NABİYEV'e değerli katkıları ve desteği için teşekkür ederim. Ayrıca lisans eğitimim boyunca emeği geçen tüm hocalarıma, aileme ve bu süreçte bana destek olan arkadaşlarıma teşekkür ederim.

Bu çalışmanın, yapay zekâ destekli tarımsal karar destek sistemleri alanında yapılacak çalışmalara katkı sağlamasını temenni ederim.

Esma Ece YILMAZ
Trabzon 2026

İÇİNDEKİLER

	Sayfa No
IEEE ETİK KURALLARI.....	II
ÖNSÖZ.....	III
İÇİNDEKİLER.....	IV
ÖZET.....	V
SEMBOLLER VE KISALTMALAR DİZİNİ.....	VI
1. GENEL BİLGİLER.....	1
1.1. Giriş.....	1
1.2. Çalışmanın Amacı.....	1
1.3. Çalışmanın Kapsamı.....	2
1.4. Literatür Taraması.....	3
1.4.1. Derin Öğrenme ve CNN Tabanlı Görüntü Sınıflandırma.....	3
1.4.2. Bitki Hastalığı Tespitinde Derin Öğrenme.....	5
1.4.3. EfficientNet, CBAM ve Açıklanabilir Yapay Zeka Yaklaşımları.....	7
2. YAPILAN ÇALIŞMALAR.....	10
2.1. Veri Setinin Hazırlanması.....	10
2.2. Veri Ön İşleme ve Etiket Düzenleme.....	11
2.3. Önerilen Hiyerarşik Karar Destek Sistemi.....	13
2.4. Bitki Türü Tespit Modelinin Geliştirilmesi.....	14
2.4.1. Önerilen Derin Öğrenme Ağının Mimari Yapısı.....	16
2.5. Domates Hastalık Sınıflandırma Modelinin Geliştirilmesi.....	18
2.5.1. Domates Hastalık Modelinin Ağ Yapısı ve Mimari Özellikleri.....	19
2.6. Genel Hastalık Sınıflandırma Modelinin Geliştirilmesi.....	21
2.6.1. Genel Hastalık Modelinin Ağ Yapısı ve Mimari Özellikleri.....	23
2.7. Yaprak Odaklı Ön İşleme ve Grad-CAM++ Analizi.....	24
2.8. Mobil Uygulama Entegrasyonu.....	25
3. SONUÇLAR.....	27
3.1. Bitki Türü Tespit Modeli Sonuçları.....	29
3.2. Domates Hastalık Modeli Sonuçları.....	32
3.3. Genel Hastalık Modeli Sonuçları.....	35
3.4. Gerçek Dünya Görüntüleri ile Karar Destek Sistemi Sonuçları.....	38
3.5. Grad-CAM++ Görselleştirme Sonuçları.....	41
3.6. Genel Değerlendirme.....	43
4. ÖNERİLER.....	45
4.1. Çalışmanın Sınırlılıkları.....	46
5. KAYNAKLAR.....	49
STANDARTLAR ve KISITLAR FORMU.....	51

ÖZET

Tarım alanında bitki hastalıklarının erken tespit edilmesi, ürün kayıplarının azaltılması ve doğru müdahale kararlarının alınması açısından önemli bir konudur. Geleneksel yöntemlerde hastalık tespiti çoğunlukla uzman gözlemine dayandığı için zaman alabilmekte ve her zaman kolay uygulanamamaktadır. Bu nedenle son yıllarda yapay zeka ve derin öğrenme tabanlı görüntü sınıflandırma yöntemleri bitki hastalıklarının tespitinde yaygın olarak kullanılmaya başlanmıştır.

Bu çalışmada, yaprak görüntülerinden bitki türünü tanıyan ve ardından hastalık durumunu tahmin eden derin öğrenme tabanlı hiyerarşik bir karar destek sistemi geliştirilmiştir. Çalışma kapsamında domates, patates, biber, mısır, salatalık, patlıcan ve çilek olmak üzere farklı bitki türlerine ait yaprak görüntüleri kullanılmıştır. Hastalık sınıflandırması için sağlıklı, mantar hastalığı, bakteriyel hastalık ve viral hastalık olmak üzere dört temel sınıf belirlenmiştir.

Geliştirilen sistem iki aşamalı bir yapıya sahiptir. İlk aşamada yaprak görüntüsünden bitki türü tahmini yapılmaktadır. İkinci aşamada ise tahmin edilen türe göre hastalık sınıflandırması gerçekleştirilmektedir. Domates türü için özel bir hastalık sınıflandırma modeli geliştirilmiş, diğer türler için ise genel hastalık sınıflandırma modeli kullanılmıştır. Model mimarisinde EfficientNetB3 temel alınmış ve modelin önemli görüntü bölgelerine daha fazla odaklanabilmesi için CBAM dikkat mekanizması eklenmiştir. Ayrıca görüntülerdeki kontrast farklılıklarını azaltmak ve yaprak üzerindeki hastalık belirtilerini daha belirgin hale getirmek amacıyla ön işlem aşamasında CLAHE yöntemi uygulanmıştır. Sınıf dengesizliği problemini azaltmak amacıyla veri artırma, sınıf ağırlıkları ve uygun kayıp fonksiyonları kullanılmıştır.

Çalışmada modelin yalnızca sınıflandırma sonucu üretmesiyle yetinilmemiş, aynı zamanda karar destek sistemi yaklaşımı da benimsenmiştir. Bu kapsamda hastalık tahminine göre kullanıcıya temel öneriler sunulmuştur. Model kararlarının daha anlaşılır hale getirilmesi amacıyla Grad-CAM++ yöntemi kullanılarak açıklanabilir yapay zeka görselleştirmeleri elde edilmiştir. Böylece modelin tahmin yaparken yaprak üzerindeki hangi bölgelere odaklandığı incelenmiştir.

Elde edilen sonuçlar, CLAHE destekli ön işleme uygulanan modellerin kontrollü veri setleri üzerinde başarılı tahminler yapabildiğini göstermiştir. Bitki türü tespit modelinde %93,89, domates hastalık sınıflandırma modelinde %96,17 ve genel hastalık sınıflandırma modelinde %92,41 doğruluk değeri elde edilmiştir. Bununla birlikte gerçek ortamdan alınan görüntüler üzerinde yapılan denemelerde ışık, arka plan, kamera açısı, yaprağın görüntüde kapladığı alan ve görüntü kalitesi gibi etkenlerin model başarısını etkileyebildiği gözlemlenmiştir. Bu nedenle sistemde güven skorları dikkate alınmış ve düşük güvenli tahminlerde sonucun kesin kabul edilmemesi gerektiği belirtilmiştir.

Sonuç olarak bu çalışmada, bitki türü tanıma ve hastalık tespiti için derin öğrenme tabanlı, açıklanabilir ve mobil uygulama ile kullanılabilecek bir karar destek sistemi geliştirilmiştir. Geliştirilen sistem, yaprak görüntüsünden önce bitki türünü belirlemekte, ardından uygun hastalık sınıflandırma modelini çalıştırarak kullanıcıya tahmin sonucu ve temel öneri sunmaktadır. Çalışmanın ilerleyen aşamalarda daha fazla gerçek ortam verisiyle desteklenmesi, farklı bitki türleri için tür-özel hastalık modellerinin geliştirilmesi ve mobil uygulama üzerinden daha kapsamlı saha testlerinin yapılması hedeflenmektedir.

Bu proje, grupta tek üye olan Esmâ Ece Yılmaz tarafından yapılmaktadır.

SEMBOLLER VE KISALTMALAR DİZİNİ

KISALTMALAR	
KISALTMA	AÇIKLAMA
AI	Artificial Intelligence / Yapay Zeka
YZ	Yapay Zeka
DL	Deep Learning / Derin Öğrenme
CNN	Convolutional Neural Network / Evrimsel Sinir Ağı
EfficientNetB3	Bu çalışmada temel alınan derin öğrenme mimarisi
CBAM	Convolutional Block Attention Module
CLAHE	Contrast Limited Adaptive Histogram Equalization / Kontrast sınırlı adaptif histogram eşitleme
XAI	Explainable Artificial Intelligence / Açıklanabilir Yapay Zeka
Grad-CAM++	Gradient-weighted Class Activation Mapping++
GAP	Global Average Pooling
RGB	Red, Green, Blue renk uzayı
GPU	Graphics Processing Unit / Grafik İşlem Birimi
CPU	Central Processing Unit / Merkezi İşlem Birimi
TFLite	TensorFlow Lite
INT8	8-bit Integer Quantization
API	Application Programming Interface
APK	Android Package Kit
Train	Eğitim veri kümesi
Val	Doğrulama veri kümesi
Test	Test veri kümesi
Acc.	Accuracy / Doğruluk
IoU	Intersection over Union
F1	F1-Skoru
TP	True Positive / Doğru Pozitif
TN	True Negative / Doğru Negatif
FP	False Positive / Yanlış Pozitif
FN	False Negative / Yanlış Negatif
SEMBOLLER	
SEMBOL	AÇIKLAMA
%	Yüzde oranı
N	Toplam örnek sayısı
C	Sınıf sayısı
y	Gerçek sınıf etiketi
$\hat{y}$	Model tarafından tahmin edilen sınıf
p	Modelin tahmin olasılığı / güven skoru
L	Kayıp fonksiyonu değeri
α	Ağırlık katsayısı
γ	Focal Loss odaklama parametresi

1. GENEL BİLGİLER

1.1. Giriş

Tarım, insan yaşamının devamlılığı açısından temel alanlardan biridir. Bitkisel üretimde verimliliğin korunması, hastalıkların erken fark edilmesi ve doğru müdahalenin yapılması büyük önem taşımaktadır. Özellikle sebze üretiminde görülen yaprak hastalıkları, zamanında tespit edilmediğinde ürün kaybına, kalite düşüşüne ve ekonomik zararlara yol açabilmektedir. Geleneksel yöntemlerde hastalık tespiti çoğunlukla uzman gözlemine dayalı olarak yapılmaktadır. Ancak bu süreç hem zaman alıcı olabilmekte hem de her üreticinin uzman desteğine kolayca ulaşamaması nedeniyle pratikte bazı sınırlılıklar oluşturmaktadır.

Günümüzde yapay zeka ve derin öğrenme yöntemleri, görüntü işleme tabanlı problemlerde yaygın olarak kullanılmaktadır. Özellikle evrimsel sinir ağları, görüntülerden anlamlı özellikler çıkarabilme yetenekleri sayesinde bitki türü tanıma ve bitki hastalığı tespiti gibi alanlarda başarılı sonuçlar verebilmektedir. Yaprak görüntülerinden bitki türünün belirlenmesi ve hastalık durumunun sınıflandırılması, tarımsal karar destek sistemleri için önemli bir uygulama alanı oluşturmaktadır.

Bu bitirme çalışmasında, yaprak görüntüleri kullanılarak sebze türü tanıma ve hastalık tespiti yapabilen derin öğrenme tabanlı bir karar destek sistemi geliştirilmesi amaçlanmıştır. Çalışmada öncelikle görüntünün hangi sebze türüne ait olduğu tahmin edilmekte, ardından hastalık sınıflandırması yapılmaktadır. Hastalık sınıflandırmasında sağlıklı, mantar hastalığı, bakteriyel hastalık ve viral hastalık olmak üzere temel sınıflar kullanılmıştır. Bu yapı sayesinde sistemin yalnızca tek bir sınıflandırma sonucu üretmesi değil, aynı zamanda kullanıcıya hastalık durumuna yönelik genel bir öneri sunması da hedeflenmiştir.

Model geliştirme sürecinde EfficientNetB3 mimarisi temel alınmış ve modele dikkat mekanizması kazandırmak amacıyla CBAM yapısı eklenmiştir. Böylece modelin görüntü içerisindeki önemli bölgelere daha fazla odaklanması amaçlanmıştır. Ayrıca sınıf dengesizliği problemi göz önünde bulundurularak uygun kayıp fonksiyonları ve veri dengeleme yaklaşımları kullanılmıştır. Model kararlarının daha anlaşılabilir hale getirilmesi için Grad-CAM++ yöntemiyle ısı haritası tabanlı açıklanabilir yapay zeka çıktıları elde edilmiştir.

Çalışma kapsamında geliştirilen modeller, mobil ortamda kullanılabilecek şekilde Android uygulamasına entegre edilmiştir. Bu sayede kullanıcıların yaprak görüntüsünü doğrudan mobil cihaz üzerinden sisteme vermesi, bitki türü ve hastalık tahmini sonucunu önerilerle birlikte alması sağlanmıştır. Bu yönüyle çalışma, tarım alanında yapay zeka destekli, pratik ve kullanıcıya yönelik bir karar destek sistemi geliştirmeye odaklanmaktadır.

1.2. Çalışmanın Amacı

Bu çalışmanın temel amacı, yaprak görüntülerinden bitki türünü ve hastalık durumunu tespit edebilen derin öğrenme tabanlı bir karar destek sistemi geliştirmektir. Tarımsal üretimde bitki hastalıklarının erken dönemde fark edilmesi, ürün kaybının azaltılması ve doğru müdahale yöntemlerinin belirlenmesi açısından önemlidir. Ancak bitki hastalıklarının belirtileri bazı durumlarda birbirine benzerlik gösterebilmekte ve gözle ayırt edilmesi zor olabilmektedir. Bu durum hastalığın yanlış değerlendirilmesine, uygun olmayan müdahale yöntemlerinin uygulanmasına ve sonucunda ürün kaybı ile verim düşüşüne neden olabilmektedir. Bu nedenle çalışmada, görüntü işleme ve derin öğrenme yöntemleri kullanılarak bu süreçte destek olabilecek bir sistem tasarlanmıştır.

Çalışma kapsamında ilk olarak yaprak görüntüsü üzerinden bitki türünün tahmin edilmesi amaçlanmıştır. Ardından sistem, tahmin edilen türe göre uygun hastalık sınıflandırma mekanizmasını çalıştırmaktadır. Veri seti dağılımı ve sınıf çeşitliliği incelendiğinde, domates sınıfının hastalık alt sınıfları açısından daha dengeli ve kapsamlı veri içerdiği görülmüştür. Bu nedenle domates türü için özel bir hastalık sınıflandırma modeli geliştirilmiştir. Sistem tarafından tahmin edilen tür domates olduğunda domates özel hastalık modeli çalıştırılmakta, domates dışındaki türlerde ise genel hastalık sınıflandırma modeli kullanılmaktadır. Hastalık sınıflandırmasında sağlıklı, mantar hastalığı, bakteriyel hastalık ve viral hastalık sınıfları dikkate alınmıştır. Böylece kullanıcıya yalnızca sınıf tahmini verilmesi değil, aynı zamanda tahmin sonucuna uygun temel önerilerin sunulması hedeflenmiştir.

Model mimarisinde EfficientNetB3 tabanlı bir yapı kullanılmış ve modele CBAM dikkat mekanizması eklenerek yaprak üzerindeki önemli bölgelerin daha etkili öğrenilmesi amaçlanmıştır. Ayrıca sınıf dengesizliği probleminin model başarısını olumsuz etkilemesini azaltmak için uygun veri ön işleme, veri artırma ve ağırlıklandırma yaklaşımlarından yararlanılmıştır. Modelin karar verme sürecini daha anlaşılır hale getirmek için Grad-CAM++ yöntemiyle açıklanabilir yapay zeka çıktıları üretilmiştir.

Çalışmanın bir diğer amacı, geliştirilen sistemi yalnızca deneysel bir model olarak bırakmayıp kullanıcıya yönelik bir uygulama haline getirmektir. Bu doğrultuda eğitilen modellerin Android mobil uygulamasına entegre edilmesi ve kullanıcının yaprak görüntüsünü doğrudan mobil cihaz üzerinden sisteme verebilmesi hedeflenmiştir. Böylece çalışma, bitki türü tanıma, hastalık tespiti, açıklanabilir yapay zeka ve öneri sunma adımlarını bir araya getiren pratik bir karar destek sistemi oluşturmayı amaçlamaktadır.

1.3. Çalışmanın Kapsamı

Bu çalışma, yaprak görüntülerinden bitki türü tanıma ve hastalık tespiti yapan derin öğrenme tabanlı bir karar destek sisteminin geliştirilmesini kapsamaktadır. Çalışmada domates, patates, biber, mısır, salatalık, patlıcan ve çilek türlerine ait yaprak görüntüleri kullanılmıştır. Bu türler üzerinden önce bitki türü tahmini yapılmış, ardından hastalık durumunun belirlenmesine yönelik sınıflandırma işlemi gerçekleştirilmiştir.

Hastalık sınıflandırması sağlıklı, mantar hastalığı, bakteriyel hastalık ve viral hastalık olmak üzere dört temel sınıf üzerinden ele alınmıştır. Farklı veri setlerinde yer alan hastalık isimleri bu ana sınıflar altında düzenlenmiştir. Örneğin erken yanıklık, geç yanıklık, yaprak küfü ve septoria gibi mantar kaynaklı hastalıklar mantar hastalığı sınıfı altında toplanmıştır. Böylece farklı kaynaklardan elde edilen veriler ortak ve daha yönetilebilir bir etiket yapısına dönüştürülmüştür.

Çalışma kapsamında hiyerarşik bir sistem yapısı benimsenmiştir. İlk aşamada bitki türü tespit modeli ile görüntünün hangi türe ait olduğu tahmin edilmektedir. İkinci aşamada ise tahmin edilen türe göre hastalık sınıflandırması yapılmaktadır. Yapılan ön denemelerde tüm tür ve hastalık kombinasyonlarını tek bir modelde sınıflandırmanın, sınıf dengesizliği ve türler arası görsel farklılıklar nedeniyle bazı sınıflarda düşük başarıya yol açtığı gözlemlenmiştir. Bu nedenle hastalık sınıflandırmasının tür bilgisi dikkate alınarak yapılmasının daha uygun olacağı değerlendirilmiştir. Veri dağılımı incelendiğinde, domates türünün hastalık alt sınıfları açısından daha kapsamlı ve dengeli veri içerdiği görülmüştür. Bu nedenle domates türü için özel bir hastalık sınıflandırma modeli geliştirilmiştir. Domates dışındaki türlerde ise genel hastalık sınıflandırma modeli kullanılmıştır. Bu yapı sayesinde sistem hem tür tespiti hem de hastalık tahmini yapabilen daha kontrollü bir karar destek yaklaşımı sunmaktadır.

Model geliştirme sürecinde EfficientNetB3 mimarisi temel alınmış ve modele CBAM dikkat mekanizması eklenmiştir. Bu mimari ile yaprak görüntülerinden daha ayırt edici özelliklerin öğrenilmesi hedeflenmiştir. Ayrıca sınıf dengesizliğini azaltmak için veri artırma, sınıf ağırlıkları ve uygun eğitim stratejileri uygulanmıştır. Model kararlarının görsel olarak yorumlanabilmesi için Grad-CAM++ yöntemi kullanılmıştır.

Çalışmanın kapsamı yalnızca model eğitimi ile sınırlı değildir. Geliştirilen sistemde hastalık tahminine bağlı olarak kullanıcıya temel öneriler sunan bir öneri modülü de yer almaktadır. Ayrıca sistemin mobil ortamda kullanılabilmesi amacıyla Android uygulama entegrasyonu gerçekleştirilmiştir. Mobil uygulama ile kullanıcının yaprak görüntüsünü sisteme vermesi, tür ve hastalık tahmini sonucunu görmesi ve öneri alması hedeflenmiştir.

Bu çalışmada geliştirilen sistem, karar destek amacı taşımaktadır. Elde edilen sonuçlar kesin bir zirai tanı yerine, kullanıcıya ön değerlendirme sunmak amacıyla kullanılmalıdır. Özellikle gerçek ortam görüntülerinde ışık koşulları, arka plan, kamera açısı, yaprağın görüntüde kapladığı alan ve görüntü kalitesi gibi faktörlerin model başarısını etkileyebileceği dikkate alınmıştır. Bu nedenle düşük güven skorlu tahminlerde kullanıcıya daha net ve yakın çekim görüntü ile tekrar test yapılması önerilmektedir.

1.4. Literatür Taraması

Bitki hastalıklarının görüntü tabanlı olarak tespit edilmesi, son yıllarda derin öğrenme yöntemlerinin gelişmesiyle birlikte daha fazla çalışılan bir konu haline gelmiştir. Özellikle yaprak görüntüleri, hastalık belirtilerinin çoğu zaman renk değişimi, leke, sararma, küf veya deformasyon şeklinde görülebilmesi nedeniyle bu alanda sık kullanılan veri kaynaklarından biridir. Derin öğrenme tabanlı yöntemler, görüntülerden elle özellik çıkarma ihtiyacını azaltarak sınıflandırma problemlerinde daha başarılı ve esnek çözümler sunabilmektedir.

1.4.1. Derin Öğrenme ve CNN Tabanlı Görüntü Sınıflandırma

Derin öğrenme, yapay sinir ağlarının çok katmanlı yapılar kullanarak veriden otomatik özellik öğrenmesini sağlayan bir makine öğrenmesi yaklaşımıdır. Geleneksel görüntü işleme yöntemlerinde sınıflandırma başarısı çoğunlukla kenar, renk, doku veya şekil gibi özelliklerin kullanıcı tarafından doğru şekilde belirlenmesine bağlıdır. Derin öğrenme yöntemlerinde ise bu özellikler model tarafından eğitim süreci içerisinde otomatik olarak öğrenilmektedir. Bu durum özellikle görüntü sınıflandırma, nesne tanıma ve tıbbi/tarımsal görüntü analizi gibi alanlarda derin öğrenme yöntemlerinin yaygınlaşmasını sağlamıştır.

Görüntü sınıflandırma problemlerinde en yaygın kullanılan derin öğrenme yapılarından biri evrişimsel sinir ağlarıdır. Evrişimsel sinir ağları, görüntülerdeki yerel örüntüleri öğrenebilmek için evrişim katmanlarından yararlanır. İlk katmanlarda genellikle kenar, köşe ve basit doku yapıları gibi düşük seviyeli özellikler öğrenilirken, daha derin katmanlarda nesneye veya sınıfa özgü daha karmaşık özellikler öğrenilmektedir. Bu yapı sayesinde CNN modelleri, görüntü içerisindeki ayırt edici bölgeleri kullanarak sınıflandırma işlemi gerçekleştirebilmektedir.

LeCun ve arkadaşları tarafından yapılan çalışmada evrimsel sinir ağlarının iki boyutlu şekillerdeki değişkenliklerle başa çıkabilecek şekilde tasarlandığı ve özellikle görüntü tabanlı tanıma problemlerinde etkili olduğu gösterilmiştir [1]. Bu çalışma, CNN mimarilerinin görüntü işleme alanında kullanılmasının temelini oluşturan önemli çalışmalardan biri olarak kabul edilmektedir. Daha sonraki yıllarda derin CNN modelleri, büyük veri setleri ve güçlü donanımların gelişmesiyle birlikte çok daha karmaşık görüntü sınıflandırma problemlerinde kullanılmaya başlanmıştır. LeCun vd. çalışması, CNN'lerin iki boyutlu şekil değişkenlikleriyle başa çıkmak üzere tasarlandığını ve el yazısı tanıma gibi görüntü problemlerinde etkili olduğunu gösteren temel çalışmalardandır.

Derin öğrenmenin görüntü sınıflandırmadaki etkisini gösteren önemli çalışmalardan biri de Krizhevsky, Sutskever ve Hinton tarafından geliştirilen AlexNet mimarisidir. Bu çalışmada büyük ölçekli ImageNet veri seti üzerinde derin bir evrimsel sinir ağı eğitilmiş ve geleneksel yöntemlere göre daha başarılı sonuçlar elde edilmiştir [2]. AlexNet çalışması, derin öğrenme yöntemlerinin büyük ölçekli görüntü sınıflandırma problemlerinde yüksek performans gösterebileceğini ortaya koyması açısından önemli bir dönüm noktasıdır. Bu gelişmeden sonra CNN tabanlı mimariler bilgisayarlı görü alanında daha yaygın kullanılmaya başlanmıştır. Krizhevsky vd. ImageNet çalışmasında 1,2 milyon yüksek çözünürlüklü görüntü ve 1000 sınıf üzerinde derin CNN eğitildiği ve önceki yaklaşımlara göre daha düşük hata oranları elde edildiği raporlanmıştır.

CNN mimarilerinin başarısında katmanlı öğrenme yapısı önemli bir rol oynamaktadır. Bir görüntü modele verildiğinde evrim katmanları görüntüden özellik haritaları çıkarmakta, havuzlama katmanları boyut azaltma işlemi yapmakta ve son katmanlarda sınıflandırma işlemi gerçekleştirilmektedir. Bu süreçte model, görüntüdeki önemli özellikleri ağırlıklar aracılığıyla öğrenmektedir. Örneğin bir yaprak görüntüsünde kenar yapıları, damar dokusu, renk değişimleri, lekeler, sararma bölgeleri veya küf benzeri yapılar model tarafından sınıflandırma için ayırt edici özellikler olarak öğrenilebilmektedir. Bu nedenle CNN tabanlı modeller bitki türü tanıma ve bitki hastalığı tespiti gibi yaprak görüntüsüne dayalı problemlerde uygun bir yaklaşım sunmaktadır.


Derin CNN modellerinin eğitiminde veri miktarı önemli bir etkidir. Büyük veri setleriyle sıfırdan model eğitmek her zaman mümkün olmayabilir. Bu nedenle birçok çalışmada transfer öğrenme yaklaşımı kullanılmaktadır. Transfer öğrenme, büyük ve genel amaçlı veri setleri üzerinde önceden eğitilmiş bir modelin, yeni bir probleme uyarlanmasıdır. Bu yaklaşım sayesinde model, daha önce öğrendiği genel görüntü özelliklerini yeni veri setine aktarabilmektedir. Yosinski ve arkadaşları, derin sinir ağlarında öğrenilen özelliklerin farklı görevlere aktarılabilirliğini incelemiş ve özellikle erken katmanlarda öğrenilen özelliklerin daha genel, ileri katmanlardaki özelliklerin ise göreve daha özel olduğunu belirtmiştir [3]. Yosinski vd. çalışması, CNN katmanlarındaki özelliklerin genellik ve göreve özgüllük derecelerini deneysel olarak incelemiş ve transfer öğrenmenin neden etkili olabildiğini açıklamıştır.

Transfer öğrenme, bitki hastalığı tespiti gibi alanlarda özellikle önemlidir. Çünkü bazı hastalık sınıflarında yeterli sayıda görüntü bulunmayabilir veya sınıflar arasında veri dengesizliği olabilir. Önceden eğitilmiş bir model kullanmak, sınırlı veriyle daha iyi başlangıç noktası sağlayabilir. Ayrıca eğitim süresini azaltır ve modelin daha kararlı öğrenmesine katkıda bulunur. Bu çalışmada da EfficientNetB3 mimarisi önceden eğitilmiş ağırlıklar kullanılarak tercih edilmiş, ardından çalışma veri setine uygun şekilde yeniden eğitilmiştir. Böylece modelin genel görüntü özelliklerinden yararlanması ve yaprak görüntülerine uyum sağlaması amaçlanmıştır.

CNN mimarilerinde model derinliği arttıkça daha karmaşık özelliklerin öğrenilmesi mümkün olmakla birlikte, çok derin ağların eğitimi bazı zorluklar oluşturmaktadır. Bu konuda He ve arkadaşları tarafından önerilen ResNet mimarisi, artık bağlantılar kullanarak daha derin ağların daha kolay eğitilmesini sağlamıştır [4]. Bu tür çalışmalar, görüntü sınıflandırma alanında mimari tasarımın model başarısı üzerinde önemli etkisi olduğunu göstermektedir. Günümüzde ResNet, EfficientNet, MobileNet ve benzeri mimariler farklı görüntü sınıflandırma problemlerinde yaygın olarak kullanılmaktadır. He vd. çalışması, derin ağların eğitilmesindeki zorluğu azaltmak için artık öğrenme yaklaşımını önermiş ve daha derin ağların daha kolay optimize edilebildiğini göstermiştir.

Bu çalışmada EfficientNetB3 mimarisinin tercih edilmesinin temel nedeni, doğruluk ve hesaplama maliyeti arasında dengeli bir yapı sunmasıdır. Bitki hastalığı tespiti gibi problemlerde hem yüksek sınıflandırma başarısı hem de mobil uygulamaya aktarılabilirlik önemlidir. Bu nedenle çok büyük ve çalıştırılması zor bir model yerine, daha verimli ve transfer öğrenmeye uygun bir mimari tercih edilmiştir. EfficientNetB3 üzerine CBAM dikkat mekanizması eklenerek modelin görüntü içerisindeki önemli kanal ve uzamsal bölgelere daha fazla odaklanması hedeflenmiştir.

Sonuç olarak, literatürdeki çalışmalar CNN tabanlı derin öğrenme modellerinin görüntü sınıflandırma problemlerinde etkili olduğunu göstermektedir. Bu çalışmada da yaprak görüntülerinden bitki türü ve hastalık durumunun belirlenmesi için CNN tabanlı bir yaklaşım benimsenmiştir. Transfer öğrenme, dikkat mekanizması ve açıklanabilir yapay zeka yöntemleri birlikte kullanılarak hem sınıflandırma başarısının artırılması hem de model çıktılarının daha yorumlanabilir hale getirilmesi amaçlanmıştır.



Şekil 1.1. CNN tabanlı görüntü sınıflandırma sürecinin genel yapısı.

1.4.2. Bitki Hastalığı Tespitinde Derin Öğrenme

Bitki hastalıklarının erken dönemde tespit edilmesi, tarımsal üretimde verim kaybının azaltılması açısından önemli bir konudur. Hastalık belirtileri çoğunlukla yapraklarda renk değişimi, sararma, leke, küf, kuruma veya deformasyon şeklinde ortaya çıkmaktadır. Bu nedenle yaprak görüntüleri, bitki hastalığı tespiti çalışmalarında yaygın olarak kullanılan veri kaynaklarından biridir. Görüntü tabanlı sistemler sayesinde hastalık belirtilerinin otomatik olarak analiz edilmesi ve kullanıcıya ön değerlendirme sunulması mümkün hale gelmektedir.

Derin öğrenme yöntemlerinin bitki hastalığı tespitinde kullanılmasına yönelik önemli çalışmalardan biri Mohanty, Hughes ve Salathé tarafından yapılmıştır. Bu çalışmada PlantVillage veri seti kullanılarak sağlıklı ve hastalıklı yaprak görüntüleri üzerinden bitki türü ve hastalık durumu sınıflandırılmıştır. Araştırmada 54.306 yaprak görüntüsü kullanılmış, 14 farklı bitki türü ve 26 hastalık ya da sağlıklı durum sınıflandırılmıştır. Elde edilen yüksek doğruluk değeri, kontrollü ortamda çekilmiş yaprak görüntüleri üzerinde derin öğrenme modellerinin bitki hastalığı tespitinde başarılı sonuçlar verebileceğini göstermiştir [5].

PlantVillage veri seti, bitki hastalığı tespiti alanında çok kullanılan bir veri seti olmakla birlikte, görüntülerin büyük kısmı kontrollü arka plan ve ışık koşullarında elde edilmiştir. Bu durum model eğitimi için avantaj sağlasa da gerçek ortamda çekilen görüntülerde aynı başarımın elde edilmesini zorlaştırabilmektedir. Gerçek ortam görüntülerinde arka plan karmaşıklığı, yaprağın görüntüdeki konumu, kamera açısı, ışık miktarı ve görüntü kalitesi gibi faktörler modelin tahmin sonucunu etkileyebilmektedir. Mohanty vd. çalışmasında da kontrollü test verisinde yüksek doğruluk elde edilmesine rağmen, farklı koşullardan alınan görüntülerde başarımın belirgin şekilde düştüğü belirtilmiştir [5]. Bu durum, geliştirilen modellerin yalnızca kontrollü veri setleriyle değil, gerçek dünya görüntüleriyle de değerlendirilmesi gerektiğini göstermektedir.

Gerçek ortam görüntülerine yönelik çalışmalardan biri PlantDoc veri setidir. Singh ve arkadaşları tarafından sunulan PlantDoc veri seti, laboratuvar veya kontrollü arka plan yerine internetten toplanan doğal koşullardaki bitki görüntülerini içermektedir. Çalışmada 2.598 görüntü, 13 bitki türü ve 17'ye kadar hastalık sınıfı kullanılmıştır [6]. Bu veri seti, gerçek ortam görüntülerinde bitki hastalığı tespitinin daha zor olduğunu ve modelin yalnızca yaprak dokusunu değil, arka plan, ışık ve görüntü kalitesi gibi değişkenlerle de başa çıkması gerektiğini göstermesi açısından önemlidir.

Literatürde kullanılan veri setlerinden biri de artırılmış görüntüler içeren New Plant Diseases Dataset veri setidir. Bu veri setinde sağlıklı ve hastalıklı yaprak görüntüleri farklı sınıflar altında düzenlenmiştir. Kaggle üzerinde sunulan açıklamaya göre veri seti yaklaşık 87 bin RGB görüntüden ve 38 sınıftan oluşmaktadır [7]. Bu tür genişletilmiş veri setleri, modelin daha fazla görüntü üzerinden öğrenmesini sağladığı için eğitim sürecinde avantaj sağlayabilmektedir. Ancak artırılmış verilerin gerçek dünya çeşitliliğini tamamen temsil etmediği de dikkate alınmalıdır.


Bitki hastalığı tespiti çalışmalarında sık karşılaşılan problemlerden biri sınıf dengesizliğidir. Bazı bitki türleri veya hastalık sınıfları çok fazla görüntü içerirken, bazı sınıflarda görüntü sayısı oldukça düşük olabilmektedir. Bu durum modelin çoğunluk sınıflarına daha fazla yönelmesine ve az örnek içeren sınıflarda düşük başarı göstermesine neden olabilmektedir. Bu nedenle literatürde veri artırma, sınıf ağırlığı kullanma, örnekleme yöntemleri ve özel kayıp fonksiyonları gibi yaklaşımlar kullanılmaktadır. Bu çalışmada da veri seti dağılımı incelenmiş ve sınıf dengesizliğinin model başarısını etkilediği gözlemlenmiştir.

Bitki hastalığı tespiti için yapılan birçok çalışmada tüm bitki türleri ve hastalık durumları tek bir sınıflandırma modeli içinde ele alınmaktadır. Ancak bu yaklaşımda hem bitki türleri arasındaki morfolojik farklılıklar hem de hastalık belirtilerinin benzer görsel özellikler göstermesi modelin öğrenmesini zorlaştırabilmektedir. Örneğin farklı bitki türlerinde görülen mantar hastalıkları benzer lekelenme veya renk değişimi oluşturabilirken, aynı bitki türünde farklı hastalıklar da birbirine yakın belirtiler gösterebilmektedir. Bu nedenle bu çalışmada tek aşamalı sınıflandırma yaklaşımı yerine hiyerarşik bir karar destek sistemi tercih edilmiştir.

Bu çalışmada geliştirilen sistemde ilk olarak bitki türü tahmin edilmekte, ardından hastalık sınıflandırması yapılmaktadır. Yapılan veri analizi ve ön denemeler sonucunda domates türünün hastalık alt sınıfları açısından daha kapsamlı ve dengeli veri içerdiği görülmüştür. Bu nedenle domates için özel bir hastalık sınıflandırma modeli geliştirilmiştir. Domates dışındaki türlerde ise genel hastalık sınıflandırma modeli kullanılmıştır. Bu yaklaşım, hem veri dengesizliği problemini daha kontrollü ele almayı hem de tür bilgisine bağlı olarak daha anlamlı bir hastalık tahmini yapmayı amaçlamaktadır.

Ayrıca bu çalışmada hastalık sınıfları çok ayrıntılı alt hastalık isimleri yerine daha genel sınıflar altında toplanmıştır. Sağlıklı, mantar hastalığı, bakteriyel hastalık ve viral hastalık olmak üzere dört temel sınıf kullanılmıştır. Örneğin erken yanıklık, geç yanıklık, yaprak küfü ve septoria gibi mantar kaynaklı hastalıklar mantar hastalığı sınıfı altında değerlendirilmiştir. Bu tercih, hem farklı veri kaynaklarından gelen etiketleri ortak bir yapıya dönüştürmek hem de sınıf sayısını daha yönetilebilir hale getirmek amacıyla yapılmıştır.

Literatürdeki çalışmalar, derin öğrenme yöntemlerinin bitki hastalığı tespitinde etkili olduğunu göstermektedir. Ancak kontrollü veri setleri ile gerçek ortam görüntüleri arasındaki fark, sınıf dengesizliği ve farklı hastalık belirtilerinin benzerliği gibi problemler hâlâ önemli sınırlılıklar oluşturmaktadır. Bu nedenle bu çalışmada yalnızca model doğruluğuna odaklanılmamış, aynı zamanda gerçek ortam görüntüleriyle test, güven skoru kontrolü, öneri modülü ve açıklanabilir yapay zeka çıktıları da sistemin bir parçası haline getirilmiştir.




Şekil 1.2. Bitki yapraklarında görülen sağlıklı ve hastalıklı durum örnekleri.

1.4.3. EfficientNet, CBAM ve Açıklanabilir Yapay Zeka Yaklaşımları

Derin öğrenme tabanlı görüntü sınıflandırma çalışmalarında model mimarisinin seçimi, elde edilen başarıyı doğrudan etkileyen önemli faktörlerden biridir. Bitki yaprak görüntülerinde hastalık belirtileri çoğu zaman renk değişimi, leke, sararma, yanıklık veya doku bozulması gibi küçük ve yerel özellikler üzerinden ayırt edilmektedir. Bu nedenle kullanılan modelin hem genel yaprak formunu hem de hastalık belirtisi olabilecek ayrıntılı bölgeleri öğrenebilmesi gerekmektedir. Bu çalışmada temel sınıflandırma mimarisi olarak EfficientNetB3 kullanılmıştır.

EfficientNet mimarisi, model başarımını artırırken parametre sayısını ve hesaplama maliyetini dengeli tutmayı amaçlayan bir derin öğrenme yaklaşımıdır. Geleneksel evrimsel sinir ağı modellerinde genellikle ağırlık derinliği, genişliği veya giriş görüntü çözünürlüğü ayrı ayrı artırılmaktadır. EfficientNet yaklaşımında ise bu üç bileşen birlikte ve dengeli biçimde ölçeklenmektedir. Bu yapı, özellikle sınırlı veri ve hesaplama kaynağı bulunan görüntü sınıflandırma problemlerinde daha verimli modeller geliştirilmesine olanak sağlamaktadır [8]. Bu çalışmada EfficientNetB3 modelinin tercih edilmesinin temel nedeni, yüksek sınıflandırma başarımları sunarken mobil uygulama entegrasyonu açısından da daha uygun bir yapı sağlamasıdır.

EfficientNetB3 tabanlı sınıflandırma yapısının genel akışı Şekil 1.3'te gösterilmiştir. Bu yapıda giriş görüntüsü evrimsel katmanlar üzerinden özellik haritalarına dönüştürülmekte, ardından sınıflandırma katmanları ile ilgili sınıfa ait tahmin üretilmektedir.




Şekil 1.3. EfficientNetB3 tabanlı evrimsel sinir ağı mimarisi

Bu çalışmada yalnızca temel EfficientNetB3 mimarisi kullanılmamış, modelin yaprak görüntülerindeki ayırt edici bölgelere daha fazla odaklanabilmesi amacıyla CBAM dikkat mekanizması da mimariye eklenmiştir. CBAM, kanal dikkati ve uzamsal dikkat olmak üzere iki temel bölümden oluşan bir dikkat mekanizmasıdır. Kanal dikkat modülü, özellik haritaları içerisindeki hangi kanalların daha önemli olduğunu belirlemeye çalışırken; uzamsal dikkat modülü görüntünün hangi bölgelerinin sınıflandırma açısından daha belirleyici olduğunu öğrenmektedir [9]. Bu yönüyle CBAM, modelin yalnızca tüm görüntüyü genel olarak değerlendirmesi yerine, hastalık belirtisi taşıyabilecek yaprak bölgelerine daha fazla önem vermesini sağlamaktadır.

Bitki hastalığı tespiti probleminde bu yaklaşım önemlidir. Çünkü hastalık belirtileri çoğu zaman tüm yaprağa yayılmış şekilde değil, belirli alanlarda yoğunlaşmış şekilde görülebilmektedir. Örneğin yaprak üzerindeki küçük lekeler, sararmış bölgeler veya kuruma belirtileri sınıflandırma kararında belirleyici olabilmektedir. Bu nedenle dikkat mekanizması kullanılarak modelin bu bölgeleri daha etkili biçimde öğrenmesi hedeflenmiştir.

CBAM dikkat mekanizmasının kanal ve uzamsal dikkat bileşenlerinden oluşan genel yapısı Şekil 1.4'te verilmiştir. Bu yapı sayesinde model, özellik haritaları üzerinde hem hangi kanalların hem de görüntünün hangi bölgelerinin daha önemli olduğunu öğrenebilmektedir.




Şekil 1.4. CBAM dikkat mekanizmasının genel yapısı

Derin öğrenme modelleri yüksek başarımlar elde etmesine rağmen, bu modellerin kararlarını nasıl verdiğinin anlaşılması her zaman kolay değildir. Özellikle tarım gibi karar destek sistemlerinin kullanıldığı alanlarda, modelin yalnızca bir sınıf tahmini üretmesi yeterli olmayabilir. Kullanıcı açısından modelin hangi görüntü bölgesine odaklanarak karar verdiğinin görülmesi de önemlidir. Bu nedenle çalışmada açıklanabilir yapay zeka yaklaşımlarından Grad-CAM++ yöntemi kullanılmıştır.

Grad-CAM, evrimsel sinir ağı modellerinde sınıflandırma kararını etkileyen görüntü bölgelerini ısı haritası şeklinde gösteren bir açıklanabilir yapay zeka yöntemidir [10]. Grad-CAM++ ise Grad-CAM yönteminin geliştirilmiş bir versiyonu olup, özellikle birden fazla ayırt edici bölgenin bulunduğu görüntülerde daha ayrıntılı görselleştirme sağlayabilmektedir [11]. Bu yöntem sayesinde modelin hastalık tahmini yaparken yaprağın hangi bölgelerine daha fazla önem verdiği görsel olarak incelenebilmektedir.

Grad-CAM++ çıktıları, modelin karar verme sürecini yorumlamaya yardımcı olmaktadır. Ancak bu çıktılar piksel düzeyinde kesin bir segmentasyon sonucu olarak değerlendirilmemelidir. Grad-CAM++ burada yaprağın hastalıklı bölgesini tam olarak kesip ayırmak için değil, modelin sınıflandırma kararında etkili olan bölgeleri görselleştirmek amacıyla kullanılmıştır. Bu nedenle elde edilen ısı haritaları, modelin kararını destekleyen açıklayıcı görseller olarak ele alınmıştır.

Grad-CAM ve Grad-CAM++ yöntemlerinin CNN tabanlı bir sınıflandırma modeli üzerinde nasıl çalıştığını gösteren genel yapı Şekil 1.5'te sunulmuştur. Bu görselleştirme, modelin sınıf tahmini üretirken hangi görüntü bölgelerinden daha fazla etkilendiğini açıklamak amacıyla kullanılmaktadır.



Şekil 1.5. Grad-CAM ve Grad-CAM++ yöntemlerinin CNN tabanlı görüntü sınıflandırma modeli üzerindeki genel çalışma yapısı

Sonuç olarak bu çalışmada EfficientNetB3 mimarisi, CBAM dikkat mekanizması ve Grad-CAM++ açıklanabilir yapay zeka yaklaşımı birlikte kullanılmıştır. EfficientNetB3 modeli görüntülerden güçlü özellikler çıkarırken, CBAM mekanizması modelin daha ayırt edici bölgelere odaklanmasına katkı sağlamıştır. Grad-CAM++ yöntemi ise geliştirilen modelin kararlarının görsel olarak yorumlanmasına olanak tanımıştır. Bu yapı, hem bitki türü tespiti hem de hastalık sınıflandırma aşamalarında daha anlaşılır ve kullanıcıya yönelik bir karar destek sistemi oluşturulmasına katkı sağlamıştır.

2. YAPILAN ÇALIŞMALAR

Bu bölümde, derin öğrenme tabanlı sebze türü tanıma ve hastalık tespiti yapan karar destek sisteminin geliştirilme süreci açıklanmıştır. Çalışma kapsamında öncelikle kullanılacak veri setleri düzenlenmiş, etiket yapıları standart hale getirilmiş ve eğitim, doğrulama ve test klasörleri oluşturulmuştur. Daha sonra bitki türü tespiti, domates hastalık sınıflandırması ve genel hastalık sınıflandırması için ayrı modeller geliştirilmiştir.

Sistemin temel amacı, yaprak görüntüsünden önce bitki türünü belirlemek, ardından belirlenen türe göre hastalık sınıflandırması yapmaktır. Bu nedenle çalışma tek aşamalı bir sınıflandırma modeli yerine hiyerarşik bir karar destek sistemi olarak tasarlanmıştır. Ayrıca model sonuçlarının daha anlaşılır hale getirilmesi için Grad-CAM++ tabanlı açıklanabilir yapay zeka çıktıları oluşturulmuş ve hastalık tahminine bağlı olarak kullanıcıya öneri sunan bir modül geliştirilmiştir. Son aşamada ise geliştirilen sistemin mobil ortamda kullanılabilmesi için Android uygulama entegrasyonu gerçekleştirilmiştir.

2.1. Veri Setinin Hazırlanması

Bu çalışmada kullanılan veri seti, yaprak görüntülerinden bitki türü ve hastalık durumunun tahmin edilebilmesi amacıyla hazırlanmıştır. Veri hazırlama sürecinde temel olarak PlantVillage veri setinden yararlanılmış, ayrıca eksik veya az örnek içeren bazı sınıfları desteklemek amacıyla farklı açık veri kaynaklarından elde edilen görüntüler de değerlendirilmiştir. PlantVillage veri setinde yer alan color, grayscale ve segmented klasörleri incelenmiş, çalışmada yalnızca gerçek yaprak rengini koruyan color klasörü kullanılmıştır. Gri tonlamalı ve segmentasyon uygulanmış görüntüler ise bu çalışmanın kapsamına dahil edilmemiştir.

Veri seti hazırlanırken domates, patates, biber, mısır, salatalık, patlıcan ve çilek türlerine ait yaprak görüntüleri dikkate alınmıştır. İlk aşamada tüm görüntüler ait oldukları bitki türü ve hastalık durumuna göre klasörleştirilmiştir. Farklı veri kaynaklarında aynı hastalığı ifade eden etiketlerin farklı isimlerle yer alabildiği görülmüştür. Bu nedenle etiketler yeniden düzenlenmiş ve ortak bir sınıf yapısı oluşturulmuştur.

Hastalık sınıflandırması için dört temel sınıf belirlenmiştir. Bunlar *Healthy*, *Fungal_Disease*, *Bacterial_Disease* ve *Viral_Disease* sınıflarıdır. Sağlıklı yaprak görüntüleri *Healthy* sınıfı altında toplanmıştır. Erken yanıklık, geç yanıklık, yaprak küfü, septoria, pas, mildiyö ve benzeri mantar kaynaklı hastalıklar *Fungal_Disease* sınıfı altında birleştirilmiştir. Bakteriyel leke ve bakteriyel solgunluk gibi hastalıklar *Bacterial_Disease* sınıfına, mozaik virüsü ve sarı yaprak kıvrıcıklık virüsü gibi hastalıklar ise *Viral_Disease* sınıfına dahil edilmiştir.

Veri hazırlama sürecinde ilk olarak tüm tür ve hastalık kombinasyonlarını içeren birleşik bir veri seti oluşturulmuştur. Bu yapı, örneğin tomato_healthy, tomato_fungal, potato_healthy, cucumber_fungal gibi hem tür hem de hastalık bilgisini içeren sınıflardan oluşmaktadır. Bu yaklaşım, modelin aynı anda hem tür hem de hastalık bilgisini öğrenmesine imkan tanımaktadır. Ancak yapılan ön incelemelerde sınıf dağılımlarının dengeli olmadığı ve bazı sınıfların diğerlerine göre çok daha az görüntü içerdiği görülmüştür. Bu durum, modelin çoğunluk sınıflarına yönelmesine ve az örnek içeren sınıflarda düşük başarımlar göstermesine neden olabileceği için daha kontrollü bir yapı tercih edilmiştir.

Bu nedenle veri seti daha sonra hiyerarşik sistem yapısına uygun olacak şekilde yeniden düzenlenmiştir. İlk aşama için bitki türü tespitine yönelik bir veri seti hazırlanmıştır. Bu veri setinde görüntüler yalnızca bitki türlerine göre sınıflandırılmıştır. Böylece domates, patates, biber, mısır, salatalık, patlıcan ve çilek türleri için ayrı sınıflar oluşturulmuştur. İkinci aşama için ise hastalık sınıflandırmasına yönelik veri setleri hazırlanmıştır. Veri dağılımı incelendiğinde domates sınıfının hastalık alt sınıfları açısından daha kapsamlı ve dengeli veri içerdiği görülmüştür. Bu nedenle domates için özel bir hastalık veri seti oluşturulmuştur. Domates dışındaki türlerde ise genel hastalık sınıflandırma yaklaşımı kullanılmıştır.

Hazırlanan veri setleri eğitim, doğrulama ve test olmak üzere üç ayrı bölüme ayrılmıştır. Veri setinin yaklaşık %70'i eğitim, %15'i doğrulama ve %15'i test amacıyla kullanılmıştır. Eğitim verileri modelin öğrenme sürecinde, doğrulama verileri eğitim sırasında model performansının izlenmesinde, test verileri ise eğitim tamamlandıktan sonra modelin daha önce görmediği görüntüler üzerindeki başarımını değerlendirmek amacıyla kullanılmıştır. Bu ayırım sayesinde modelin yalnızca eğitim verilerine ezber yapıp yapmadığı kontrol edilmeye çalışılmıştır.

Veri seti hazırlama sürecinde klasör yapılarının düzenli ve model eğitimine uygun olmasına dikkat edilmiştir. Her sınıf için ayrı klasörler oluşturulmuş ve görüntüler ilgili sınıf klasörlerine aktarılmıştır. Ayrıca veri setinde yer alan görüntü sayıları sınıf bazında kontrol edilmiştir. Bu kontroller sonucunda bazı sınıflarda belirgin veri dengesizliği olduğu görülmüştür. Bu nedenle sonraki aşamalarda sınıf ağırlıkları, veri artırma ve uygun eğitim stratejileri kullanılarak bu dengesizliğin model üzerindeki etkisi azaltılmaya çalışılmıştır.

2.2. Veri Ön İşleme ve Etiket Düzenleme

Veri seti hazırlandıktan sonra model eğitimine uygun hale getirilmesi için çeşitli ön işleme ve etiket düzenleme adımları uygulanmıştır. Bu aşamada temel amaç, farklı kaynaklardan elde edilen görüntülerin ortak bir klasör ve etiket yapısına dönüştürülmesi, hatalı veya kapsam dışı sınıfların ayrılması, görüntülerin model girişine uygun hale getirilmesi ve eğitim sürecinde kullanılabilecek düzenli bir veri yapısının oluşturulmasıdır.

İlk olarak veri setinde yer alan klasör yapıları incelenmiştir. PlantVillage veri setinde color, grayscale ve segmented olmak üzere farklı görüntü türleri bulunduğu görülmüştür. Bu çalışmada yaprakların gerçek renk bilgisi hastalık belirtilerinin ayırt edilmesi açısından önemli olduğu için yalnızca color klasörü kullanılmıştır. Gri tonlamalı ve önceden segmentasyon uygulanmış görüntüler çalışma kapsamına dahil edilmemiştir. Böylece modelin, yaprak üzerindeki doğal renk değişimlerini, lekelenmeleri, sararmaları ve hastalık belirtilerini doğrudan renkli görüntüler üzerinden öğrenmesi amaçlanmıştır.

Farklı veri setlerinde hastalık isimlerinin farklı biçimlerde etiketlendiği görülmüştür. Örneğin bazı veri setlerinde erken yanıklık, geç yanıklık, yaprak küfü, septoria, pas veya mildiyö gibi hastalıklar ayrı ayrı klasörlerde bulunurken, bu çalışmada bu hastalıklar mantar kaynaklı hastalıklar olarak değerlendirilmiş ve Fungal_Disease sınıfı altında toplanmıştır. Benzer şekilde bakteriyel hastalıklar Bacterial_Disease, viral hastalıklar ise Viral_Disease sınıfı altında düzenlenmiştir. Sağlıklı yaprak görüntüleri ise Healthy sınıfına atanmıştır.


Etiket düzenleme sürecinde sınıf isimlerinin model eğitiminde karışıklığa yol açmaması için tüm klasör adları standart hale getirilmiştir. Bu kapsamda tür ve hastalık bilgisini birlikte ifade eden sınıf isimleri oluşturulmuştur. Örneğin domates sağlıklı yaprakları tomato_healthy, domates mantar hastalığı içeren yaprakları tomato_fungal, patates sağlıklı yaprakları potato_healthy, salatalık bakteriyel hastalık içeren yaprakları ise cucumber_bacterial şeklinde düzenlenmiştir. Böylece her sınıf hem bitki türünü hem de hastalık durumunu ifade edecek şekilde adlandırılmıştır.

Veri setinde bazı klasörlerin çalışma kapsamına uygun olmadığı görülmüştür. Özellikle böcek zararı, fiziksel hasar veya hastalık sınıflandırma yapısına doğrudan karşılık gelmeyen bazı klasörler kapsam dışı bırakılmıştır. Bu tür klasörler model eğitime dahil edilmemiştir. Böylece modelin yalnızca çalışmada belirlenen tür ve hastalık sınıfları üzerinde eğitilmesi sağlanmıştır.

Ön işleme sürecinde görüntü dosyalarının uzantıları da kontrol edilmiştir. .jpg, .jpeg, .png, .bmp ve .webp gibi yaygın görüntü formatları kabul edilmiştir. Görüntüler eğitim sırasında modele uygun boyuta getirilmiştir. EfficientNetB3 tabanlı modeller için giriş görüntü boyutu 300×300 piksel olarak kullanılmıştır. Böylece farklı çözünürlüklerdeki görüntüler model eğitiminde ortak bir giriş boyutuna dönüştürülmüştür.

Bu çalışmada görüntülerin yalnızca yeniden boyutlandırılmasıyla yetinilmemiş, yaprak üzerindeki hastalık belirtilerinin daha belirgin hale getirilebilmesi amacıyla CLAHE ön işleme yöntemi de uygulanmıştır. CLAHE, özellikle görüntüdeki yerel kontrastı artırarak yaprak yüzeyindeki leke, sararma, renk değişimi ve doku farklılıklarının daha belirgin görünmesine yardımcı olmaktadır. Bitki yaprak görüntülerinde ışık koşulları, gölge, kamera açısı ve arka plan gibi faktörler model başarısını etkileyebildiği için CLAHE yöntemi bu çalışmada ön işlem adımı olarak değerlendirilmiştir.

CLAHE uygulanırken görüntünün genel yapısını bozmayacak şekilde kontrast artırımı yapılmıştır. Bu işlem sonucunda yaprak üzerindeki damar yapıları, hastalık lekeleri ve renk geçişleri daha ayırt edilebilir hale gelmiştir. Böylece modelin yalnızca genel yaprak şekline değil, hastalık belirtisi olabilecek yerel görüntü özelliklerine de daha fazla odaklanması amaçlanmıştır. Orijinal görüntü ile CLAHE uygulanmış görüntü arasındaki fark, çalışmada görsel olarak da karşılaştırılmıştır.



Şekil 2.1. Orijinal yaprak görüntüsü ve CLAHE uygulanmış görüntü örneği

Veri seti düzenlendikten sonra eğitim, doğrulama ve test klasörlerinin aynı sınıf yapısına sahip olup olmadığı kontrol edilmiştir. Her üç bölümde de sınıf klasörlerinin tutarlı olması sağlanmıştır. Bu kontrol önemlidir, çünkü eğitimde bulunan bir sınıfın doğrulama veya test aşamasında eksik olması model değerlendirme sürecinde hatalı sonuçlara yol açabilmektedir. Bu nedenle klasör yapısı eğitim öncesinde tekrar incelenmiş ve eksik ya da uyumsuz sınıflar düzeltilmiştir.

Etiket düzenleme işlemlerinden sonra veri seti, çalışmanın hiyerarşik karar destek sistemi yapısına uygun hale getirilmiştir. İlk aşamada bitki türü tespiti için yalnızca tür bilgisini içeren bir veri seti oluşturulmuştur. İkinci aşamada ise hastalık tahmini için domates özel hastalık veri seti ve genel hastalık veri seti hazırlanmıştır. Domates veri seti, sınıf dağılımının daha dengeli olması ve domates yaprak hastalıklarının çalışmada daha ayrıntılı incelenmek istenmesi nedeniyle tür-özel hastalık modeli için kullanılmıştır. Diğer bitki türleri ise genel hastalık sınıflandırma modeli altında değerlendirilmiştir.


Sonuç olarak veri ön işleme ve etiket düzenleme aşamasında, farklı kaynaklardan gelen görüntüler ortak bir yapıya dönüştürülmüş, kapsam dışı sınıflar ayrılmış, hastalık etiketleri standartlaştırılmış ve model eğitime uygun klasör düzeni oluşturulmuştur. Ayrıca görüntüler 300×300 piksel boyutuna getirilmiş ve hastalık belirtilerini daha belirgin hale getirmek amacıyla CLAHE ön işleme yöntemi uygulanmıştır. Bu aşama, modelin doğru sınıfları öğrenebilmesi, hastalık belirtilerini daha iyi ayırt edebilmesi ve eğitim sürecinin sağlıklı ilerleyebilmesi açısından önemli bir adım olmuştur.

2.3. Önerilen Hiyerarşik Karar Destek Sistemi

Bu çalışmada geliştirilen sistem, yaprak görüntüsünden yalnızca tek bir sınıflandırma sonucu üretmek yerine, aşamalı olarak karar veren hiyerarşik bir yapı şeklinde tasarlanmıştır. Bu yaklaşımda sistemin ilk amacı bitki türünü belirlemek, ikinci amacı ise belirlenen türe göre hastalık durumunu tahmin etmektir. Böylece tür bilgisi ve hastalık bilgisi birbirinden bağımsız değerlendirilmemiş, karar süreci daha kontrollü hale getirilmiştir.

Önerilen sistemin genel çalışma akışı, bitki türü tahmini, uygun hastalık modelinin seçilmesi, hastalık sınıflandırması, güven skoru kontrolü ve öneri üretimi adımlarından oluşmaktadır. Kullanıcı sisteme bir yaprak görüntüsü verdiğinde ilk olarak bitki türü tespit modeli çalışmaktadır. Bu model görüntünün domates, patates, biber, mısır, salatalık, patlıcan veya çilek türlerinden hangisine ait olduğunu tahmin etmektedir. Tür tahmininden sonra sistem, hastalık sınıflandırması için hangi modelin kullanılacağına karar vermektedir.

Hiyerarşik Karar Destek Sistemi Veri Akış Diyagramı



Not: Güven skoru düşükse sonuç kesin kabul edilmez; kullanıcıdan daha net ve yaprak odaklı yeni görüntü istenir.

Şekil 2.2. Önerilen hiyerarşik karar destek sisteminin genel çalışma akışı

Şekil 2.1’de görüldüğü gibi sistem, kullanıcıdan alınan yaprak görüntüsünü önce bitki türü tespit modeline vermektedir. Tür tahmini sonucuna göre uygun hastalık sınıflandırma modeli seçilmekte, ardından hastalık sınıfı, güven skoru ve öneri çıktısı üretilmektedir. Bu yapı sayesinde sistem tek aşamalı bir sınıflandırma yerine, tür bilgisine göre yönlendirilen daha kontrollü bir karar destek süreci izlemektedir.

Bu karar mekanizmasında domates türü için özel olarak eğitilmiş hastalık sınıflandırma modeli kullanılmıştır. Bunun nedeni, veri seti incelendiğinde domates türünün hastalık alt sınıfları açısından daha kapsamlı ve dengeli bir dağılıma sahip olmasıdır. Eğer sistem tarafından tahmin edilen tür domates ise domates özel hastalık modeli çalıştırılmaktadır. Domates dışındaki türlerde ise genel hastalık sınıflandırma modeli kullanılmaktadır. Genel hastalık modeli, türden bağımsız olarak sağlıklı, mantar hastalığı, bakteriyel hastalık ve viral hastalık sınıfları üzerinden tahmin yapmaktadır.

Sistemin bu şekilde hiyerarşik olarak tasarlanmasının temel nedeni, tüm tür ve hastalık kombinasyonlarını tek bir sınıflandırma problemi olarak ele almanın bazı durumlarda model başarısını düşürmesidir. Yapılan ön denemelerde, sınıf dengesizliği ve türler arası görsel farklılıklar nedeniyle birleşik sınıflandırma yaklaşımının bazı sınıflarda yeterli performans göstermediği gözlemlenmiştir. Bu nedenle önce türün belirlenmesi, ardından hastalık tahmininin yapılması daha uygun bir yaklaşım olarak değerlendirilmiştir.

Geliştirilen karar destek sistemi iki farklı kullanım modunu destekleyecek şekilde tasarlanmıştır. Birinci modda kullanıcı yalnızca yaprak görüntüsünü sisteme vermekte ve tür tahmini tamamen model tarafından yapılmaktadır. İkinci modda ise kullanıcı bitki türünü önceden biliyorsa tür bilgisini seçebilmekte ve sistem doğrudan hastalık analizine geçmektedir. Bu yapı, hem tam otomatik kullanım senaryosunu hem de kullanıcı destekli kullanım senaryosunu mümkün hale getirmektedir.

Sistemde yalnızca tahmin sınıfı değil, aynı zamanda güven skoru da dikkate alınmıştır. Tür veya hastalık tahmininde güven skorunun düşük olması durumunda kullanıcıya sonucun kesin kabul edilmemesi gerektiği belirtilmektedir. Bu durumda daha net, yakın çekim ve yaprağın görüntüde daha fazla alan kapladığı bir fotoğrafla tekrar test yapılması önerilmektedir. Bu yaklaşım, özellikle gerçek ortam görüntülerinde oluşabilecek belirsizlikleri azaltmak amacıyla kullanılmıştır.

Hastalık tahmini tamamlandıktan sonra sistem kullanıcıya ilgili hastalık sınıfına yönelik temel bir öneri sunmaktadır. Örneğin mantar hastalığına benzer belirtiler tespit edildiğinde fazla nemden kaçınılması, hava sirkülasyonunun artırılması ve gerektiğinde uzman görüşü alınması önerilmektedir. Sağlıklı sınıfı tahmin edildiğinde ise bitkinin mevcut bakım koşullarında takip edilmesi önerilmektedir. Bu nedenle geliştirilen sistem yalnızca bir sınıflandırma modeli değil, kullanıcıya ön değerlendirme ve yönlendirme sağlayan bir karar destek sistemi olarak ele alınmıştır.

Ayrıca model kararlarının daha anlaşılır hale getirilebilmesi için Grad-CAM++ yöntemi sisteme dahil edilmiştir. Bu yöntem ile hastalık tahmini yapılırken modelin görüntünün hangi bölgelerine odaklandığı ısı haritası olarak gösterilmektedir. Böylece kullanıcı veya araştırmacı, modelin kararını yalnızca sayısal sonuç olarak değil, görsel olarak da inceleyebilmektedir.

Sonuç olarak önerilen hiyerarşik karar destek sistemi; bitki türü tespiti, uygun hastalık modelinin seçilmesi, hastalık sınıflandırması, güven skoru kontrolü, öneri üretimi ve Grad-CAM++ tabanlı görsel açıklama adımlarından oluşmaktadır. Bu yapı sayesinde sistem, yaprak görüntülerinden daha anlaşılır, yorumlanabilir ve kullanıcıya yönelik sonuçlar üretebilecek şekilde tasarlanmıştır.

2.4. Bitki Türü Tespit Modelinin Geliştirilmesi

Bu çalışmada geliştirilen karar destek sisteminin ilk aşamasını bitki türü tespit modeli oluşturmaktadır. Bu modelin görevi, sisteme verilen yaprak görüntüsünün hangi bitki türüne ait olduğunu belirlemektir. Tür tahmini, sistemin sonraki aşamasında hangi hastalık sınıflandırma modelinin çalıştırılacağını etkilediği için önemli bir adımdır. Bu nedenle bitki türü tespit modeli, hiyerarşik karar destek sisteminin başlangıç noktası olarak ele alınmıştır.

Bitki türü tespiti için domates, patates, biber, mısır, salatalık, patlıcan ve çilek olmak üzere yedi farklı sınıf belirlenmiştir. Veri setinde yer alan görüntüler, hastalık durumlarından bağımsız olarak yalnızca ait oldukları bitki türüne göre yeniden düzenlenmiştir. Örneğin domatese ait sağlıklı, mantar hastalıklı, bakteriyel hastalıklı veya viral hastalıklı tüm görüntüler tür tespit modeli için tomato sınıfı altında değerlendirilmiştir. Böylece modelin öncelikli olarak yaprağın türüne ait morfolojik özellikleri öğrenmesi amaçlanmıştır.

Tür tespit modelinde EfficientNetB3 mimarisi temel alınmıştır. EfficientNetB3'ün tercih edilmesinde hem önceki mühendislik tasarımı çalışmasında EfficientNet tabanlı bir yaklaşımın kullanılmış olması hem de bu mimarinin doğruluk ve hesaplama maliyeti açısından dengeli bir yapı sunması etkili olmuştur. Ayrıca ilerleyen aşamada modelin mobil uygulamaya entegre edilecek olması nedeniyle çok büyük ve çalıştırılması zor bir mimari yerine daha verimli bir yapı tercih edilmiştir.

Model geliştirme sürecinde transfer öğrenme yaklaşımı kullanılmıştır. Bu kapsamda EfficientNetB3 modeli, önceden eğitilmiş ağırlıklarla başlatılmış ve yaprak görüntülerinden oluşan veri setine uyarlanmıştır. Transfer öğrenme sayesinde modelin daha önce öğrendiği genel görüntü özelliklerinden yararlanılmış, ardından bu özelliklerin bitki yapraklarına özgü sınıflandırma problemine adapte edilmesi sağlanmıştır.

EfficientNetB3 omurgasının ardından modele dikkat mekanizması eklenmiştir. Bu amaçla CBAM yapısından yararlanılmıştır. CBAM, kanal ve uzamsal dikkat mekanizmalarını kullanarak modelin görüntü içerisindeki önemli özelliklere daha fazla odaklanmasına yardımcı olmaktadır. Yaprak görüntülerinde tür ayrımı yapılırken yaprak şekli, damar yapısı, kenar özellikleri, renk tonu ve yüzey dokusu gibi görsel ipuçları önemli olabilmektedir. Bu nedenle dikkat mekanizmasının, modelin ayırt edici bölgelere daha etkili odaklanmasına katkı sağlaması hedeflenmiştir.

Modelin son kısmında global average pooling, dropout ve tam bağlantılı sınıflandırma katmanları kullanılmıştır. Global average pooling katmanı, EfficientNetB3 ve CBAM sonrasında elde edilen özellik haritalarını daha kompakt bir temsile dönüştürmektedir. Dropout katmanı ise aşırı öğrenmeyi azaltmak amacıyla kullanılmıştır. Son katmanda softmax aktivasyon fonksiyonu kullanılarak yedi bitki türü için olasılık değerleri üretilmiştir. Model çıktısında en yüksek olasılığa sahip sınıf tahmin edilen bitki türü olarak kabul edilmiştir.

Eğitim aşamasında görüntüler modele uygun olacak şekilde 300×300 piksel boyutuna dönüştürülmüştür. Modelin farklı ışık, açı ve görüntü koşullarına daha dayanıklı hale gelmesi amacıyla veri artırma yöntemlerinden yararlanılmıştır. Bu kapsamda döndürme, yatay/dikey çevirme, yakınlaştırma ve renk değişimi gibi işlemler uygulanmıştır. Böylece modelin yalnızca eğitim görüntülerini ezberlemesi yerine, farklı koşullarda çekilmiş yaprak görüntülerine karşı daha genellenebilir hale gelmesi amaçlanmıştır.

Veri setindeki sınıflar arasında görüntü sayısı açısından dengesizlik bulunduğu için eğitim sürecinde bu durum dikkate alınmıştır. Bazı türlerin görüntü sayısı diğer türlere göre daha fazla olduğundan, modelin çoğunluk sınıflarına yönelmesini azaltmak amacıyla sınıf ağırlıkları kullanılmıştır. Bu sayede az örnek içeren türlerin eğitim sürecinde daha fazla dikkate alınması sağlanmaya çalışılmıştır.

Model eğitimi iki aşamalı olarak gerçekleştirilmiştir. İlk aşamada EfficientNetB3 omurgasının büyük bölümü dondurularak yalnızca eklenen üst katmanların eğitilmesi sağlanmıştır. Bu aşama, modelin veri setine hızlı ve kararlı bir şekilde uyum sağlaması için kullanılmıştır. İkinci aşamada ise modelin belirli katmanları yeniden eğitime açılarak ince ayar yapılmıştır. Bu fine-tuning aşaması ile modelin bitki türlerine ait daha özel görsel özellikleri öğrenmesi hedeflenmiştir.

Tür tespit modelinin çıktısı yalnızca tahmin edilen sınıftan oluşmamaktadır. Model aynı zamanda her sınıf için güven skoru üretmektedir. Bu güven skoru, karar destek sisteminin sonraki aşamalarında kullanılmıştır. Eğer tür tahmini yeterince yüksek güvenle yapılmışsa sistem bu tür bilgisine göre hastalık modelini seçmektedir. Güven skorunun düşük olduğu durumlarda ise sonucun kesin kabul edilmemesi ve daha net bir görüntü ile tekrar test yapılması gerektiği kullanıcıya bildirilmektedir.

Gerçek ortam görüntülerinde modelin kontrollü veri setlerine göre daha zorlandığı gözlemlendiği için tür tespit modeli gerçek görüntülerle de ayrıca değerlendirilmiştir. Bu aşamada farklı bitki türlerine ait gerçek dünya görüntüleri kullanılarak modelin saha koşullarındaki davranışı incelenmiştir. Bu denemeler, özellikle mobil uygulama kullanımında görüntünün net, yakın çekim ve yaprağı yeterince kapsayacak şekilde alınmasının önemli olduğunu göstermiştir.

Sonuç olarak bitki türü tespit modeli, önerilen hiyerarşik karar destek sisteminin ilk ve kritik bileşeni olarak geliştirilmiştir. EfficientNetB3 tabanlı mimari, CBAM dikkat mekanizması, veri artırma, sınıf ağırlıkları ve ince ayar eğitimi birlikte kullanılarak yaprak görüntülerinden bitki türünün tahmin edilmesi amaçlanmıştır. Bu modelden elde edilen tür tahmini, sistemin hastalık sınıflandırma aşamasında kullanılacak modelin belirlenmesini sağlamaktadır.

2.4.1. Önerilen Derin Öğrenme Ağının Mimari Yapısı

Bu çalışmada kullanılan bitki türü tespit modeli, yalnızca tek bir sınıflandırma katmanından oluşan basit bir yapı yerine; özellik çıkarıcı omurga, dikkat mekanizması ve sınıflandırıcı başlık olmak üzere üç temel bileşenden oluşan modüler bir derin öğrenme mimarisi olarak tasarlanmıştır. Modele verilen giriş görüntüleri $300 \times 300 \times 3$ boyutunda RGB yaprak görüntüleridir. Görüntüler eğitim öncesinde uygun boyuta getirilmiş ve modelin giriş katmanına bu formatta aktarılmıştır.

Modelin ana özellik çıkarıcı bölümü olarak EfficientNetB3 mimarisi kullanılmıştır. EfficientNetB3, yaprak görüntülerinden düşük seviyeli kenar ve renk bilgilerini, orta seviyeli doku ve damar yapılarını, daha derin katmanlarda ise bitki türlerine özgü ayırt edici şekil ve yapısal özellikleri çıkarmaktadır. Bu sayede model, farklı bitki türlerine ait yaprakların biçim, renk dağılımı, damar yapısı ve yüzey dokusu gibi özelliklerini öğrenebilmektedir.

EfficientNetB3 omurgasından elde edilen özellik haritaları doğrudan sınıflandırma katmanına verilmemiş, öncelikle CBAM dikkat mekanizmasından geçirilmiştir. CBAM, kanal dikkat mekanizması ve uzamsal dikkat mekanizması olmak üzere iki aşamadan oluşmaktadır. Kanal dikkat mekanizması, özellik haritaları içerisindeki hangi kanalların sınıflandırma açısından daha önemli olduğunu öğrenmektedir. Uzamsal dikkat mekanizması ise modelin görüntü üzerinde hangi bölgelere daha fazla odaklanması gerektiğini belirlemektedir. Böylece model, yaprak üzerindeki ayırt edici damar yapısı, renk geçişleri, yaprak formu ve dokusal bölgeleri daha etkili biçimde değerlendirebilmektedir.

CBAM bloğundan sonra elde edilen özellik haritaları Global Average Pooling katmanı ile daha düşük boyutlu bir özellik vektörüne dönüştürülmüştür. Bu işlem, modelin parametre sayısını azaltırken görüntüden çıkarılan genel temsil bilgisinin korunmasını sağlamaktadır. Ardından Dropout katmanı kullanılarak aşırı öğrenme riskinin azaltılması hedeflenmiştir. Son aşamada ise Softmax aktivasyon fonksiyonuna sahip çıkış katmanı kullanılarak her bir bitki türü için olasılık değeri üretilmiştir.

Tür tespit modelinin çıkış katmanı yedi sınıftan oluşmaktadır. Bu sınıflar mısır, salatalık, patlıcan, biber, patates, çilek ve domates olarak belirlenmiştir. Model, giriş görüntüsünü bu yedi sınıftan birine ait olasılık değerleriyle eşleştirmekte ve en yüksek olasılığa sahip sınıfı tahmin sonucu olarak üretmektedir. Bu yapı sayesinde sistemin ilk aşamasında yaprak görüntüsünün hangi bitki türüne ait olduğu belirlenmekte, sonraki aşamada ise tahmin edilen türe uygun hastalık sınıflandırma modeli çalıştırılmaktadır.

Aşağıda EfficientNetB3-CBAM tabanlı tür tespit modelinin genel katman akışı verilmiştir.

Sıra	Bileşen / Katman	Mimari görevi	Açıklama
1	Giriş katmanı	Görüntüyü modele alma	300×300×3 boyutunda RGB yaprak görüntüsü kullanılır.
2	Ön işleme	Görüntüyü standartlaştırma	Görüntü yeniden boyutlandırılır; ilgili deneylerde CLAHE ile yerel kontrast artırılır.
3	EfficientNetB3 omurgası	Özellik çıkarımı	Önceden öğrenilmiş derin özellikler kullanılarak yaprak dokusu, damar ve renk bilgileri çıkarılır.
4	CBAM kanal dikkati	Önemli kanalları seçme	Ortalama ve maksimum havuzlama ile sınıflandırmaya katkısı yüksek özellik kanalları ağırlıklandırılır.
5	CBAM uzamsal dikkat	Önemli görüntü bölgelerini belirleme	Modelin yaprak üzerindeki ayırt edici bölgelere daha fazla odaklanması sağlanır.
6	Global Average Pooling	Özellik vektörü oluşturma	Uzamsal özellik haritaları tek boyutlu temsil vektörüne dönüştürülür.
7	Düzenleme katmanları	Aşırı öğrenmeyi azaltma	Dropout ve benzeri düzenleme işlemleriyle genelleme başarısı desteklenir.
8	Softmax çıkış katmanı	Sınıf olasılığı üretme	Tür modelinde 7 sınıf, hastalık modellerinde 4 sınıf için olasılık değeri üretilir.

Tablo 2.1. EfficientNetB3-CBAM tabanlı modelin genel katman akışı

Genel olarak bu mimari yapıda EfficientNetB3 modeli temel özellik çıkarıcı omurga olarak görev yaparken, CBAM bloğu çıkarılan özelliklerin önem derecesini yeniden ağırlıklandırmaktadır. Global Average Pooling ve Dropout katmanları modelin daha dengeli ve genellenebilir bir yapı kazanmasına katkı sağlarken, Softmax çıkış katmanı tür tahmininin olasılık temelli olarak üretilmesini sağlamaktadır.

2.5. Domates Hastalık Sınıflandırma Modelinin Geliştirilmesi

Hiyerarşik karar destek sisteminin ikinci aşamasında, bitki türü tahmininden sonra hastalık sınıflandırması yapılmaktadır. Bu çalışmada domates türü için özel bir hastalık sınıflandırma modeli geliştirilmiştir. Domates sınıfının seçilmesinde, veri seti incelendiğinde domatese ait hastalık alt sınıflarının diğer türlere göre daha kapsamlı ve daha dengeli bir dağılım göstermesi etkili olmuştur. Ayrıca danışman görüşü doğrultusunda, tüm türler üzerinde çok geniş kapsamlı bir hastalık tahmini yapmak yerine, daha dengeli ve güçlü veri içeren bir tür üzerinde daha başarılı sonuçlar elde etmeye odaklanılmıştır.

Domates hastalık sınıflandırma modeli, domates yaprak görüntülerini dört temel sınıfa ayıracak şekilde tasarlanmıştır. Bu sınıflar *Healthy*, *Fungal_Disease*, *Bacterial_Disease* ve *Viral_Disease* olarak belirlenmiştir. Sağlıklı domates yaprakları *Healthy* sınıfına dahil edilmiştir. Erken yanıklık, geç yanıklık, yaprak küfü, septoria ve benzeri mantar kaynaklı hastalıklar *Fungal_Disease* sınıfı altında toplanmıştır. Bakteriyel leke gibi hastalıklar *Bacterial_Disease*, domates mozaik virüsü ve sarı yaprak kıvrıcıklık virüsü gibi hastalıklar ise *Viral_Disease* sınıfında değerlendirilmiştir.

Domates hastalık modelinin veri seti, daha önce hazırlanan tür-hastalık birleşimli veri setinden yalnızca domates sınıfları seçilerek oluşturulmuştur. Bu kapsamda *tomato_healthy*, *tomato_fungal*, *tomato_bacterial* ve *tomato_viral* klasörleri dikkate alınmış ve bu klasörlerdeki görüntüler dört ana hastalık sınıfına göre yeniden düzenlenmiştir. Böylece modelin yalnızca domates yaprakları üzerindeki hastalık belirtilerine odaklanması sağlanmıştır.

Model mimarisi olarak bitki türü tespit modelinde olduğu gibi EfficientNetB3 tabanlı bir yapı kullanılmıştır. EfficientNetB3 omurgası, yaprak görüntülerinden yüksek seviyeli özelliklerin çıkarılması için temel model olarak seçilmiştir. Bu omurganın üzerine CBAM dikkat mekanizması eklenerek modelin hastalık belirtisi taşıyabilecek bölgelere daha fazla odaklanması amaçlanmıştır. Domates yapraklarında hastalık belirtileri genellikle leke, sararma, renk değişimi, kuruma veya doku bozulması şeklinde görüldüğü için dikkat mekanizmasının bu bölgelerin öğrenilmesine katkı sağlaması hedeflenmiştir.

Modelin son katmanlarında global average pooling, dropout ve softmax sınıflandırma katmanı kullanılmıştır. Global average pooling katmanı, özellik haritalarını sınıflandırma için daha uygun bir yapıya dönüştürmektedir. Dropout katmanı aşırı öğrenmeyi azaltmak amacıyla eklenmiştir. Son katmanda kullanılan softmax aktivasyon fonksiyonu ile dört hastalık sınıfı için olasılık değerleri elde edilmiştir. En yüksek olasılığa sahip sınıf, modelin hastalık tahmini olarak kabul edilmiştir.

Eğitim sürecinde görüntüler EfficientNetB3 mimarisine uygun olacak şekilde 300×300 piksel boyutuna dönüştürülmüştür. Modelin farklı görüntü koşullarına daha dayanıklı hale gelmesi için veri artırma işlemleri uygulanmıştır. Bu kapsamda döndürme, çevirme, yakınlaştırma ve renk değişimi gibi işlemlerden yararlanılmıştır. Böylece modelin yalnızca belirli görüntülere bağlı kalmadan, farklı açılardan ve farklı koşullarda çekilmiş domates yapraklarını daha iyi değerlendirebilmesi amaçlanmıştır.

Domates veri seti diğer türlere göre daha dengeli olsa da hastalık sınıfları arasında yine de görüntü sayısı farklılıkları bulunmaktadır. Bu nedenle eğitim aşamasında sınıf dengesizliği dikkate alınmıştır. Modelin çoğunluk sınıflarına fazla yönelmesini azaltmak amacıyla sınıf ağırlıkları ve uygun kayıp fonksiyonu yaklaşımları kullanılmıştır. Bu sayede az örnek içeren sınıfların da eğitim sürecinde daha etkili şekilde öğrenilmesi hedeflenmiştir.

Model eğitimi iki aşamalı olarak gerçekleştirilmiştir. İlk aşamada EfficientNetB3 omurgasının büyük bölümü dondurularak yalnızca sonradan eklenen sınıflandırma katmanları eğitilmiştir. Bu aşamada modelin domates hastalık sınıflandırma problemine temel düzeyde uyum sağlaması amaçlanmıştır. İkinci aşamada ise modelin bazı katmanları eğitime açılarak fine-tuning işlemi uygulanmıştır. Bu sayede modelin domates yapraklarındaki hastalık belirtilerine ait daha ayrıntılı özellikleri öğrenmesi sağlanmıştır.

Domates hastalık sınıflandırma modeli, hiyerarşik karar destek sisteminde yalnızca tür tahmini domates olduğunda çalışacak şekilde kullanılmıştır. Yani sisteme verilen görüntü tür tespit modeli tarafından domates olarak tahmin edildiğinde, hastalık analizi için domates özel hastalık modeli devreye girmektedir. Bu yapı sayesinde domates yaprakları için genel hastalık modeline göre daha özelleştirilmiş bir tahmin mekanizması oluşturulmuştur.

Model çıktısında tahmin edilen hastalık sınıfının yanında güven skoru da üretilmektedir. Bu güven skoru, sistemin kullanıcıya sunduğu kararın ne kadar güvenilir olduğunu değerlendirmek için kullanılmıştır. Hastalık güven skoru düşük olduğunda kullanıcıya sonucun kesin kabul edilmemesi gerektiği ve daha net bir görüntü ile tekrar test yapılmasının uygun olacağı belirtilmiştir. Böylece modelin belirsiz kaldığı durumlarda kullanıcıyı doğrudan yanlış yönlendirilmemiştir.

Domates hastalık sınıflandırma modeli, yalnızca hastalık tahmini yapmak için değil, aynı zamanda karar destek sisteminin öneri modülüne girdi sağlamak için de kullanılmıştır. Modelin tahmin ettiği hastalık sınıfına göre kullanıcıya temel bakım ve müdahale önerileri sunulmuştur. Örneğin mantar hastalığı tahmininde nem kontrolü ve hava sirkülasyonu önerilirken, viral hastalık tahmininde enfekte bitkilerin ayrılması ve uzman desteği alınması gerektiği belirtilmiştir.

Sonuç olarak domates hastalık sınıflandırma modeli, çalışmanın hastalık tespiti aşamasındaki en önemli bileşenlerinden biri olarak geliştirilmiştir. Domates türüne özel veri seti kullanılması, EfficientNetB3 ve CBAM tabanlı mimari, veri artırma, sınıf dengesizliğine yönelik eğitim stratejileri ve güven skoru kontrolü ile modelin daha kontrollü ve yorumlanabilir bir hastalık tahmini yapması amaçlanmıştır. Bu model, hiyerarşik karar destek sisteminde domates türü için özel hastalık analizi sağlayan temel mekanizma olarak kullanılmıştır.

2.5.1. Domates Hastalık Modelinin Ağ Yapısı ve Mimari Özellikleri

Bu çalışmada domates hastalık sınıflandırması için kullanılan model, hiyerarşik karar destek sisteminin ikinci aşamasında görev yapan tür-özel bir hastalık sınıflandırma modelidir. Bu model yalnızca domates yaprak görüntüleri üzerinde eğitilmiş ve domates türüne ait yapraklarda görülebilecek hastalık durumlarını sınıflandırmak amacıyla geliştirilmiştir. Modelin giriş boyutu $300 \times 300 \times 3$ olarak belirlenmiş ve RGB formatındaki yaprak görüntüleri bu boyuta dönüştürülerek modele verilmiştir.

Domates hastalık modelinin temel özellik çıkarıcı kısmında EfficientNetB3 mimarisi kullanılmıştır. EfficientNetB3 omurgası, yaprak görüntülerinden renk değişimleri, leke oluşumları, doku bozulmaları, damar çevresindeki farklılaşmalar ve hastalık belirtisi olabilecek yüzey özelliklerini öğrenmektedir. Hastalık sınıflandırma probleminde özellikle yaprak üzerindeki küçük lekeler, renk solmaları ve bölgesel doku farklılıkları önemli olduğu için güçlü bir özellik çıkarıcı mimarinin kullanılması tercih edilmiştir.

EfficientNetB3 omurgasından elde edilen özellik haritaları CBAM dikkat mekanizmasına aktarılmıştır. CBAM yapısı, modelin hastalık sınıflandırması açısından daha anlamlı olan kanal ve görüntü bölgelerine odaklanmasını sağlamaktadır. Kanal dikkat mekanizması, çıkarılan özellik haritaları içinde hastalık belirtisini temsil etme olasılığı yüksek olan kanalları ön plana çıkarmaktadır. Uzamsal dikkat mekanizması ise yaprak üzerinde hastalık belirtisi taşıyan leke, renk değişimi veya bozulmuş doku bölgelerine daha fazla ağırlık verilmesine yardımcı olmaktadır.

CBAM bloğundan sonra elde edilen özellik haritaları Global Average Pooling katmanı ile tek boyutlu bir özellik vektörüne dönüştürülmüştür. Bu işlem, özellik haritalarındaki genel bilgiyi korurken modelin parametre sayısını azaltmaktadır. Ardından Dropout katmanı kullanılarak modelin eğitim verisine aşırı uyum sağlamasının önüne geçilmeye çalışılmıştır. Son katmanda ise Softmax aktivasyon fonksiyonu kullanılarak her hastalık sınıfı için olasılık değeri üretilmiştir.

Domates hastalık modelinin çıkış katmanı dört sınıftan oluşmaktadır. Bu sınıflar *Bacterial_Disease*, *Fungal_Disease*, *Healthy* ve *Viral_Disease* olarak belirlenmiştir. Model, giriş olarak verilen domates yaprağı görüntüsünü bu dört sınıftan birine ait olasılık değerleriyle değerlendirmekte ve en yüksek olasılığa sahip sınıfı tahmin sonucu olarak üretmektedir.

Bileşen / Katman	Görevi	Açıklama
Giriş katmanı	Görüntünün modele alınması	300×300×3 boyutundaki RGB domates yaprağı görüntüsü modele verilir.
EfficientNetB3 omurgası	Özellik çıkarımı	Yaprak üzerindeki renk, doku, leke ve hastalık belirtisi olabilecek görsel özellikler çıkarılır.
CBAM kanal dikkat bloğu	Kanal bazlı önemlendirme	Hastalık sınıflandırması açısından önemli özellik kanalları ön plana çıkarılır.
CBAM uzamsal dikkat bloğu	Bölge bazlı odaklanma	Modelin yaprak üzerindeki belirti bölgelerine daha fazla odaklanması sağlanır.
Global Average Pooling	Özellik vektörü oluşturma	Özellik haritaları sınıflandırmaya uygun daha düşük boyutlu temsil vektörüne dönüştürülür.
Dropout katmanı	Aşırı öğrenmeyi azaltma	Modelin eğitim verisine aşırı uyum sağlaması azaltılmaya çalışılır.
Softmax çıkış katmanı	Hastalık sınıfı olasılığı üretme	<i>Bacterial_Disease</i> , <i>Fungal_Disease</i> , <i>Healthy</i> ve <i>Viral_Disease</i> olmak üzere dört hastalık sınıfı için olasılık değeri üretir.

Tablo 2.2. Domates hastalık modelinin genel katman akışı

Bu mimari yapı sayesinde domates yapraklarında görülen hastalık belirtileri, genel tür özelliklerinden bağımsız olarak daha ayrıntılı biçimde öğrenilebilmektedir. Domates türüne özel ayrı bir hastalık modelinin kullanılması, hiyerarşik sistemde domates tahmin edilen görüntüler için daha kontrollü ve tür odaklı bir hastalık sınıflandırması yapılmasını sağlamaktadır.

2.6. Genel Hastalık Sınıflandırma Modelinin Geliştirilmesi

Hiyerarşik karar destek sisteminde domates türü için özel bir hastalık sınıflandırma modeli geliştirilmiştir. Ancak sistemin yalnızca domates yaprakları üzerinde çalışması yeterli görülmemiştir. Kullanıcı sisteme patates, biber, mısır, salatalık, patlıcan veya çilek gibi farklı bitki türlerine ait yaprak görüntüleri de verebileceği için domates dışındaki türlerde kullanılmak üzere genel bir hastalık sınıflandırma modeli geliştirilmiştir.

Genel hastalık sınıflandırma modelinin amacı, bitki türünden bağımsız olarak yaprak görüntüsündeki genel hastalık belirtilerini değerlendirmektir. Bu model, tür-özel kesin bir hastalık tanısı vermek yerine, yaprağın sağlıklı mı yoksa temel hastalık gruplarından birine mi ait olduğunu tahmin etmektedir. Bu nedenle genel hastalık modeli, karar destek sisteminde domates dışındaki türler için ön değerlendirme yapan tamamlayıcı bir model olarak kullanılmıştır.

Genel hastalık sınıflandırma modeli *Healthy*, *Fungal_Disease*, *Bacterial_Disease* ve *Viral_Disease* olmak üzere dört temel sınıf üzerinden eğitilmiştir. Bu modelde sınıflar bitki türüne göre değil, hastalık durumuna göre oluşturulmuştur. Yani sınıf adlarında doğrudan domates, patates veya biber gibi tür bilgisi yer almamaktadır. Ancak her hastalık sınıfının içinde farklı bitki türlerine ait görüntüler bulunmaktadır.

Bu kapsamda *Healthy* sınıfında domates, patates, biber, mısır, salatalık, patlıcan ve çilek gibi türlere ait sağlıklı yaprak görüntüleri kullanılmıştır. *Fungal_Disease* sınıfında domates, patates, biber, mısır, salatalık, patlıcan ve çilek türlerinde görülen mantar kaynaklı hastalık görüntüleri yer almıştır. *Bacterial_Disease* sınıfında veri setinde bulunan domates, biber ve salatalık gibi türlere ait bakteriyel hastalık görüntüleri değerlendirilmiştir. *Viral_Disease* sınıfında ise özellikle domates ve patlıcan gibi türlere ait viral hastalık görüntüleri kullanılmıştır. Böylece model, farklı bitki türlerinde görülen temel hastalık belirtilerini ortak sınıflar altında öğrenebilecek şekilde hazırlanmıştır.

Genel hastalık modelinin bu şekilde oluşturulmasının temel nedeni, veri setindeki sınıf dağılımı ve hastalık çeşitliliğidir. Her bitki türü için ayrı ayrı hastalık modeli geliştirmek, bazı türlerde yeterli ve dengeli veri bulunmadığı için sağlıklı bir yaklaşım olmayacaktır. Örneğin bazı türlerde yalnızca sağlıklı ve mantar hastalıklı görüntüler bulunurken, bazı türlerde bakteriyel veya viral hastalık görüntüleri çok az sayıda yer almaktadır. Bu durum, her tür için ayrı model eğitildiğinde bazı modellerin yetersiz veriyle eğitilmesine ve düşük başarı göstermesine neden olabilir.

Buna karşılık domates türünün hastalık alt sınıfları incelendiğinde, diğer türlere göre daha kapsamlı ve dengeli bir veri dağılımına sahip olduğu görülmüştür. Bu nedenle domates için özel bir hastalık sınıflandırma modeli geliştirilmiştir. Domates dışındaki türlerde ise yeterli veri dağılımı her hastalık sınıfı için aynı düzeyde sağlanamadığından, bu türler genel hastalık sınıflandırma modeli altında değerlendirilmiştir. Böylece sistem hem domates için daha özelleştirilmiş bir analiz yapabilmekte hem de diğer türler için genel bir hastalık tahmini sunabilmektedir.

Bu tercih aynı zamanda tek aşamalı birleşik sınıflandırma yaklaşımına göre daha kontrollü bir yapı sağlamaktadır. Yapılan ön denemelerde, tüm tür ve hastalık kombinasyonlarını tek bir modelde sınıflandırmanın sınıf dengesizliği nedeniyle bazı sınıflarda düşük başarıya yol açtığı görülmüştür. Özellikle az görüntü içeren sınıflarda modelin kararsız tahminler yapabildiği gözlemlenmiştir. Bu nedenle sistem önce tür tespiti yapan, ardından uygun hastalık modelini çalıştıran hiyerarşik bir yapıya dönüştürülmüştür.

Genel hastalık sınıflandırma modelinde EfficientNetB3 tabanlı bir mimari kullanılmıştır. EfficientNetB3 omurgası, yaprak görüntülerinden ayırt edici özelliklerin çıkarılması için temel model olarak seçilmiştir. Bu omurgaya CBAM dikkat mekanizması eklenerek modelin görüntü içerisindeki önemli kanal ve uzamsal bölgelere daha fazla odaklanması amaçlanmıştır. Farklı türlere ait yaprak şekilleri ve dokuları değişkenlik gösterdiği için modelin yalnızca tür özelliklerine değil, hastalık belirtisi olabilecek leke, sararma, renk değişimi, kuruma ve doku bozulması gibi görsel özelliklere odaklanması hedeflenmiştir.

Modelin son katmanlarında global average pooling, dropout ve softmax sınıflandırma katmanı kullanılmıştır. Softmax katmanı dört temel hastalık sınıfı için olasılık değerleri üretmektedir. En yüksek olasılığa sahip sınıf modelin tahmini olarak kabul edilmiştir. Bununla birlikte, genel hastalık modelinin çıktısı kesin zirai tanı olarak değil, genel semptom tahmini ve karar destek çıktısı olarak değerlendirilmiştir.

Eğitim sürecinde görüntüler 300×300 piksel boyutuna dönüştürülmüştür. Modelin farklı görüntü koşullarına daha dayanıklı hale gelmesi için veri artırma işlemleri uygulanmıştır. Bu kapsamda döndürme, çevirme, yakınlaştırma ve renk değişimi gibi işlemlerden yararlanılmıştır. Böylece modelin farklı açılardan, farklı ışık koşullarında ve farklı türlerde çekilmiş yaprak görüntülerine karşı daha genellenebilir hale gelmesi amaçlanmıştır.

Genel hastalık veri setinde sınıflar arasında görüntü sayısı bakımından dengesizlikler bulunduğu için eğitim sırasında bu durum dikkate alınmıştır. Bazı hastalık sınıflarının diğerlerine göre daha az görüntü içermesi, modelin çoğunluk sınıflarına yönelmesine neden olabileceğinden sınıf ağırlıkları ve uygun eğitim stratejileri kullanılmıştır. Bu sayede az temsil edilen hastalık sınıflarının da eğitim sürecinde daha etkili öğrenilmesi hedeflenmiştir.

Karar destek sistemi çalışırken genel hastalık modeli yalnızca belirli durumlarda devreye girmektedir. Sisteme verilen yaprak görüntüsü tür tespit modeli tarafından domates olarak tahmin edilirse, hastalık analizi için domates özel hastalık modeli kullanılmaktadır. Eğer tahmin edilen tür domates dışında bir tür ise genel hastalık sınıflandırma modeli çalıştırılmaktadır. Böylece domates türü için daha ayrıntılı ve özelleştirilmiş bir model kullanılırken, diğer türler için genel hastalık belirtisi tahmini yapılmaktadır.

Genel hastalık modelinin çıktısında tahmin edilen hastalık sınıfının yanında güven skoru da üretilmektedir. Hastalık güven skorunun düşük olduğu durumlarda kullanıcıya sonucun kesin kabul edilmemesi gerektiği ve daha net bir görüntü ile yeniden test yapılmasının uygun olacağı bildirilmektedir. Bu yaklaşım özellikle gerçek ortam görüntülerinde oluşabilecek ışık, arka plan, kamera açısı ve görüntü kalitesi kaynaklı belirsizlikleri azaltmak amacıyla kullanılmıştır.

Modelin tahmin ettiği hastalık sınıfı, öneri modülü ile birlikte değerlendirilmiştir. *Healthy* sınıfı tahmin edildiğinde bitkinin mevcut bakım koşullarında takip edilmesi önerilmiştir. *Fungal_Disease* tahmininde nem kontrolü, hava sirkülasyonunun artırılması ve gerekirse uzman görüşü alınması önerilmiştir. *Bacterial_Disease* tahmininde enfekte yaprakların kontrol edilmesi ve yayılımın önlenmesi vurgulanmıştır. *Viral_Disease* tahmininde ise enfekte bitkilerin ayrılması, vektör böcek kontrolü ve uzman desteği alınması gerektiği belirtilmiştir.

Sonuç olarak genel hastalık sınıflandırma modeli, hiyerarşik karar destek sisteminin domates dışındaki türlerde de çalışabilmesini sağlayan önemli bir bileşen olarak geliştirilmiştir. Bu model sayesinde sistem, farklı bitki türlerine ait yaprak görüntülerinde temel hastalık grupları üzerinden genel bir ön değerlendirme yapabilmekte ve kullanıcıya güven skoru ile birlikte öneri sunabilmektedir. Ancak modelin tür-özel kesin bir tanı yerine, genel hastalık belirtisi tahmini sunduğu dikkate alınmalıdır.

2.6.1. Genel Hastalık Modelinin Ağ Yapısı ve Mimari Özellikleri


Genel hastalık sınıflandırma modeli, hiyerarşik karar destek sisteminde domates dışındaki bitki türleri için hastalık tahmini yapmak amacıyla geliştirilmiştir. Bu model, farklı bitki türlerine ait yaprak görüntülerini ortak hastalık üst sınıfları altında değerlendirmektedir. Modelin giriş boyutu $300 \times 300 \times 3$ olarak belirlenmiş ve görüntüler RGB formatında modele aktarılmıştır.

Genel hastalık modelinde de temel özellik çıkarıcı omurga olarak EfficientNetB3 mimarisi kullanılmıştır. EfficientNetB3, farklı bitki türlerine ait yaprak görüntülerinden renk, doku, damar yapısı, leke oluşumu ve yaprak yüzeyindeki bozulmaları öğrenmektedir. Genel hastalık modeli birden fazla bitki türünden görüntü içerdiği için, modelin yalnızca tek bir türe özgü yaprak formunu değil, farklı türlerde ortak olarak görülebilen hastalık belirtilerini öğrenmesi amaçlanmıştır.

EfficientNetB3 tarafından çıkarılan özellik haritaları CBAM dikkat mekanizması ile yeniden ağırlıklandırılmıştır. CBAM bloğu, farklı bitki türlerinden gelen görüntülerde hastalıkla ilişkili olabilecek bölgelerin daha etkili değerlendirilmesine yardımcı olmaktadır. Kanal dikkat mekanizması, hastalık belirtilerini temsil eden özellik kanallarını ön plana çıkarırken; uzamsal dikkat mekanizması, görüntü üzerinde leke, sararma, renk değişimi veya doku bozulması gibi alanlara daha fazla odaklanılmasını sağlamaktadır.

CBAM sonrasında Global Average Pooling katmanı kullanılarak özellik haritaları sınıflandırmaya uygun bir özellik vektörüne dönüştürülmüştür. Dropout katmanı ile modelin eğitim verisine aşırı bağımlı hale gelmesi azaltılmaya çalışılmıştır. Son aşamada Softmax çıkış katmanı kullanılmış ve modelin dört hastalık sınıfı için olasılık üretmesi sağlanmıştır.

Genel hastalık modelinin çıkış katmanı Bacterial_Disease, Fungal_Disease, Healthy ve Viral_Disease olmak üzere dört sınıftan oluşmaktadır. Bu model, türden bağımsız olarak yaprak görüntüsünü genel hastalık kategorilerinden birine atamaktadır. Bu nedenle modelin çıktısı, domates dışındaki türler için tür-özel kesin hastalık tanısı yerine genel hastalık durumu tahmini olarak değerlendirilmiştir.



Şekil 2.3. Genel hastalık modelinin genel katman akışı

Genel hastalık modeli, farklı bitki türlerinden gelen görüntüler üzerinde ortak hastalık belirtilerini öğrenmeye çalıştığı için domates özel modeline göre daha genel bir sınıflandırma yaklaşımı sunmaktadır. Bu yapı sayesinde sistem, domates dışındaki türlerde de kullanıcıya hastalık durumuna ilişkin temel bir karar destek çıktısı verebilmektedir. Ancak farklı türlerin yaprak yapıları ve hastalık belirtileri değişkenlik gösterebildiği için bu modelin çıktıları genel hastalık tahmini olarak yorumlanmalıdır.

2.7. Yaprak Odaklı Ön İşleme ve Grad-CAM++ Analizi

Bu çalışmada modelin yalnızca sınıflandırma sonucu üretmesi yeterli görülmemiş, aynı zamanda modelin görüntüde hangi bölgelere odaklandığının da incelenmesi amaçlanmıştır. Özellikle gerçek ortam görüntülerinde arka plan, ışık koşulları, yaprağın görüntüde kapladığı alan ve kamera açısı gibi faktörlerin model tahminini etkileyebildiği görülmüştür. Bu nedenle hem görüntülerin yaprak bölgesine daha fazla odaklanmasını sağlamak hem de model kararlarını yorumlayabilmek amacıyla yaprak odaklı ön işleme ve Grad-CAM++ analizi uygulanmıştır.

Yaprak odaklı ön işleme aşamasında temel amaç, görüntü içerisindeki asıl bilgi taşıyan bölgenin yaprak olduğunu dikkate alarak modelin arka plan yerine yaprak dokusuna yönelmesini sağlamaktır. Gerçek ortamda çekilen görüntülerde yaprak dışında toprak, duvar, masa, el, saksı veya farklı bitki parçaları gibi arka plan öğeleri bulunabilmektedir. Bu tür öğeler bazı durumlarda modelin yanlış bölgelere odaklanmasına ve hatalı tahmin üretmesine neden olabilmektedir. Bu nedenle görüntüler üzerinde yaprağın daha belirgin hale getirilmesine yönelik ön işleme adımları uygulanmıştır.

Ön işleme sürecinde görüntüler öncelikle okunmuş ve model girişine uygun biçime getirilmiştir. Daha sonra yaprak bölgesinin görüntü içerisinde daha baskın hale gelmesi için maskeleme ve kırpma yaklaşımlarından yararlanılmıştır. Bu işlemde amaç, görüntünün tamamını kullanmak yerine yaprağı daha fazla kapsayan bir alan elde etmektir. Böylece modelin hastalık belirtisi olabilecek leke, sararma, renk değişimi, kuruma ve doku bozulması gibi yaprak üzerindeki görsel ipuçlarına daha fazla odaklanması hedeflenmiştir.

Yaprak odaklı ön işleme işlemi uygulanırken veri setindeki sınıf dağılımının bozulmamasına dikkat edilmiştir. Yani ön işleme sonrasında sınıflardaki görüntü sayılarının korunması amaçlanmıştır. Bu sayede model eğitimi sırasında kullanılan sınıflar arasında beklenmeyen veri kaybı oluşmasının önüne geçilmiştir. Ön işleme sonucunda elde edilen yeni veri seti, domates hastalık sınıflandırma modeli üzerinde ayrıca değerlendirilmiştir.

Bu aşamada yapılan denemeler, yalnızca görüntüyü modele vermenin bazı durumlarda yeterli olmadığını göstermiştir. Özellikle yaprağın görüntüde küçük kaldığı, arka planın karmaşık olduğu veya görüntünün ekran görüntüsü olarak alındığı durumlarda modelin tür ve hastalık tahmininde zorlanabildiği gözlemlenmiştir. Buna karşılık yaprağı daha net, yakın ve görüntünün büyük bölümünü kaplayacak şekilde içeren görsellerde modelin daha tutarlı sonuçlar verdiği görülmüştür. Bu nedenle sistemin gerçek kullanımında kullanıcıdan net, yakın çekim ve yaprağı mümkün olduğunca kapsayan görüntüler alınması gerektiği değerlendirilmiştir.

Model kararlarının daha anlaşılır hale getirilmesi için Grad-CAM++ yöntemi kullanılmıştır. Grad-CAM++, derin öğrenme modelinin belirli bir sınıf için görüntünün hangi bölgelerine daha fazla odaklandığını ısı haritası şeklinde göstermektedir. Bu yöntem sayesinde modelin yalnızca hangi sınıfı tahmin ettiği değil, bu tahmini yaparken hangi görüntü bölgelerini daha önemli gördüğü de incelenebilmektedir.

Bu çalışmada Grad-CAM++ analizi özellikle hastalık sınıflandırma modelleri üzerinde uygulanmıştır. Model bir yaprak görüntüsü için hastalık tahmini yaptıktan sonra, tahmin edilen sınıfa karşılık gelen Grad-CAM++ ısı haritası üretilmiştir. Daha sonra bu ısı haritası orijinal görüntü üzerine bindirilerek modelin odaklandığı bölgeler görsel olarak değerlendirilmiştir. Böylece modelin hastalık belirtisi taşıyan yaprak bölgelerine mi, yoksa arka plan gibi ilgisiz alanlara mı odaklandığı kontrol edilmiştir.

Grad-CAM++ çıktıları bu çalışmada bir segmentasyon sonucu olarak değerlendirilmemiştir. Çünkü Grad-CAM++ doğrudan hastalıklı bölgeyi piksel düzeyinde ayıran bir segmentasyon yöntemi değildir. Bunun yerine modelin karar verme sürecini açıklamaya yardımcı olan açıklanabilir yapay zeka yöntemidir. Bu nedenle elde edilen ısı haritaları, modelin kararını destekleyen görsel açıklamalar olarak kullanılmıştır.

Yapılan analizlerde bazı görüntülerde Grad-CAM++ ısı haritasının yaprak üzerindeki lekeli veya renk değişimi olan bölgelere odaklandığı görülmüştür. Bu durum modelin hastalık belirtisi taşıyan bölgeleri dikkate alabildiğini göstermesi açısından olumlu değerlendirilmiştir. Ancak bazı gerçek ortam görüntülerinde modelin yaprak dışındaki bölgelere de odaklanabildiği gözlemlenmiştir. Bu durum, gerçek dünya görüntülerinde arka plan ve görüntü kalitesinin model kararları üzerindeki etkisini göstermektedir.

Bu nedenle Grad-CAM++ çıktıları yalnızca başarılı örnekleri göstermek için değil, modelin sınırlılıklarını incelemek için de kullanılmıştır. Modelin yanlış veya düşük güvenli tahmin yaptığı durumlarda ısı haritası incelenerek modelin hangi bölgelere odaklandığı kontrol edilmiştir. Böylece sistemin hangi görüntü koşullarında daha güvenilir çalıştığı ve hangi durumlarda kullanıcıdan daha uygun bir görüntü istemesi gerektiği daha iyi anlaşılmıştır.

Yaprak odaklı ön işleme ve Grad-CAM++ analizi, çalışmanın açıklanabilirlik ve gerçek kullanım açısından önemli adımlarından biridir. Ön işleme ile modelin yaprak bölgesine daha fazla odaklanması hedeflenirken, Grad-CAM++ ile model kararlarının görsel olarak yorumlanması sağlanmıştır. Bu iki yaklaşım birlikte kullanılarak sistemin yalnızca tahmin sonucu veren bir yapı olmaktan çıkarılıp, karar süreci daha anlaşılır bir yapıya dönüştürülmesi amaçlanmıştır.

2.8. Mobil Uygulama Entegrasyonu

Bu çalışmada geliştirilen hiyerarşik karar destek sisteminin yalnızca bilgisayar ortamında çalışan bir model olarak kalmaması, kullanıcı tarafından mobil cihaz üzerinden de kullanılabilmesi amaçlanmıştır. Bu nedenle geliştirilen bitki türü tespit modeli, domates özel hastalık sınıflandırma modeli ve genel hastalık sınıflandırma modeli Android tabanlı bir mobil uygulama yapısına entegre edilmiştir. Mobil uygulama ile kullanıcının yaprak görüntüsünü doğrudan cihaz kamerası ile alması veya galeriden seçmesi, ardından bitki türü ve hastalık tahmini sonucunu görüntülemesi sağlanmıştır.

Mobil uygulama entegrasyonunda temel amaç, geliştirilen derin öğrenme tabanlı karar destek sistemini son kullanıcı açısından daha pratik ve erişilebilir hale getirmektir. Colab veya masaüstü ortamında çalışan modeller deneysel değerlendirme için yeterli olsa da gerçek kullanım senaryosunda kullanıcının yaprak görüntüsünü kolayca sisteme verebilmesi gerekmektedir. Bu nedenle Android uygulama, model çıktılarının kullanıcıya anlaşılır bir arayüz üzerinden sunulmasını sağlayan uygulama katmanı olarak tasarlanmıştır.

Sistemin mobil çalışma mantığında kullanıcı öncelikle yaprak görüntüsünü uygulamaya yüklemektedir. Görüntü kamera aracılığıyla alınabildiği gibi galeriden de seçilebilmektedir. Uygulamaya verilen görüntü ön işleme adımlarından geçirildikten sonra model giriş boyutuna uygun hale getirilmektedir. Bu kapsamda görüntü yeniden boyutlandırılmakta, gerekli normalizasyon işlemleri uygulanmakta ve modelin beklediği giriş formatına dönüştürülmektedir. Çalışmada CLAHE ön işleme yöntemi kullanıldığı için mobil uygulama tarafında da görüntülerin modele verilmeden önce aynı ön işleme mantığına uygun şekilde hazırlanması hedeflenmiştir. Böylece eğitim ve mobil tahmin aşamalarında kullanılan görüntü yapısı arasında tutarlılık sağlanmıştır.

Mobil uygulamada sistemin temel kullanım modu otomatik tahmin yapısına dayanmaktadır. Bu yapıda kullanıcıdan alınan yaprak görüntüsü ilk olarak bitki türü tespit modeline verilmektedir. Tür tespit modeli görüntünün domates, patates, biber, mısır, salatalık, patlıcan veya çilek türlerinden hangisine ait olduğunu tahmin etmektedir. Daha sonra sistem, tahmin edilen türe göre uygun hastalık sınıflandırma modelini çalıştırmaktadır. Eğer görüntü domates olarak tahmin edilirse domates için özel olarak geliştirilen hastalık sınıflandırma modeli kullanılmaktadır. Domates dışındaki türlerde ise genel hastalık sınıflandırma modeli devreye alınmaktadır. Böylece sistem, önce tür tespiti yapan, ardından uygun hastalık modelini çalıştıran hiyerarşik bir karar destek yapısı ile çalışmaktadır.

Uygulamada ayrıca kullanıcı deneyimini artırmak amacıyla yönlendirmeli kullanım yapısı da düşünülmüştür. Kullanıcıya görüntünün çalışmada desteklenen bitki türlerinden birine ait olup olmadığı sorulmakta ve bu doğrultuda tahmin süreci başlatılmaktadır. Kullanıcı bitki türünü bilmiyorsa sistem otomatik tür tahmini yapmaktadır. Kullanıcı bitki türünü biliyorsa, sistem bu bilgiyi destekleyici bir giriş olarak kullanabilmektedir. Ancak çalışmanın temel amacı tür tespiti ve ardından hastalık sınıflandırması yapmak olduğu için uygulamanın ana çalışma yapısı otomatik tür tahminine dayanmaktadır. Kullanıcıdan alınan tür bilgisi yalnızca daha kontrollü kullanım senaryoları için yardımcı bir seçenek olarak değerlendirilmiştir.


Mobil uygulamada tahmin sonucunda kullanıcıya bitki türü, hastalık sınıfı, güven skoru ve hastalık durumuna bağlı öneri metni sunulmaktadır. Hastalık sınıfları Healthy, Fungal_Disease, Bacterial_Disease ve Viral_Disease olmak üzere dört temel grupta değerlendirilmiştir. Eğer model yaprak görüntüsünü sağlıklı olarak sınıflandırırsa kullanıcıya düzenli bakım, sulama ve gözlem önerileri sunulmaktadır. Mantar, bakteriyel veya viral hastalık belirtisi tespit edildiğinde ise kullanıcıya hastalık türüne uygun genel bilgilendirme ve uzman görüşüne başvurulması gerektiğini belirten öneriler gösterilmektedir. Bu öneriler kesin tedavi amacı taşımamakta, kullanıcıyı bilgilendirmeye yönelik karar destek çıktıları olarak sunulmaktadır.

Gerçek ortam görüntülerinde ışık, arka plan, kamera açısı, yaprağın görüntüde kapladığı alan ve görüntü kalitesi gibi etkenler model sonucunu etkileyebilmektedir. Bu nedenle mobil uygulamada güven skoru önemli bir kontrol mekanizması olarak kullanılmıştır. Tahmin güven skoru belirlenen eşik değerin altında kaldığında kullanıcıya sonucun kesin kabul edilmemesi gerektiği belirtilmektedir. Bu durumda daha net, yakın çekim, yaprağı merkeze alan ve arka planı mümkün olduğunca sade olan yeni bir görüntü ile tekrar test yapılması önerilmektedir. Bu yapı, uygulamanın kullanıcıyı yanlış yönlendirme riskini azaltmak amacıyla eklenmiştir.

Android entegrasyonunda geliştirilen modellerin mobil cihazlarda çalışabilecek şekilde hazırlanması gerekmektedir. Bu kapsamda modeller TensorFlow Lite formatına dönüştürülerek mobil ortamda daha verimli çalışabilecek hale getirilmiştir. TensorFlow Lite kullanımı, modelin Android cihaz üzerinde daha hızlı çalışmasını ve daha düşük kaynak tüketimiyle tahmin üretebilmesini sağlamaktadır. Model boyutunun azaltılması ve işlem süresinin iyileştirilmesi amacıyla gerekli optimizasyon adımları da değerlendirilmiştir. Böylece karar destek sisteminin yalnızca deneysel ortamda değil, mobil cihaz üzerinde de uygulanabilir olması sağlanmıştır.

Mobil uygulama arayüzünde sade ve anlaşılır bir yapı tercih edilmiştir. Kullanıcı uygulama üzerinden görüntü seçme veya kamera ile görüntü alma işlemini gerçekleştirmekte, ardından tahmin sürecini başlatmaktadır. Tahmin tamamlandıktan sonra sonuç ekranında bitki türü, hastalık sınıfı, güven skoru ve öneri metni gösterilmektedir. Bu sayede kullanıcı, model çıktısını yalnızca sınıf adı olarak değil, güven düzeyi ve açıklayıcı öneri ile birlikte değerlendirebilmektedir.

Mobil uygulamada kullanıcının sistemle etkileşimini gösteren UML kullanım senaryosu diyagramı Şekil 2.2’de verilmiştir.



Şekil 2.4. Mobil uygulama kullanım senaryosuna ait UML diyagramı

Sonuç olarak mobil uygulama entegrasyonu ile geliştirilen hiyerarşik karar destek sistemi, kullanıcıdan alınan yaprak görüntüsünü işleyebilen, bitki türünü tahmin eden, uygun hastalık sınıflandırma modelini çalıştıran ve sonucu öneri metniyle birlikte sunan bir yapıya dönüştürülmüştür. Bu entegrasyon, çalışmanın yalnızca model geliştirme aşamasında kalmamasını, aynı zamanda gerçek kullanım senaryosuna daha yakın bir karar destek sistemi haline gelmesini sağlamıştır.

3. SONUÇLAR

Bu bölümde, geliştirilen hiyerarşik karar destek sisteminden elde edilen sonuçlar açıklanmıştır. Çalışma kapsamında bitki türü tespiti, domates hastalık sınıflandırması, genel hastalık sınıflandırması, Grad-CAM++ açıklanabilir yapay zeka çıktıları ve gerçek ortam görüntüleriyle yapılan denemeler değerlendirilmiştir. Elde edilen sonuçlar, geliştirilen sistemin kontrollü veri setlerinde başarılı çalıştığını, ancak gerçek ortam görüntülerinde görüntü kalitesi ve çekim koşullarının model başarımı üzerinde önemli etkisi olduğunu göstermiştir.

İlk aşamada tüm tür ve hastalık kombinasyonlarını birlikte ele alan birleşik sınıflandırma yaklaşımı denenmiştir. Bu yaklaşımda model, aynı anda hem bitki türünü hem de hastalık durumunu tahmin etmeye çalışmıştır. Ancak sınıf sayısının fazla olması, bazı sınıflarda veri sayısının düşük kalması ve sınıflar arasında belirgin dengesizlik bulunması nedeniyle modelin bazı sınıflarda kararsız tahminler yaptığı görülmüştür. Özellikle az örnek içeren sınıflarda recall değerlerinin düşük olması, sistemin tek aşamalı sınıflandırma yaklaşımıyla yeterince güvenilir olmayabileceğini göstermiştir.

Bu nedenle çalışma hiyerarşik bir yapıya dönüştürülmüştür. Hiyerarşik sistemde önce bitki türü tespit edilmiş, ardından tahmin edilen türe göre uygun hastalık sınıflandırma modeli çalıştırılmıştır. Bu yapı sayesinde tür tespiti ve hastalık tespiti birbirinden ayrılmış, karar süreci daha kontrollü hale getirilmiştir. Ayrıca domates türü için özel hastalık modeli geliştirilmiş, domates dışındaki türler için ise genel hastalık sınıflandırma modeli kullanılmıştır.

Bitki türü tespit modeli, domates, patates, biber, mısır, salatalık, patlıcan ve çilek olmak üzere yedi sınıf üzerinde eğitilmiştir. Model, kontrollü test verileri üzerinde yüksek doğruluk değerine ulaşmıştır. Bu sonuç, yaprak görüntülerinden bitki türü tahmininin genel olarak başarılı şekilde yapılabildiğini göstermiştir. Ancak gerçek ortam görüntüleriyle yapılan denemelerde modelin başarısının görüntü kalitesine duyarlı olduğu görülmüştür. Yaprığın görüntüde küçük kaldığı, arka planın karmaşık olduğu veya görüntünün ekran görüntüsü olarak alındığı durumlarda tür tahmininde hatalar oluşabilmektedir.

Domates hastalık sınıflandırma modeli, domates yapraklarını *Healthy*, *Fungal_Disease*, *Bacterial_Disease* ve *Viral_Disease* sınıflarına ayırmak amacıyla geliştirilmiştir. Domates veri setinin diğer türlere göre daha kapsamlı ve dengeli olması nedeniyle bu modelden daha başarılı sonuçlar elde edilmiştir. Kontrollü test verileri üzerinde domates özel hastalık modelinin yüksek doğruluk oranına ulaştığı görülmüştür. Bu durum, hastalık sınıflandırmasının tür-özel olarak yapılmasının bazı durumlarda daha güçlü sonuç verdiğini göstermektedir.

Genel hastalık sınıflandırma modeli ise domates dışındaki türlerde genel bir hastalık ön değerlendirmesi yapabilmek amacıyla geliştirilmiştir. Bu model de *Healthy*, *Fungal_Disease*, *Bacterial_Disease* ve *Viral_Disease* sınıfları üzerinden çalışmaktadır. Genel hastalık modeli, farklı bitki türlerine ait görüntülerle eğitildiği için tür-özel bir kesin tanı yerine genel semptom tahmini sunmaktadır. Elde edilen sonuçlar, bu modelin sistemin kapsamını genişletmek açısından gerekli olduğunu göstermiştir. Böylece sistem yalnızca domates yapraklarıyla sınırlı kalmamış, diğer türlerde de temel hastalık grupları üzerinden tahmin yapılabilir hale gelmiştir.

Çalışmada kullanılan EfficientNetB3 ve CBAM tabanlı mimari, yaprak görüntülerinden ayırt edici özelliklerin çıkarılmasında etkili olmuştur. EfficientNetB3 modeli temel özellik çıkarıcı olarak kullanılırken, CBAM dikkat mekanizması modelin görüntüdeki önemli bölgelere daha fazla odaklanmasına katkı sağlamıştır. Özellikle hastalık belirtilerinin yaprağın belirli bölgelerinde ortaya çıktığı düşünüldüğünde, dikkat mekanizmasının modele eklenmesi çalışmanın önemli mimari katkılarından biri olmuştur.

Model sonuçlarını daha anlaşılır hale getirmek amacıyla Grad-CAM++ yöntemi kullanılmıştır. Grad-CAM++ çıktıları, modelin hastalık tahmini yaparken görüntünün hangi bölgelerine odaklandığını göstermiştir. Bazı örneklerde ısı haritasının yaprak üzerindeki lekeli, sararmış veya renk değişimi olan bölgelere yoğunlaştığı görülmüştür. Bu durum, modelin karar verirken hastalık belirtisi taşıyan alanları dikkate alabildiğini göstermesi açısından olumlu değerlendirilmiştir.

Bununla birlikte, Grad-CAM++ analizleri modelin bazı sınırlılıklarını da ortaya koymuştur. Özellikle gerçek ortam görüntülerinde arka planın karmaşık olduğu, yaprağın yeterince net olmadığı veya görüntünün yaprağı tam kapsamadığı durumlarda modelin ilgisiz alanlara odaklanabildiği görülmüştür. Bu nedenle Grad-CAM++ çıktıları yalnızca başarılı örnekleri göstermek için değil, modelin hangi durumlarda zorlandığını anlamak için de kullanılmıştır.

Gerçek ortam görüntüleriyle yapılan denemelerde, sistemin kontrollü veri setlerine göre daha fazla zorlandığı görülmüştür. İnternette alınan veya farklı çekim koşullarına sahip görüntülerde ışık, arka plan, çözünürlük, yaprağın kadraj içindeki oranı ve görüntü netliği sonuçları doğrudan etkilemiştir. Yaprığı net, yakın ve büyük ölçüde kapsayan görüntülerde sistem daha tutarlı sonuçlar üretirken; ekran görüntüsü, uzaktan çekim veya arka planı karmaşık görsellerde hatalı tahminler oluşabilmektedir.

Bu gözlemler doğrultusunda karar destek sistemine güven skoru kontrolü eklenmiştir. Tür veya hastalık tahmininde güven skoru düşük olduğunda kullanıcıya sonucun kesin kabul edilmemesi gerektiği ve daha net bir görüntü ile tekrar test yapılmasının uygun olacağı belirtilmiştir. Bu yaklaşım, özellikle mobil uygulama kullanımında modelin kullanıcıyı yanlış yönlendirme riskini azaltmak amacıyla önemlidir.

Sonuç olarak geliştirilen sistem; bitki türü tespiti, hastalık sınıflandırması, güven skoru değerlendirmesi, kullanıcıya öneri sunma ve Grad-CAM++ ile görsel açıklama üretme adımlarını bir araya getiren hiyerarşik bir karar destek sistemi olarak çalışmaktadır. Kontrollü veri setlerinde elde edilen sonuçlar sistemin temel amacını karşıladığını göstermiştir. Gerçek ortam görüntülerinde karşılaşılan zorluklar ise sistemin mobil uygulama aşamasında görüntü alma koşullarının önemli olduğunu ortaya koymuştur.

Bu nedenle geliştirilen sistem, bitki hastalıklarının erken fark edilmesine yardımcı olabilecek bir ön değerlendirme aracı olarak değerlendirilebilir. Ancak sistem çıktıları kesin zirai tanı yerine karar destek amacıyla kullanılmalıdır. Hastalık tespiti yapılan durumlarda, özellikle ciddi belirtiler görüldüğünde kullanıcıların uzman görüşüne başvurması önemlidir.

3.1. Bitki Türü Tespit Modeli Sonuçları

Bu çalışmada hiyerarşik karar destek sisteminin ilk aşaması olarak yaprak görüntüsünden bitki türünün tespit edilmesi amaçlanmıştır. Bu kapsamda mısır, salatalık, patlıcan, biber, patates, çilek ve domates olmak üzere toplam yedi bitki türünü içeren bir sınıflandırma modeli geliştirilmiştir. Tür tespit modelinin amacı, sisteme verilen yaprak görüntüsünün hangi bitki türüne ait olduğunu belirlemek ve sonraki aşamada çalıştırılacak hastalık tahmin mekanizmasını seçmektir. Bu nedenle tür tespit modeli, önerilen hiyerarşik karar destek sisteminin ilk ve temel adımını oluşturmaktadır.

Modelin geliştirilmesinde EfficientNetB3 mimarisi temel alınmış ve bu mimariye CBAM dikkat mekanizması eklenmiştir. CBAM yapısı ile modelin görüntü içerisindeki daha ayırt edici yaprak bölgelerine odaklanması hedeflenmiştir. Eğitim süreci iki aşamalı olarak yürütülmüştür. İlk aşamada EfficientNetB3 taban modeli büyük ölçüde dondurularak eklenen sınıflandırıcı katmanların eğitilmesi sağlanmıştır. İkinci aşamada ise modelin son katmanları belirli ölçüde açılarak fine-tuning işlemi uygulanmıştır. Böylece önceden öğrenilmiş özelliklerden yararlanılırken, modelin çalışmada kullanılan bitki türlerine daha iyi uyum sağlaması amaçlanmıştır.

Danışman önerisi doğrultusunda son deneylerde görüntüler üzerinde CLAHE ön işleme yöntemi de uygulanmıştır. CLAHE yöntemi ile yaprak görüntülerindeki yerel kontrastın artırılması, damar yapısı, renk geçişleri ve yaprak yüzeyindeki ayırt edici bölgelerin daha belirgin hale getirilmesi amaçlanmıştır. Bu nedenle nihai tür tespit sonucu, CLAHE uygulanmış veri seti üzerinde eğitilen model üzerinden değerlendirilmiştir.

CLAHE uygulanmış tür tespit modeli, test veri kümesi üzerinde %93,89 doğruluk ve %97,93 Top-3 doğruluk değerine ulaşmıştır. Test loss değeri 0,2839 olarak elde edilmiştir. Bu sonuç, modelin kontrollü test veri setinde bitki türlerini genel olarak başarılı şekilde ayırt edebildiğini göstermektedir. Ancak sınıf bazlı sonuçlar incelendiğinde her bitki türü için başarımın aynı seviyede olmadığı görülmüştür. Bu nedenle model yalnızca genel doğruluk değeri ile değil, precision, recall ve F1-score değerleriyle birlikte değerlendirilmiştir.

BİTKİ TÜRÜ TESPİT MODELİ PERFORMANS SONUÇLARI				
Sınıf / Ölçüt	Precision	Recall	F1-Skoru	Support
corn	0,9983	0,9983	0,9983	582
cucumber	0,9042	0,9856	0,9431	833
eggplant	0,6402	1,0000	0,7807	315
pepper	0,9407	0,7923	0,8602	621
potato	0,9785	0,6667	0,7930	546
strawberry	0,9555	1,0000	0,9773	236
tomato	0,9872	0,9923	0,9897	2482
Accuracy	-	-	0,9389	5615
Macro Avg.	0,9149	0,9190	0,9061	5615
Weighted Avg.	0,9454	0,9389	0,9362	5615
GENEL TEST SONUÇLARI				
Test Loss			0,2839	
Test Accuracy			0,9389	
Test Top-3 Accuracy			0,9793	


Tablo 3.1. CLAHE uygulanmış bitki türü tespit modeline ait sınıf bazlı performans değerleri

Tablo 3.1 incelendiğinde modelin özellikle mısır, salatalık, çilek ve domates sınıflarında yüksek başarı gösterdiği görülmektedir. Mısır sınıfında precision, recall ve F1-score değerlerinin 0,9983 olması, bu sınıfa ait yaprak görüntülerinin model tarafından oldukça doğru ayrıştırıldığını göstermektedir. Domates sınıfında F1-score değerinin 0,9897 olması, sistemin domates yapraklarını yüksek güvenilirlikle ayırt edebildiğini göstermesi açısından önemlidir. Çünkü hiyerarşik karar destek sisteminde domates olarak tahmin edilen görüntüler, sonraki aşamada domates özel hastalık sınıflandırma modeline yönlendirilmektedir.

Patlıcan ve çilek sınıflarında recall değerinin 1,0000 olarak elde edilmesi, test veri kümesindeki bu sınıflara ait örneklerin tamamının doğru yakalandığını göstermektedir. Ancak patlıcan sınıfında precision değerinin 0,6402 olması, başka sınıflara ait bazı görüntülerin patlıcan olarak tahmin edilebildiğini göstermektedir. Bu durum, recall değerinin tek başına yeterli olmadığını ve model başarısının precision ve F1-score değerleriyle birlikte değerlendirilmesi gerektiğini ortaya koymaktadır.


Buna karşılık patates sınıfında recall değerinin 0,6667 düzeyinde kalması, bu sınıfa ait bazı örneklerin farklı türlerle karışabildiğini göstermektedir. Benzer şekilde biber sınıfında da recall değerinin diğer bazı sınıflara göre daha düşük olduğu görülmektedir. Bu karışmaların temel nedeni, bazı bitki türlerinin yaprak formu, renk tonu ve damar yapısı bakımından birbirine benzemesidir. Özellikle yalnızca yaprak görüntüsünün kullanıldığı durumlarda, bitkinin gövde, meyve veya genel form bilgisi bulunmadığı için tür ayrımı daha zor hale gelebilmektedir.

CLAHE uygulanmış tür tespit modeline ait confusion matrix ve normalize edilmiş confusion matrix sonuçları Şekil 3.1 ve Şekil 3.2’de verilmiştir.



Şekil 3.1. CLAHE uygulanmış bitki türü tespit modeline ait confusion matrix


Şekil 3.1 incelendiğinde doğru tahminlerin büyük ölçüde ana köşegen üzerinde toplandığı görülmektedir. Bu durum modelin genel olarak bitki türlerini doğru sınıflandırdığını göstermektedir. Özellikle mısır, domates ve salatalık sınıflarında doğru sınıflandırma sayılarının yüksek olduğu görülmektedir. Ancak patates sınıfına ait bazı örneklerin salatalık, patlıcan, biber veya domates gibi sınıflarla karışabildiği gözlemlenmiştir. Bu durum, patates yapraklarının bazı görüntülerde diğer türlerle benzer görsel özellikler taşımasından kaynaklanabilecek doğal bir sınıflandırma zorluğu olarak değerlendirilmiştir.



Şekil 3.2. CLAHE uygulanmış bitki türü tespit modeline ait normalize edilmiş confusion matrix

Normalize edilmiş confusion matrix, her sınıfın kendi içindeki doğru ve hatalı tahmin oranlarını daha açık göstermektedir. Bu görselde mısır, salatalık, patlıcan, çilek ve domates sınıflarında recall değerlerinin yüksek olduğu görülmektedir. Buna karşılık patates sınıfında doğru tahmin oranının daha düşük kalması, modelin bu sınıfta diğer türlere göre daha fazla zorlandığını desteklemektedir.

Modelin eğitim sürecine ait doğruluk ve kayıp grafikleri Şekil 3.3'te verilmiştir.



Şekil 3.3. CLAHE uygulanmış bitki türü tespit modelinin fine-tuning doğruluk ve kayıp grafikleri

Şekil 3.3 incelendiğinde eğitim doğruluğunun yüksek seviyelere ulaştığı, doğrulama doğruluğunun ise yaklaşık %93 düzeyinde seyrettiği görülmektedir. Eğitim kaybının oldukça düşük değerlere inmesine rağmen doğrulama kaybının aynı oranda azalmaması, modelin eğitim verisine güçlü biçimde uyum sağladığını göstermektedir. Bu durum belirli düzeyde overfitting eğilimi bulunduğunu düşündürmektedir. Ancak test veri kümesi üzerinde elde edilen %93,89 doğruluk değeri, modelin genel olarak başarılı bir sınıflandırma performansı sunduğunu göstermektedir.

Bu nedenle eğitim sürecinde veri artırma, dropout, sınıf ağırlıklandırma, erken durdurma ve CLAHE gibi yöntemler kullanılarak modelin genelleme başarısı artırılmaya çalışılmıştır. Elde edilen sonuçlar, CLAHE uygulanmış bitki türü tespit modelinin hiyerarşik karar destek sisteminin ilk aşamasında kullanılabilecek düzeyde başarılı olduğunu göstermektedir. Bununla birlikte patates ve biber sınıflarında görülen karışmalar, gerçek dünya kullanımında görüntü kalitesi, yaprağın görüntüde yeterince büyük yer kaplaması ve arka planın sade olması gibi koşulların model başarısı açısından önemli olduğunu ortaya koymaktadır.

3.2. Domates Hastalık Modeli Sonuçları

Domates hastalık modeli, önerilen hiyerarşik karar destek sisteminde tür tahmini domates olarak belirlendiğinde devreye giren tür özel hastalık sınıflandırma modelidir. Bu modelin amacı, domates yaprak görüntülerini hastalık durumuna göre sınıflandırmak ve sistemin ikinci aşamasında daha ayrıntılı bir karar üretmesini sağlamaktır. Çalışmada domates yaprakları için *Bacterial_Disease*, *Fungal_Disease*, *Healthy* ve *Viral_Disease* olmak üzere dört sınıf kullanılmıştır.

Domates için ayrı bir hastalık modelinin geliştirilmesinin temel nedeni, domates veri setinin diğer türlere göre daha fazla örnek içermesi ve hastalık sınıflarının daha düzenli bir yapıda temsil edilebilmesidir. Ayrıca domates hastalıklarında leke, sararma, yanıklık ve renk değişimi gibi belirtiler yaprak yüzeyinde daha belirgin gözlenebildiği için tür özel bir modelin genel hastalık modeline göre daha kontrollü sonuç üretmesi hedeflenmiştir. Bu nedenle domates sınıfı, hiyerarşik sistem içerisinde ayrı bir alt model olarak değerlendirilmiştir.

Modelin geliştirilmesinde EfficientNetB3 tabanlı yapı kullanılmış ve modele CBAM dikkat mekanizması eklenmiştir. Eğitim süreci iki aşamalı olarak yürütülmüştür. İlk aşamada modelin genel özellikleri öğrenmesi sağlanmış, ikinci aşamada ise belirli katmanlar yeniden eğitilerek fine-tuning işlemi uygulanmıştır. Nihai deneylerde görüntülerin kontrast bilgisini daha belirgin hale getirmek amacıyla CLAHE ön işleme yöntemi kullanılmıştır. Böylece özellikle yaprak yüzeyindeki renk değişimleri, lekeler ve damar çevresindeki belirti farklılıklarının model tarafından daha net algılanması amaçlanmıştır.

Model performansı accuracy, precision, recall ve f1-score metrikleri ile değerlendirilmiştir. Accuracy değeri modelin tüm test örnekleri içerisindeki genel doğru sınıflandırma oranını göstermektedir. Precision, modelin ilgili sınıfa ait olarak tahmin ettiği örneklerin ne kadarının gerçekten o sınıfa ait olduğunu; recall ise ilgili sınıfa ait gerçek örneklerin ne kadarının doğru yakalandığını ifade etmektedir. F1-score değeri ise precision ve recall değerlerini birlikte değerlendiren bir başarı ölçütüdür. CLAHE uygulanmış domates hastalık modeli test veri kümesi üzerinde %96,17 doğruluk değerine ulaşmıştır. Test loss değeri ise 0,1005 olarak elde edilmiştir. Modele ait sınıf bazlı sonuçlar Tablo 3.2’de verilmiştir.


DOMATES HASTALIK MODELİ PERFORMANS SONUÇLARI				
Sınıf / Ölçüt	Precision	Recall	F1-Skoru	Support
Bacterial_Disease	0,9204	0,9750	0,9469	320
Fungal_Disease	0,9785	0,9453	0,9616	1060
Healthy	0,8500	0,9917	0,9154	240
Viral_Disease	0,9952	0,9687	0,9818	862
Accuracy	-	-	0,9617	2482
Macro Avg.	0,9360	0,9702	0,9514	2482
Weighted Avg.	0,9679	0,9617	0,9628	2482
GENEL TEST SONUÇLARI				
Test Loss		0,1005		
Test Accuracy		0,9617		

Tablo 3.2. CLAHE uygulanmış domates hastalık modeline ait sınıf bazlı performans değerleri


Tablo 3.2 incelendiğinde modelin dört sınıfta da yüksek başarı elde ettiği görülmektedir. Bacterial_Disease sınıfında recall değerinin 0,9750 olması, bakteriyel hastalığa ait gerçek örneklerin büyük bölümünün doğru yakalandığını göstermektedir. Fungal_Disease sınıfında f1-score değerinin 0,9616 olması, bu sınıfta precision ve recall dengesinin yüksek olduğunu göstermektedir. Healthy sınıfında recall değerinin 0,9917’ye ulaşması, modelin sağlıklı domates yapraklarını büyük oranda doğru ayırt edebildiğini göstermektedir. Viral_Disease sınıfında ise precision değerinin 0,9952, f1-score değerinin 0,9818 olması, viral hastalık sınıfında oldukça güçlü bir sınıflandırma başarısı elde edildiğini göstermektedir.

Bununla birlikte Healthy sınıfında precision değerinin diğer sınıflara göre daha düşük kalması, bazı hastalıklı örneklerin model tarafından sağlıklı sınıfa yakın değerlendirilebildiğini göstermektedir. Özellikle hastalık belirtisinin çok hafif olduğu veya görüntü kalitesinin düşük olduğu durumlarda bu tür karışmaların ortaya çıkması mümkündür. Bu nedenle model çıktıları karar destek amacıyla değerlendirilmiş ve kesin tanı yerine ön değerlendirme niteliğinde yorumlanmıştır.

CLAHE uygulanmış domates hastalık modeline ait confusion matrix ve normalize edilmiş confusion matrix sonuçları Şekil 3.4 ve Şekil 3.5'te verilmiştir. Confusion matrix sonuçlarında doğru tahminlerin büyük ölçüde köşegen üzerinde toplandığı görülmektedir. Bacterial_Disease sınıfında 320 örneğin 312'si doğru sınıflandırılmıştır. Fungal_Disease sınıfında 1060 örneğin 1002'si doğru tahmin edilmiştir. Healthy sınıfında 240 örneğin 238'i doğru sınıflandırılırken, Viral_Disease sınıfında 862 örneğin 835'i doğru tahmin edilmiştir.




Şekil 3.4. CLAHE uygulanmış domates hastalık modeline ait confusion matrix



Şekil 3.5. CLAHE uygulanmış domates hastalık modeline ait normalize edilmiş confusion matrix

Normalize edilmiş confusion matrix incelendiğinde her sınıf için doğru sınıflandırma oranlarının yüksek olduğu görülmektedir. Bacterial_Disease sınıfında 0,97, Fungal_Disease sınıfında 0,95, Healthy sınıfında 0,99 ve Viral_Disease sınıfında 0,97 değerleri elde edilmiştir. Bu sonuçlar, domates özel hastalık modelinin sınıflar arasında genel olarak dengeli bir performans gösterdiğini ortaya koymaktadır. En belirgin karışma, Fungal_Disease sınıfındaki bazı örneklerin Healthy sınıfına yakın değerlendirilmesiyle oluşmuştur. Bu durum, mantar kaynaklı hastalık belirtilerinin bazı görüntülerde erken evrede veya düşük belirginlikte görünmesiyle açıklanabilir.

Modelin fine-tuning aşamasına ait doğruluk ve kayıp grafikleri Şekil 3.6’da birlikte verilmiştir. Doğruluk grafiğinde hem eğitim hem de doğrulama doğruluğunun epoch ilerledikçe arttığı görülmektedir. Kayıp grafiğinde ise eğitim ve doğrulama kayıplarının genel olarak azalma eğiliminde olduğu görülmektedir. Bu durum, modelin eğitim sürecinde öğrenmesini sürdürdüğünü ve CLAHE uygulanmış veri üzerinde kararlı bir performans elde ettiğini göstermektedir.



Şekil 3.6. CLAHE uygulanmış domates hastalık modelinin fine-tuning doğruluk ve kayıp grafikleri

Eğitim ve doğrulama eğrileri birlikte değerlendirildiğinde, modelde belirgin bir başarısız öğrenme durumu görülmemektedir. Doğrulama doğruluğunun yüksek seviyeye ulaşması ve test doğruluğunun %96,17 olarak elde edilmesi, modelin domates hastalık sınıflandırması için güçlü bir performans sergilediğini göstermektedir. Eğitim doğruluğu ile doğrulama doğruluğu arasındaki farkın sınırlı kalması, modelin yalnızca eğitim verisini ezberlemediğini ve test veri kümesi üzerinde de kullanılabilir bir genelleme başarısı sağladığını düşündürmektedir.

Sonuç olarak CLAHE uygulanmış domates hastalık modeli, hiyerarşik karar destek sisteminde domates türü tespit edildiğinde kullanılabilecek başarılı bir alt model olarak değerlendirilmiştir. Özellikle *Healthy* ve *Viral_Disease* sınıflarındaki yüksek recall ve f1-score değerleri, modelin domates yapraklarında sağlıklı ve hastalıklı örnekleri ayırt etmede etkili olduğunu göstermektedir. Bu nedenle nihai karar destek yapısında domates türü için genel hastalık modeli yerine domates özel hastalık modelinin kullanılması uygun görülmüştür.

3.3. Genel Hastalık Modeli Sonuçları

Bu çalışmada domates türü için ayrı bir tür-özel hastalık sınıflandırma modeli geliştirilmiştir. Ancak önerilen hiyerarşik karar destek sisteminin yalnızca domates türü ile sınırlı kalmaması için, domates dışındaki bitki türlerinde de temel hastalık durumuna yönelik tahmin üretebilen genel bir hastalık modeli oluşturulmuştur. Bu model, yaprak görüntüsünü bitki türünden bağımsız olarak *Bacterial_Disease*, *Fungal_Disease*, *Healthy* ve *Viral_Disease* sınıflarından birine atamaktadır. Böylece kullanıcı tarafından sisteme domates dışında bir bitki görüntüsü verildiğinde de sistem hastalık durumuna ilişkin genel bir sonuç üretebilmektedir.

Genel hastalık modeli; mısır, salatalık, patlıcan, biber, patates, çilek ve domates türlerine ait görüntülerden oluşturulan veri yapısı üzerinde eğitilmiştir. Bu yaklaşımın tercih edilmesinin nedeni, her bitki türü için ayrı ayrı ve dengeli hastalık veri seti bulunmamasıdır. Bu nedenle domates dışındaki türlerde hastalık tespiti, ayrıntılı hastalık isimleri yerine dört temel üst hastalık kategorisi üzerinden ele alınmıştır. Nihai hiyerarşik sistemde görüntü domates olarak tahmin edildiğinde domates özel hastalık modeli çalıştırılmakta, diğer türlerde ise genel hastalık modeli kullanılmaktadır.

Nihai deneylerde genel hastalık modeli için görüntüler üzerinde CLAHE ön işlemi uygulanmıştır. CLAHE, görüntüdeki yerel kontrastı artırarak yaprak yüzeyindeki leke, renk değişimi ve doku farklılıklarının daha belirgin hale gelmesine yardımcı olmaktadır. Bu nedenle özellikle farklı ışık koşullarında elde edilen görüntülerde hastalık belirtilerinin model tarafından daha iyi ayırt edilebilmesi amaçlanmıştır.

CLAHE uygulanmış genel hastalık modeli test veri kümesi üzerinde %92,41 doğruluk değerine ulaşmıştır. Test loss değeri 0,0470 olarak elde edilmiştir. Ayrıca makro ortalama F1-skoru 0,9298, ağırlıklı ortalama F1-skoru ise 0,9234 olarak hesaplanmıştır. Bu sonuçlar, modelin farklı bitki türlerinden gelen görüntüler üzerinde dört temel hastalık sınıfını genel olarak başarılı şekilde ayırt edebildiğini göstermektedir. Sınıf bazlı performans değerleri Tablo 3.3'te verilmiştir.


GENEL HASTALIK MODELİ PERFORMANS DEĞERLERİ				
Sınıf / Ölçüt	Precision	Recall	F1-Skoru	Support
Bacterial_Disease	0,9041	0,9829	0,9419	643
Fungal_Disease	0,9120	0,9468	0,9291	2648
Healthy	0,9212	0,8234	0,8695	1433
Viral_Disease	0,9808	0,9764	0,9786	891
Accuracy	-	-	0,9241	5615
Macro Avg.	0,9295	0,9324	0,9298	5615
Weighted Avg.	0,9249	0,9241	0,9234	5615
GENEL TEST SONUÇLARI				
Test Loss			0,0470	
Test Accuracy			0,9241	

Tablo 3.3. CLAHE uygulanmış genel hastalık modeline ait sınıf bazlı performans değerleri

Tablo 3.3 incelendiğinde, modelin özellikle Viral_Disease sınıfında yüksek başarı gösterdiği görülmektedir. Bu sınıfta precision, recall ve F1-skor değerleri sırasıyla 0,9808, 0,9764 ve 0,9786 olarak elde edilmiştir. Bacterial_Disease sınıfında recall değerinin 0,9829 olması, bakteriyel hastalık örneklerinin büyük bir bölümünün doğru şekilde tespit edildiğini göstermektedir. Fungal_Disease sınıfında da modelin dengeli bir performans sergilediği ve bu sınıf için F1-skorunun 0,9291 olduğu görülmektedir.

Healthy sınıfında recall değeri 0,8234 olarak elde edilmiş ve bu değer diğer sınıflara göre daha düşük kalmıştır. Bu durum, bazı sağlıklı yaprak görüntülerinin özellikle Fungal_Disease sınıfı ile karışabildiğini göstermektedir. Sağlıklı yapraklarda görülebilen gölge, doğal doku farklılıkları, renk değişimleri veya görüntü kalitesi gibi etkenler model tarafından hastalık belirtisi gibi algılanabilmektedir. Bu nedenle genel hastalık modelinde sağlıklı ve mantar hastalığı sınıfları arasındaki ayrımın daha dikkatli yorumlanması gerekmektedir.

CLAHE uygulanmış genel hastalık modeline ait confusion matrix ve normalize edilmiş confusion matrix sonuçları Şekil 3.7 ve Şekil 3.8'de verilmiştir. Confusion matrix sonuçları incelendiğinde, doğru tahminlerin büyük ölçüde köşegen üzerinde toplandığı görülmektedir. Bu durum modelin genel hastalık sınıflandırma görevinde başarılı bir karar yapısı oluşturduğunu göstermektedir. Bununla birlikte Healthy sınıfındaki bazı örneklerin Fungal_Disease olarak tahmin edilmesi, farklı bitki türlerinden gelen görüntü çeşitliliğinin sınıflandırma sürecini zorlaştırabildiğini ortaya koymaktadır.




Şekil 3.7. CLAHE uygulanmış genel hastalık modeline ait confusion matrix



Şekil 3.8. CLAHE uygulanmış genel hastalık modeline ait normalize edilmiş confusion matrix

Şekil 3.7 ve Şekil 3.8 birlikte değerlendirildiğinde, Viral_Disease, Bacterial_Disease ve Fungal_Disease sınıflarında doğru sınıflandırma oranlarının yüksek olduğu görülmektedir. Normalize edilmiş confusion matrix üzerinde Viral_Disease sınıfı 0,98, Bacterial_Disease sınıfı 0,98 ve Fungal_Disease sınıfı 0,95 düzeyinde doğru sınıflandırılmıştır. Healthy sınıfında ise doğru sınıflandırma oranı 0,82 düzeyinde kalmıştır. Bu sonuç, genel modelde sağlıklı yaprak görüntülerinin bazı durumlarda mantar hastalığına benzeyen görsel özellikler taşıyabildiğini göstermektedir.

Eğitim sürecine ait doğruluk ve kayıp grafikleri Şekil 3.9’da birlikte verilmiştir. Doğruluk grafiği incelendiğinde eğitim doğruluğunun epochlar ilerledikçe düzenli olarak arttığı, doğrulama doğruluğunun ise daha sınırlı ancak kararlı bir artış gösterdiği görülmektedir. Kayıp grafiğinde eğitim kaybı belirgin biçimde azalırken doğrulama kaybının daha yatay bir seyir izlediği görülmektedir. Bu durum, modelin eğitim verisini güçlü şekilde öğrendiğini ancak farklı türlerden gelen görüntü çeşitliliği nedeniyle doğrulama verisi üzerinde belirli bir genelleme farkı bulunduğunu göstermektedir.



Şekil 3.9. CLAHE uygulanmış genel hastalık modelinin fine-tuning doğruluk ve kayıp grafikleri

Genel olarak değerlendirildiğinde, CLAHE uygulanmış genel hastalık modeli domates dışındaki bitki türlerinde temel hastalık durumunun belirlenebilmesi için kullanılabilecek bir yapı sunmaktadır. Modelin test doğruluğunun %92,41 olması ve özellikle bakteriyel, mantar ve viral hastalık sınıflarında yüksek F1-skorları elde edilmesi, genel modelin karar destek sistemi için uygun bir alt bileşen olduğunu göstermektedir.


Bununla birlikte farklı bitki türlerinin aynı hastalık üst sınıfları altında değerlendirilmesi, bazı sınıflar arasındaki görsel benzerlikleri artırmaktadır. Özellikle Healthy ve Fungal Disease sınıfları arasındaki karışmalar, gerçek kullanımda görüntü kalitesi, ışık koşulları ve yaprağın görüntüde kapladığı alanın önemli olduğunu ortaya koymaktadır. Bu nedenle nihai sistemde güven skoru düşük olan tahminlerde kullanıcının daha net ve yaprak odaklı bir görüntü ile yeniden test yapması gerektiği belirtilmiştir. Böylece genel hastalık modeli, tür-özel model bulunmayan durumlarda kullanıcıya temel hastalık tahmini ve öneri sunan tamamlayıcı bir bileşen olarak değerlendirilmiştir.

3.4. Gerçek Dünya Görüntüleri ile Karar Destek Sistemi Sonuçları

Bu çalışmada geliştirilen karar destek sisteminin yalnızca düzenlenmiş veri seti görüntüleri üzerinde değil, gerçek kullanım koşullarına daha yakın görüntüler üzerinde de nasıl davrandığını incelemek amacıyla ek denemeler yapılmıştır. Eğitim ve test aşamalarında kullanılan veri setlerinde yaprak görüntüleri çoğunlukla daha kontrollü, tek yaprağın belirgin olduğu ve arka planın daha sade olduğu görüntülerden oluşmaktadır. Ancak gerçek kullanım senaryosunda kullanıcılar mobil cihaz kamerası ile farklı ışık koşullarında, farklı açılardan, karmaşık arka planlar üzerinde veya yaprağın görüntüyü tam olarak kaplamadığı fotoğraflar çekebilmektedir. Bu nedenle sistemin gerçek dünya görüntülerindeki davranışını ayrıca gözlemlemek gerekli görülmüştür.

Bu amaçla Google üzerinden elde edilen gerçek dünya yaprak görüntülerinden oluşan ek bir görüntü kümesi hazırlanmıştır. Bu veri kümesinde mısır, salatalık, patlıcan, biber, patates, çilek ve domates olmak üzere sistemde yer alan yedi bitki türünün her biri için 50 görüntü toplanmış ve toplam 350 görüntü bir gerçek dünya görüntü kümesi oluşturulmuştur. Bu görüntüler ana eğitim veri seti olarak kullanılmamıştır. Bu görüntülerin temel amacı, daha önce geliştirilen bitki türü tespit modelinin gerçek kullanım koşullarına daha yakın görüntüler karşısında nasıl davrandığını görmek ve sistemin sınırlılıklarını belirlemektir. Bu nedenle bu bölümde verilen sonuçlar, ana model başarımının yerine geçen sonuçlar olarak değil, sistemin gerçek kullanım koşullarındaki davranışını anlamaya yönelik ek değerlendirme sonuçları olarak ele alınmıştır.


Gerçek dünya görüntüleri kullanılarak yapılan ek uyum denemesinde, modelin bu tür görüntüler karşısındaki öğrenme davranışını incelemek amacıyla doğruluk ve kayıp grafikleri de değerlendirilmiştir. Bu süreç, nihai karar destek sisteminin ana eğitim sürecinin yerine geçmemekte; yalnızca gerçek ortam görüntülerinin model performansı üzerindeki etkisini gözlemlemek amacıyla kullanılmaktadır.



Şekil 3.12. Gerçek dünya görüntüleriyle yapılan ek tür tespit denemesine ait confusion matrix


Şekil 3.12’de gerçek dünya görüntüleri üzerinde yapılan tür tespit denemesine ait confusion matrix verilmiştir. Confusion matrix incelendiğinde, modelin bazı sınıflarda doğru tahminler ürettiği, bazı sınıflarda ise sınıflar arasında karışmalar yaşadığı görülmektedir. Özellikle mısır sınıfında daha kararlı sonuçlar elde edilirken, patates, salatalık ve çilek gibi bazı sınıflarda tahmin kaymaları oluşmuştur. Bu durum, gerçek dünya görüntülerinde yaprakların şekil, renk, damar yapısı ve arka plan koşulları açısından eğitim veri setindeki örneklerden farklılık gösterebildiğini göstermektedir.

Gerçek dünya görüntüleri kullanılarak yapılan ek uyum denemesinde modelin öğrenme davranışını incelemek amacıyla doğruluk ve kayıp grafikleri de değerlendirilmiştir. Bu grafikler, gerçek dünya görüntülerinin model için daha zorlayıcı olduğunu ve modelin bu görüntülerden belirli ölçüde öğrenme gerçekleştirebildiğini göstermektedir. Ancak bu çalışma, ana eğitim sürecinin yerine geçen bir eğitim aşaması olarak değil, gerçek kullanım koşullarını analiz etmeye yönelik ek bir değerlendirme olarak ele alınmıştır.



Şekil 3.13. Gerçek dünya görüntüleriyle yapılan ek uyum denemesine ait doğruluk grafiği

Şekil 3.13'te verilen doğruluk grafiği incelendiğinde, eğitim ve doğrulama doğruluk değerlerinde genel olarak artış eğilimi olduğu görülmektedir. Bununla birlikte doğrulama doğruluğunun kontrollü veri setindeki sonuçlara göre daha düşük seviyede kalması, gerçek dünya görüntülerinin model açısından daha zorlayıcı olduğunu göstermektedir. Bu sonuç, mobil uygulama kullanımında görüntü kalitesinin model başarımı üzerinde doğrudan etkili olduğunu ortaya koymaktadır.



Şekil 3.14. Gerçek dünya görüntüleriyle yapılan ek uyum denemesine ait kayıp grafiği

Şekil 3.14'te verilen kayıp grafiği incelendiğinde, eğitim ve doğrulama kayıp değerlerinde genel olarak azalma eğilimi olduğu görülmektedir. Bu durum modelin gerçek dünya görüntülerinden belirli ölçüde öğrenme gerçekleştirdiğini göstermektedir. Ancak doğruluk değerlerinin kontrollü veri setindeki sonuçlara göre daha düşük kalması, gerçek dünya görüntülerinin sisteme eklenmesinin ve ilerleyen çalışmalarda daha geniş saha görüntüleriyle modelin desteklenmesinin önemli olduğunu göstermiştir.

Karar destek sisteminin ilk aşamasında, düzenlenen tür veri seti üzerinde geliştirilen bitki türü tespit modeli kullanılmaktadır. Nihai sistemde kullanıcıdan alınan yaprak görüntüsü önce bu modele verilmekte ve görüntünün mısır, salatalık, patlıcan, biber, patates, çilek veya domates sınıflarından hangisine ait olduğu tahmin edilmektedir. Tür tahmini domates olarak elde edildiğinde, domates için özel olarak geliştirilen hastalık sınıflandırma modeli çalıştırılmaktadır. Domates dışındaki türlerde ise türden bağımsız olarak geliştirilen genel hastalık sınıflandırma modeli devreye alınmaktadır. Böylece sistem, bitki türü tespiti, hastalık sınıflandırması ve kullanıcıya öneri sunma aşamalarını bir araya getiren hiyerarşik bir karar destek yapısı olarak çalışmaktadır.

Gerçek dünya görüntüleriyle yapılan denemeler, bu karar destek sistemine güven skoru kontrolü eklenmesi gerektiğini göstermiştir. Çünkü gerçek kullanım koşullarında model bazı görüntülerde düşük güven skoru ile tahmin yapabilmekte veya türler arasında kararsız kalabilmektedir. Bu nedenle nihai sistemde tür tahmini için güven skoru ve ilk iki tahmin arasındaki fark dikkate alınmıştır. Tahmin güveni düşük olduğunda sistem sonucu kesin kabul etmemekte ve kullanıcıya daha net, tek yaprağı kapsayan ve uygun ışıktaki çekilmiş bir görüntü ile tekrar deneme yapılması gerektiğini bildirmektedir.


Nihai karar destek akışı, kullanıcıdan tekil görüntü alabilen arayüz üzerinde de test edilmiştir. Bu aşamada kullanılan arayüz eğitim amacıyla değil, daha önce eğitilen modellerin kullanıcıdan alınan görüntü üzerinde birlikte çalışmasını göstermek amacıyla kullanılmıştır. Kullanıcı görüntüyü yüklediğinde sistem önce tür tahmini yapmakta, ardından uygun hastalık modelini seçmekte, hastalık durumunu belirlemekte, güven skorlarını göstermekte ve hastalık sonucuna göre öneri üretmektedir. Ayrıca Grad-CAM++ yöntemi ile modelin görüntünün hangi bölgelerine odaklandığı görsel olarak sunulmaktadır.

Genel olarak değerlendirildiğinde, gerçek dünya görüntüleri ile yapılan denemeler sistemin pratik kullanım açısından önemli sınırlılıklarını ortaya koymuştur. Kontrollü veri setlerinde yüksek doğruluk değerleri elde edilmesine rağmen, gerçek ortam görüntülerinde ışık, arka plan, görüntü açısı ve yaprağın kadraj içindeki oranı model başarımını doğrudan etkilemektedir. Bu nedenle geliştirilen sistemde yalnızca tahmin sonucu verilmemiş, tahminin güvenilirliği de dikkate alınmıştır. Böylece sistem, kullanıcıya doğrudan kesin bir tanı sunmak yerine, güven skoru ve öneri mekanizmasıyla desteklenen daha kontrollü bir karar destek yapısı olarak tasarlanmıştır.

3.5. Grad-CAM++ Görselleştirme Sonuçları

Bu çalışmada geliştirilen sınıflandırma modellerinin yalnızca tahmin sonucu üretmesi yeterli görülmemiş, model kararlarının görsel olarak yorumlanabilmesi için Grad-CAM++ yöntemi kullanılmıştır. Grad-CAM++, derin öğrenme modelinin bir görüntüyü belirli bir sınıfa ait olarak tahmin ederken hangi bölgelere daha fazla odaklandığını ısı haritası şeklinde göstermektedir. Bu sayede modelin kararının yalnızca sayısal bir çıktı olarak değil, görüntü üzerinde açıklanabilir bir biçimde değerlendirilmesi amaçlanmıştır. Grad-CAM++ çıktıları piksel düzeyinde kesin bir segmentasyon sonucu olarak değil, model kararını açıklamaya yardımcı bir görselleştirme yöntemi olarak değerlendirilmiştir.


Bu çalışmada Grad-CAM++ yöntemi özellikle hastalık sınıflandırma aşamasında kullanılmıştır. Çünkü hastalık sınıflandırmasında modelin yaprağın hangi bölgelerini dikkate aldığı, sistemin güvenilirliğini yorumlamak açısından önemlidir. Modelin hastalık belirtisi bulunan yaprak bölgelerine odaklanması beklenmektedir. Ancak bu çıktılar kesin hastalık bölgesi tespiti olarak değil, modelin sınıflandırma kararını yorumlamaya yardımcı açıklanabilir yapay zeka çıktısı olarak değerlendirilmiştir.



Şekil 3.15. Domates hastalık modeli için Grad-CAM++ görselleştirme örneği

Şekil 3.15'te domates hastalık sınıflandırma modeline ait örnek bir Grad-CAM++ çıktısı verilmiştir. Görselde modelin hastalık tahmini yaparken yaprak üzerindeki belirli bölgelere daha fazla odaklandığı görülmektedir. Isı haritasında sıcak renklerle gösterilen alanlar, modelin karar sürecinde daha etkili olan bölgeleri ifade etmektedir. Bu durum, modelin karar verirken yaprak yüzeyi üzerindeki ayırt edici bölgelere ne ölçüde odaklandığını değerlendirmeye yardımcı olmaktadır.


Grad-CAM++ çıktıları incelendiğinde bazı örneklerde modelin yaprak üzerindeki lekelenme, renk değişimi veya doku bozukluğu gibi hastalık belirtisi olabilecek bölgelere yoğunlaştığı görülmüştür. Bu tür örnekler model kararının görsel olarak daha anlamlı olduğunu göstermektedir. Özellikle mantar veya viral hastalık belirtileri bulunan görüntülerde, modelin yaprak yüzeyindeki belirgin renk ve doku farklılıklarına odaklanması beklenen bir sonuçtur.



Şekil 3.16. Hastalık belirtisi içeren yaprak görüntüsünde Grad-CAM++ odak bölgeleri

Şekil 3.16'da hastalık belirtisi içeren bir yaprak görüntüsüne ait Grad-CAM++ sonucu verilmiştir. Görsel incelendiğinde modelin karar verirken yaprak üzerindeki semptom bölgelerine yakın alanlara daha fazla ağırlık verdiği görülmektedir. Bu durum, modelin hastalık sınıflandırma kararını görüntüdeki belirli görsel ipuçlarına dayandığını göstermesi açısından önemlidir. Böylece Grad-CAM++ çıktıları, sınıflandırma sonucunun görsel olarak desteklenmesine katkı sağlamıştır.

Bununla birlikte, bazı gerçek dünya görüntülerinde Grad-CAM++ çıktılarının her zaman beklenen şekilde hastalık belirtisi bulunan alanlara odaklanmadığı da görülmüştür. Özellikle görüntüde arka planın karmaşık olduğu, yaprağın kadrajı tam olarak kaplamadığı, ışık ve gölge etkilerinin fazla olduğu durumlarda ısı haritası yaprak dışındaki bölgelere veya yaprağın hastalıkla doğrudan ilişkili olmayan alanlarına kayabilmektedir. Bu nedenle Grad-CAM++ çıktıları tek başına kesin karar aracı olarak değil, model kararını yorumlamaya yardımcı destekleyici bir çıktı olarak değerlendirilmiştir.



Şekil 3.17. Gerçek dünya görüntüsü üzerinde karar destek sistemi ile üretilen Grad-CAM++ çıktısı

Şekil 3.17’de karar destek sistemi üzerinden yüklenen gerçek dünya görüntüsüne ait Grad-CAM++ çıktısı verilmiştir. Bu örnekte sistem önce bitki türünü tahmin etmiş, ardından uygun hastalık sınıflandırma modelini çalıştırmış ve son olarak modelin kararına ilişkin Grad-CAM++ görselleştirmesini üretmiştir. Böylece nihai sistemde kullanıcı yalnızca sınıf tahmini ve güven skoru almamakta, aynı zamanda modelin görüntü üzerinde hangi bölgelere odaklandığını da görebilmektedir.

Grad-CAM++ sonuçları genel olarak değerlendirildiğinde, bu yöntemin geliştirilen karar destek sistemine açıklanabilirlik kazandırdığı görülmektedir. Modelin hangi görüntü bölgelerine odaklandığını görselleştirmek, özellikle tarım gibi kullanıcı kararının önemli olduğu alanlarda sistem çıktılarının daha anlaşılır hale gelmesine katkı sağlamaktadır. Ancak Grad-CAM++ çıktıları kesin hastalık bölgesi tespiti veya piksel düzeyinde segmentasyon sonucu olarak yorumlanmamalıdır. Bu çıktılar, hastalık sınıflandırma sonucu, güven skoru ve öneri metni ile birlikte değerlendirilmesi gereken destekleyici görsel açıklamalar olarak ele alınmıştır.

3.6. Genel Değerlendirme

Bu bölümde elde edilen sonuçlar genel olarak değerlendirildiğinde, geliştirilen sistemin yaprak görüntülerinden bitki türü tespiti ve hastalık sınıflandırma işlemlerini hiyerarşik bir yapı içerisinde gerçekleştirebildiği görülmektedir. Çalışmada öncelikle yaprak görüntüsünün hangi bitki türüne ait olduğunu belirleyen bir tür tespit modeli geliştirilmiştir. Ardından tahmin edilen türe göre uygun hastalık sınıflandırma modeli devreye alınmıştır. Bu yapı sayesinde sistem, tüm sınıfları tek bir model altında değerlendirmek yerine, problemi daha kontrollü ve aşamalı bir şekilde ele almıştır.

Nihai deneylerde görüntülerin kontrast bilgisini artırmak amacıyla CLAHE ön işlemi uygulanmıştır. CLAHE uygulanmış bitki türü tespit modeli test veri kümesi üzerinde %93,89 doğruluk değerine ulaşmıştır. Ayrıca modelin Top-3 doğruluk değerinin %97,93 olması, ilk tahminin hatalı olduğu bazı durumlarda doğru türün yüksek olasılıklı tahminler arasında yer alabildiğini göstermektedir. Bu sonuç, tür tespit modelinin hiyerarşik karar destek sisteminin ilk aşaması için kullanılabilir bir başarı düzeyine ulaştığını göstermektedir.

Hastalık sınıflandırma aşamasında iki farklı model kullanılmıştır. Domates türü için ayrı bir hastalık sınıflandırma modeli geliştirilmiştir. Bunun nedeni, domates veri setinin diğer türlere göre daha fazla örnek içermesi ve hastalık sınıflarının daha dengeli bir yapıya sahip olmasıdır. CLAHE uygulanmış domates hastalık modeli test veri kümesi üzerinde %96,17 doğruluk değerine ulaşmıştır. Bu sonuç, domates türü için ayrı bir hastalık modelinin kullanılmasının sistem başarısı açısından anlamlı olduğunu göstermektedir.

Domates dışındaki türlerde ise genel hastalık sınıflandırma modeli kullanılmıştır. Bu model, farklı bitki türlerinden elde edilen yaprak görüntülerini Bacterial_Disease, Fungal_Disease, Healthy ve Viral_Disease olmak üzere dört temel hastalık sınıfı altında değerlendirmiştir. CLAHE uygulanmış genel hastalık modeli test veri kümesi üzerinde %92,41 doğruluk değerine ulaşmıştır. Genel hastalık modelinin başarısı, sistemin yalnızca domates türüyle sınırlı kalmadığını ve diğer bitki türleri için de genel hastalık durumu hakkında karar destek sağlayabilecek bir yapıya sahip olduğunu göstermektedir.

Elde edilen sonuçlar birlikte değerlendirildiğinde, hiyerarşik yaklaşımın çalışma için uygun bir yapı sunduğu görülmektedir. İlk olarak bitki türünün belirlenmesi, ardından bu türe göre uygun hastalık modelinin çalıştırılması, sistemin karar verme sürecini daha anlaşılır hale getirmiştir. Domates için tür-özel hastalık modelinin, diğer türler için ise genel hastalık modelinin kullanılması; veri setinin mevcut dağılımına ve çalışmanın kapsamına uygun bir çözüm olmuştur. Bu yapı aynı zamanda ilerleyen çalışmalarda her bitki türü için ayrı hastalık modelleri eklenmesine de olanak sağlamaktadır.

Gerçek dünya görüntüleriyle yapılan ek denemeler, kontrollü veri setleri üzerinde elde edilen başarının gerçek kullanım koşullarında doğrudan aynı şekilde korunamayabileceğini göstermiştir. Işık koşulları, arka plan karmaşıklığı, kamera açısı, yaprağın görüntüde kapladığı alan ve görüntü kalitesi gibi faktörler model tahminlerini etkileyebilmektedir. Bu nedenle gerçek dünya görüntüleriyle yapılan denemeler, ana model eğitim sürecinin yerine geçen bir aşama olarak değil, sistemin pratik kullanım koşullarındaki davranışını gözlemlemek için yapılan ek bir değerlendirme olarak ele alınmıştır.

Bu gözlemler doğrultusunda karar destek sisteminde güven skoru önemli bir kontrol mekanizması olarak kullanılmıştır. Modelin güven skorunun düşük olduğu durumlarda sonucun kesin kabul edilmemesi ve daha net, yaprağı merkeze alan bir görüntü ile yeniden test yapılması gerektiği belirtilmiştir. Bu yaklaşım, sistemin kullanıcıyı yanlış yönlendirme riskini azaltmak ve tahmin sonuçlarının daha dikkatli yorumlanmasını sağlamak amacıyla tercih edilmiştir.

Grad-CAM++ görselleştirme sonuçları ise geliştirilen sistemin açıklanabilirlik yönünü desteklemiştir. Bu yöntem sayesinde modelin hastalık sınıflandırması yaparken görüntünün hangi bölgelerine daha fazla odaklandığı görsel olarak incelenebilmiştir. Ancak Grad-CAM++ çıktıları piksel düzeyinde kesin bir segmentasyon sonucu olarak değil, model kararını açıklamaya yardımcı bir görselleştirme yöntemi olarak değerlendirilmiştir. Bu yönüyle sistem, yalnızca sınıf tahmini yapan bir yapı olmaktan çıkarak kullanıcıya daha yorumlanabilir sonuçlar sunan bir karar destek sistemine dönüştürülmüştür.

Genel olarak değerlendirildiğinde, bu çalışmada geliştirilen yapı; bitki türü tespiti, hastalık sınıflandırması, güven skoru, öneri üretimi ve açıklanabilir yapay zeka bileşenlerini bir araya getiren bütünsel bir karar destek sistemi ortaya koymaktadır. Sistem, domates türü için daha ayrıntılı hastalık sınıflandırması yapabilmekte, diğer türlerde ise genel hastalık durumu hakkında kullanıcıya ön değerlendirme sunabilmektedir. Bununla birlikte gerçek dünya görüntülerinde elde edilen gözlemler, sistemin saha koşullarında daha güçlü hale getirilebilmesi için daha fazla gerçek ortam görüntüsüyle desteklenmesi gerektiğini göstermektedir.

Sonuç olarak geliştirilen hiyerarşik karar destek sistemi, tarımsal üretimde yaprak görüntülerinden bitki türü ve hastalık durumunun belirlenmesine yönelik kullanılabilir bir yapay zeka yaklaşımı sunmaktadır. Sistem doğrudan kesin tanı koymak amacıyla değil; kullanıcıya ön değerlendirme, güven skoru, görsel açıklama ve temel öneri sağlayan destekleyici bir araç olarak tasarlanmıştır. Bu özellikleriyle çalışma, derin öğrenme tabanlı bitki hastalığı tespit sistemlerinin mobil uygulamalarla birlikte kullanılabilmesi için uygulanabilir bir örnek oluşturmaktadır.

4. ÖNERİLER

Bu çalışmada geliştirilen hiyerarşik karar destek sistemi, yaprak görüntülerinden bitki türü tespiti ve hastalık sınıflandırması yapabilen bütünleşik bir yapı sunmaktadır. Elde edilen sonuçlar, geliştirilen modellerin kontrollü veri setleri üzerinde başarılı tahminler yapabildiğini göstermiştir. Bununla birlikte sistemin gerçek kullanım koşullarında daha güvenilir, esnek ve uygulanabilir hale getirilebilmesi için ilerleyen çalışmalarda bazı geliştirmeler yapılabilir.

Öncelikle veri setinin gerçek saha görüntüleriyle daha fazla genişletilmesi önerilmektedir. Bu çalışmada kullanılan veri setleri büyük ölçüde belirli veri kaynaklarından elde edilen ve çoğunlukla kontrollü koşullarda çekilmiş yaprak görüntülerinden oluşmaktadır. Ancak gerçek kullanımda mobil cihazlarla çekilen görüntüler farklı ışık koşullarına, arka plan karmaşıklığına, kamera açılara ve görüntü kalitesine sahip olabilmektedir. Bu nedenle ilerleyen çalışmalarda farklı tarlalardan, seralardan ve doğal ortamlardan elde edilen daha fazla gerçek dünya görüntüsünün veri setine eklenmesi, modelin saha koşullarındaki genelleme yeteneğini artıracaktır.

Bu çalışmada görüntüler üzerinde CLAHE ön işlemi uygulanmış ve özellikle kontrast bilgisinin artırılması amaçlanmıştır. İlerleyen çalışmalarda CLAHE yönteminin farklı parametreleri denenebilir ve bu yöntemin farklı bitki türleri ile hastalık sınıfları üzerindeki etkisi daha ayrıntılı olarak incelenebilir. Ayrıca CLAHE dışında farklı görüntü iyileştirme, renk normalizasyonu, arka plan azaltma ve yaprak odaklı kırpma yöntemleri de karşılaştırmalı olarak değerlendirilebilir. Böylece modelin değişken ışık ve görüntü kalitesi koşullarına karşı daha dayanıklı hale gelmesi sağlanabilir.

Hastalık sınıflandırma aşamasında bu çalışmada domates türü için tür-özel bir hastalık modeli geliştirilmiş, domates dışındaki türlerde ise genel hastalık modeli kullanılmıştır. Bu yaklaşım mevcut veri seti yapısı açısından uygun olmakla birlikte, ilerleyen çalışmalarda patates, biber, salatalık, mısır, patlıcan ve çilek gibi diğer türler için de ayrı hastalık sınıflandırma modelleri oluşturulabilir. Böylece her bitki türüne özgü hastalık belirtileri daha ayrıntılı şekilde öğrenilebilir ve sistemin tür-özel hastalık tahmin başarısı artırılabilir.

Veri dengesizliği problemi de geliştirilmeye açık bir konudur. Bazı tür ve hastalık sınıflarında görüntü sayısının diğer sınıflara göre daha az olması, modelin bu sınıfları öğrenmesini zorlaştırabilmektedir. Bu nedenle ilerleyen çalışmalarda az örnek içeren sınıflar için daha fazla görüntü toplanması, veri artırma yöntemlerinin geliştirilmesi ve sınıf dengeleme tekniklerinin daha kapsamlı uygulanması önerilmektedir. Ayrıca veri setindeki etiketlerin ziraat alanında uzman kişiler tarafından doğrulanması, modelin güvenilirliğini artıracaktır.

Bu çalışmada açıklanabilir yapay zeka yaklaşımı olarak Grad-CAM++ yöntemi kullanılmıştır. Grad-CAM++ yöntemi, modelin karar verirken görüntünün hangi bölgelerine daha fazla odaklandığını göstermesi açısından faydalıdır. Ancak bu yöntem piksel düzeyinde kesin bir hastalık bölgesi tespiti yapmamaktadır. Bu nedenle gelecek çalışmalarda maskeli veri setleri kullanılarak segmentasyon tabanlı modeller geliştirilebilir. Böylece yalnızca hastalık sınıfı değil, hastalıklı bölgenin yaprak üzerindeki konumu ve yayılım oranı da daha net şekilde belirlenebilir.

Mobil uygulama tarafında da sistemin kullanıcı deneyimini artıracak geliştirmeler yapılabilir. Kullanıcıya görüntü çekimi sırasında yaprağın kadrajı mümkün olduğunca doldurması, arka planın sade olması, görüntünün net çekilmesi ve yaprağın yeterli ışık altında bulunması yönünde yönlendirmeler verilebilir. Ayrıca güven skoru düşük olduğunda sistemin kullanıcıdan daha net bir görüntü ile yeniden deneme yapmasını istemesi, hatalı tahminlerin azaltılmasına katkı sağlayacaktır. Modelin mobil cihazlarda daha hızlı çalışabilmesi için TensorFlow Lite dönüşümü, model boyutu optimizasyonu ve quantization gibi yöntemler daha ayrıntılı olarak uygulanabilir.

Son olarak, geliştirilen sistemin yalnızca model doğruluğu üzerinden değil, gerçek kullanıcı denemeleriyle de değerlendirilmesi önerilmektedir. Çiftçiler, ziraat mühendisleri veya tarım alanında çalışan kullanıcılarla yapılacak testler sayesinde sistemin kullanılabilirliği, anlaşılabilirliği ve karar destek değeri daha gerçekçi biçimde ölçülebilir. Bu geri bildirimler doğrultusunda öneri modülü geliştirilebilir ve sistemin kullanıcıyı daha doğru yönlendirmesi sağlanabilir.

Genel olarak bu çalışma, bitki türü tespiti, hastalık sınıflandırması, güven skoru, öneri üretimi ve açıklanabilir yapay zeka bileşenlerini bir araya getiren hiyerarşik bir karar destek sistemi ortaya koymuştur. İlerleyen çalışmalarda daha geniş veri setleri, daha fazla tür-özel hastalık modeli, gerçek saha görüntüleri, segmentasyon desteği ve mobil uygulama iyileştirmeleri ile sistemin daha güçlü ve kullanışlı hale getirilmesi mümkündür. Bu yönüyle çalışma, tarım alanında yapay zeka destekli karar destek sistemleri için geliştirilebilir bir temel altyapı sunmaktadır.

4.1. Çalışmanın Sınırlılıkları

Bu çalışmada derin öğrenme tabanlı hiyerarşik bir bitki türü tespit ve hastalık sınıflandırma sistemi geliştirilmiştir. Elde edilen sonuçlar, geliştirilen sistemin kontrollü veri setleri üzerinde başarılı tahminler yapabildiğini göstermektedir. Bununla birlikte çalışmanın kapsamı, kullanılan veri setleri, model yapısı ve gerçek kullanım koşulları açısından bazı sınırlılıkları bulunmaktadır.

Çalışmanın ilk sınırlılığı veri seti ile ilgilidir. Kullanılan görüntülerin önemli bir bölümü düzenlenmiş ve kontrollü veri setlerinden elde edilmiştir. Bu veri setlerinde yapraklar genellikle daha net, daha belirgin ve arka plandan daha kolay ayrılabilir durumdadır. Ancak gerçek kullanım senaryosunda mobil cihazlarla çekilen görüntüler farklı ışık koşulları, karmaşık arka planlar, değişken kamera açıları, düşük çözünürlük, bulanıklık ve yaprağın kadrajda yeterince büyük yer kaplamaması gibi problemler içerebilmektedir. Bu nedenle modelin düzenli veri setlerinde gösterdiği başarı, gerçek dünya görüntülerinde her zaman aynı düzeyde korunamamaktadır.

Bir diğer sınırlılık sınıf dengesizliğidir. Veri setinde bazı bitki türleri ve hastalık sınıfları daha fazla görüntü içerirken, bazı sınıflarda görüntü sayısı daha sınırlıdır. Bu durum modelin fazla örnek içeren sınıfları daha iyi öğrenmesine, az örnek içeren sınıflarda ise daha düşük başarı göstermesine neden olabilmektedir. Çalışmada sınıf ağırlıklandırma, veri artırma ve uygun kayıp fonksiyonları gibi yöntemlerle bu problemin etkisi azaltılmaya çalışılmıştır. Ancak sınıf dengesizliği tamamen ortadan kaldırılamamıştır.

Çalışmada görüntülerin daha belirgin hale getirilmesi amacıyla CLAHE ön işleme yöntemi uygulanmıştır. CLAHE, yaprak üzerindeki kontrastı artırarak damar yapısı, renk geçişleri ve hastalık belirtilerinin daha görünür hale gelmesine katkı sağlamıştır. Bununla birlikte CLAHE her görüntüde aynı etkiyi göstermeyebilir. Özellikle çok düşük kaliteli, aşırı parlak, fazla karanlık veya bulanık görüntülerde kontrast artırımı tek başına yeterli olmayabilir. Bu nedenle CLAHE yöntemi model başarısını destekleyen bir ön işlem adımı olarak değerlendirilmiş, tüm gerçek dünya koşullarını tamamen çözen bir yöntem olarak ele alınmamıştır.

Hastalık sınıflandırma açısından da bazı sınırlılıklar bulunmaktadır. Bu çalışmada domates türü için tür-özel bir hastalık sınıflandırma modeli geliştirilmiştir. Domates dışındaki bitki türlerinde ise genel hastalık sınıflandırma modeli kullanılmıştır. Bu nedenle domates dışındaki türlerde elde edilen hastalık sonuçları tür-özel kesin tanı olarak değil, genel hastalık belirtisi tahmini olarak değerlendirilmelidir. Her bitki türü için ayrı hastalık modeli oluşturulmadığı için bazı türlere özgü hastalık belirtileri model tarafından yeterince ayrıntılı öğrenilememiş olabilir.

Çalışmada hastalık sınıfları Healthy, Bacterial_Disease, Fungal_Disease ve Viral_Disease olmak üzere dört temel başlık altında toplanmıştır. Özellikle mantar kaynaklı hastalıklar tek bir Fungal_Disease sınıfı altında birleştirilmiştir. Bu yaklaşım, sınıflandırma problemini daha uygulanabilir ve dengeli hale getirmiştir. Ancak model, erken yanıklık, geç yanıklık, yaprak küfü, septoria veya pas gibi alt hastalık türlerini ayrı ayrı ayırt etmemektedir. Bu nedenle sistemin çıktısı hastalığın genel grubunu belirtmekte, hastalığın kesin alt türünü vermemektedir.

Gerçek dünya görüntüleriyle yapılan ek denemeler de çalışmanın önemli sınırlılıklarından birini ortaya koymuştur. Bu görüntülerde yaprak görüntüyü tam olarak kaplamadığında, arka plan karmaşık olduğunda, görüntüde birden fazla yaprak bulunduğunda veya yaprak net şekilde odaklanmadığında modelin tahmin performansı düşebilmektedir. Bu nedenle sistemin daha doğru çalışabilmesi için kullanıcının yaprağı mümkün olduğunca yakın, net, iyi ışık altında ve sade bir arka planla görüntülemesi gerekmektedir.

Açıklanabilir yapay zeka aşamasında kullanılan Grad-CAM++ yöntemi de belirli sınırlılıklara sahiptir. Grad-CAM++ modelin karar verirken görüntünün hangi bölgelerine daha fazla odaklandığını göstermektedir. Ancak bu yöntem piksel düzeyinde kesin bir hastalık bölgesi segmentasyonu üretmemektedir. Bu nedenle Grad-CAM++ çıktıları, hastalıklı bölgenin kesin sınırlarını gösteren bir maske olarak değil, model kararını yorumlamaya yardımcı görsel açıklamalar olarak değerlendirilmelidir.

Öneri modülü de genel bilgilendirme amacı taşımaktadır. Sistem, tahmin edilen hastalık sınıfına göre kullanıcıya temel bakım ve önlem önerileri sunmaktadır. Ancak bu öneriler kesin tarımsal tedavi reçetesi yerine geçmemektedir. Gerçek üretim koşullarında hastalık teşhisi, ilaçlama kararı ve mücadele yöntemi için ziraat mühendisi veya alan uzmanı değerlendirmesi gereklidir.

Mobil uygulama entegrasyonu açısından da bazı sınırlılıklar bulunmaktadır. Mobil cihazlarda çekilen görüntülerin kalitesi kullanılan kameraya, ortam ışığına ve kullanıcının çekim biçimine bağlı olarak değişebilmektedir. Bu nedenle mobil kullanımda model başarısını artırmak için kullanıcıya görüntü çekimi sırasında yönlendirme yapılması önemlidir. Ayrıca modelin mobil cihaz üzerinde daha hızlı ve düşük kaynak kullanımıyla çalışabilmesi için TensorFlow Lite dönüşümü, quantization ve cihaz üzerinde performans testleri gibi adımların daha ayrıntılı şekilde değerlendirilmesi gerekmektedir.

Son olarak, geliştirilen sistem karar destek amacıyla tasarlanmıştır. Sistem kullanıcıya bitki türü, hastalık durumu, güven skoru, Grad-CAM++ görselleştirmesi ve öneri sunmaktadır. Ancak model çıktıları kesin tanı olarak kabul edilmemelidir. Özellikle düşük güven skoruna sahip tahminlerde veya gerçek dünya görüntülerinde elde edilen sonuçlar dikkatli yorumlanmalı ve gerekirse daha net bir görüntü ile tekrar test yapılmalıdır.

Genel olarak bu sınırlılıklar, geliştirilen sistemin mevcut haliyle kullanılabilir bir karar destek yapısı sunduğunu; ancak daha geniş, dengeli ve gerçek saha koşullarını temsil eden veri setleriyle desteklenmesi gerektiğini göstermektedir. Gelecek çalışmalarda daha fazla gerçek dünya görüntüsü, her bitki türü için tür-özel hastalık modelleri, uzman onaylı etiketler, gerçek segmentasyon yöntemleri ve mobil cihaz testleri kullanılarak sistemin başarımı artırılabilir.

5. KAYNAKLAR

- [1] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [2] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, vol. 25, pp. 1097–1105, 2012.
- [3] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?," in *Advances in Neural Information Processing Systems*, vol. 27, pp. 3320–3328, 2014.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016.
- [5] S. P. Mohanty, D. P. Hughes, and M. Salathé, "Using deep learning for image-based plant disease detection," *Frontiers in Plant Science*, vol. 7, Art. no. 1419, 2016.
- [6] D. Singh, N. Jain, P. Jain, P. Kayal, S. Kumawat, and N. Batra, "PlantDoc: A dataset for visual plant disease detection," in *Proceedings of the 7th ACM IKDD CoDS and 25th COMAD*, pp. 249–253, 2020.
- [7] V. Yadav, "New Plant Diseases Dataset," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/vipooool/new-plant-diseases-dataset>. Accessed: May 8, 2026.
- [8] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proceedings of the 36th International Conference on Machine Learning*, pp. 6105–6114, 2019.
- [9] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, "CBAM: Convolutional Block Attention Module," in *Proceedings of the European Conference on Computer Vision*, pp. 3–19, 2018.
- [10] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proceedings of the IEEE International Conference on Computer Vision*, pp. 618–626, 2017.
- [11] A. Chattopadhyay, A. Sarkar, P. Howlader, and V. N. Balasubramanian, "Grad-CAM++: Improved visual explanations for deep convolutional networks," in *Proceedings of the IEEE Winter Conference on Applications of Computer Vision*, pp. 839–847, 2018.
- [12] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proceedings of the IEEE International Conference on Computer Vision*, pp. 2980–2988, 2017.
- [13] D. P. Hughes and M. Salathé, "An open access repository of images on plant health to enable the development of mobile disease diagnostics," *arXiv preprint arXiv:1511.08060*, 2015.
- [14] K. P. Ferentinos, "Deep learning models for plant disease detection and diagnosis," *Computers and Electronics in Agriculture*, vol. 145, pp. 311–318, 2018.
- [15] E. C. Too, L. Yujian, S. Njuki, and L. Yingchun, "A comparative study of fine-tuning deep learning models for plant disease identification," *Computers and Electronics in Agriculture*, vol. 161, pp. 272–279, 2019.
- [16] J. G. A. Barbedo, "A review on the main challenges in automatic plant disease identification based on visible range images," *Biosystems Engineering*, vol. 144, pp. 52–60, 2016.
- [17] A. Kamilaris and F. X. Prenafeta-Boldú, "Deep learning in agriculture: A survey," *Computers and Electronics in Agriculture*, vol. 147, pp. 70–90, 2018.
- [18] J. Liu and X. Wang, "Plant diseases and pests detection based on deep learning: A review," *Plant Methods*, vol. 17, Art. no. 22, 2021.

- [19] M. Buda, A. Maki, and M. A. Mazurowski, “A systematic study of the class imbalance problem in convolutional neural networks,” *Neural Networks*, vol. 106, pp. 249–259, 2018.
- [20] H. Zhang, M. Cisse, Y. N. Dauphin, and D. Lopez-Paz, “mixup: Beyond empirical risk minimization,” in *Proceedings of the International Conference on Learning Representations*, 2018.
- [21] S. Yun, D. Han, S. J. Oh, S. Chun, J. Choe, and Y. Yoo, “CutMix: Regularization strategy to train strong classifiers with localizable features,” in *Proceedings of the IEEE International Conference on Computer Vision*, pp. 6023–6032, 2019.
- [22] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba, “Learning deep features for discriminative localization,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2921–2929, 2016.
- [23] M. Brahimi, S. Mahmoudi, K. Boukhalfa, and A. Moussaoui, “Deep interpretable architecture for plant diseases classification,” *arXiv preprint arXiv:1905.13523*, 2019.
- [24] J. Yao, S. N. Tran, S. Garg, and S. Sawyer, “Deep learning for plant identification and disease classification from leaf images: Multi-prediction approaches,” *arXiv preprint arXiv:2310.16273*, 2023.
- [25] M. Abadi et al., “TensorFlow: Large-scale machine learning on heterogeneous distributed systems,” *arXiv preprint arXiv:1603.04467*, 2016.
- [26] F. Chollet, “Keras,” GitHub repository, 2015. [Online]. Available: <https://github.com/keras-team/keras>. Accessed: May 8, 2026.
- [27] F. Alam, “Leaf Disease Segmentation Dataset,” Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/fakhrealam9537/leaf-disease-segmentation-dataset>. Accessed: May 8, 2026.
- [28] Roboflow Universe, “Plant Disease Detection Dataset,” Roboflow. [Online]. Available: <https://universe.roboflow.com/floragenic-9v9os/plant-disease-detection-3anip/dataset/1>. Accessed: May 8, 2026.
- [29] TensorFlow, “TensorFlow Lite.” [Online]. Available: <https://www.tensorflow.org/lite>. Accessed: May 8, 2026.
- [30] Android Developers, “CameraX overview.” [Online]. Available: <https://developer.android.com/media/camera/camerax>. Accessed: May 8, 2026.
- [31] K. Zuiderveld, “Contrast limited adaptive histogram equalization,” in *Graphics Gems IV*, P. S. Heckbert, Ed. San Diego, CA, USA: Academic Press, pp. 474–485, 1994.

STANDARTLAR ve KISITLAR FORMU

Projenin hazırlanmasında uyulan standart ve kısıtlarla ilgili olarak, aşağıdaki soruları cevaplayınız.

1. Projenizin tasarım boyutu nedir? (Yeni bir proje midir? Var olan bir projenin tekrarı mıdır? Bir projenin parçası mıdır? Sizin tasarımınız proje toplamının yüzde olarak ne kadarını oluşturmaktadır?)

Bu proje, yaprak görüntülerinden bitki türü tespiti ve hastalık sınıflandırması yapan derin öğrenme tabanlı hiyerarşik bir karar destek sistemi geliştirmeyi amaçlayan yeni bir uygulamalı mühendislik projesidir. Çalışma tamamen var olan bir projenin tekrarı değildir; ancak literatürdeki derin öğrenme, transfer öğrenme, dikkat mekanizması ve açıklanabilir yapay zeka yaklaşımlarından yararlanılarak geliştirilmiştir.

Projede hazır veri setleri ve mevcut derin öğrenme kütüphaneleri kullanılmıştır. Bununla birlikte veri setlerinin düzenlenmesi, etiketlerin standartlaştırılması, hiyerarşik sistem yapısının kurulması, EfficientNetB3 tabanlı CBAM destekli modellerin eğitilmesi, CLAHE ön işleminin denenmesi, Grad-CAM++ açıklanabilirlik çıktıların alınması ve karar destek mantığının oluşturulması tarafımdan gerçekleştirilmiştir. Bu nedenle proje tasarımının önemli bir bölümü bana aittir. Hazır veri setleri ve mevcut yazılım kütüphaneleri dışarıda bırakıldığında, sistem tasarımı ve uygulama geliştirme açısından katkım yaklaşık %70-80 düzeyindedir.

2. Projenizde bir mühendislik problemini kendiniz formüle edip, çözdünüz mü? Açıklayınız.

Evet. Bu çalışmada tarımsal üretimde karşılaşılan bitki türü ve hastalık tespiti problemi bir görüntü sınıflandırma ve karar destek problemi olarak formüle edilmiştir. Problem başlangıçta yaprak görüntülerinden hastalık tahmini yapılması şeklinde ele alınmış, ancak farklı bitki türleri ve hastalık sınıfları birlikte değerlendirildiğinde sınıf dengesizliği ve türler arası görsel benzerlikler nedeniyle tek model yaklaşımının yeterli olmadığı görülmüştür.

Bu nedenle problem hiyerarşik bir yapıya dönüştürülmüştür. İlk aşamada yaprak görüntüsünden bitki türü tahmin edilmekte, ikinci aşamada ise tahmin edilen türe göre uygun hastalık sınıflandırma modeli çalıştırılmaktadır. Domates türü için daha dengeli veri yapısı bulunduğundan tür-özel hastalık modeli geliştirilmiş, diğer türler için ise genel hastalık sınıflandırma modeli kullanılmıştır.

Ayrıca model kararlarının daha anlaşılır hale getirilmesi için Grad-CAM++ yöntemi kullanılmış, gerçek dünya görüntülerinde karşılaşılan sorunları azaltmak amacıyla güven skoru kontrolü ve kullanıcı uyarıları eklenmiştir. Bu yönüyle çalışma, yalnızca bir sınıflandırma modeli değil, mühendislik problemi olarak formüle edilmiş bütünlük bir karar destek sistemi çözümüdür.

3. Önceki derslerde edindiğiniz hangi bilgi ve becerileri kullandınız?

Bu projede, lisans eğitimi süresince alınan Introduction to Computer Programming, Data Structures, Algoritmalar ve Yapay Zekâ derslerinde edinilen bilgi ve becerilerden yararlanılmıştır. Bu dersler kapsamında kazanılan programlama, algoritma tasarımı, veri yapıları ve yapay zekâ temelli modelleme bilgileri; bitki tanıma ve hastalık tespiti için geliştirilen CNN tabanlı sistemin tasarlanması, uygulanması ve performansının değerlendirilmesi aşamalarında doğrudan kullanılmıştır.

4. Kullandığınız veya dikkate aldığınız mühendislik standartları nelerdir? (Proje konunuzla ilgili olarak kullandığınız ve kullanılması gereken standartları burada kod ve isimleri ile sıralayınız).

Bu çalışma doğrudan bir endüstriyel sertifikasyon süreci kapsamında geliştirilmemiştir. Ancak yazılım geliştirme, veri kalitesi, yapay zeka risk yönetimi, yazılım kalitesi ve bilgi güvenliği açısından bazı uluslararası standartlar dikkate alınmıştır.

- **ISO/IEC/IEEE 12207:2017 — Systems and software engineering — Software life cycle processes:** Yazılım yaşam döngüsü süreçlerinin planlanması, geliştirilmesi, kontrol edilmesi ve iyileştirilmesi açısından dikkate alınmıştır. Bu standart, yazılım ürünlerinin yaşam döngüsü süreçleri için genel bir çerçeve sunmaktadır.
- **ISO/IEC 25010:2023 — Systems and software engineering — Product quality model:** Geliştirilen sistemin kullanılabilirlik, doğruluk, güvenilirlik, sürdürülebilirlik ve performans gibi yazılım kalite özellikleri açısından değerlendirilmesinde dikkate alınmıştır. ISO/IEC 25010, yazılım ve ICT ürünleri için kalite modeli tanımlamaktadır.
- **ISO/IEC 25012:2008 — Software engineering — Data quality model:** Veri setlerinin düzenlenmesi, etiket tutarlılığı, veri doğruluğu ve veri kalitesi açısından dikkate alınmıştır. Bu standart, bilgisayar sistemlerinde kullanılan yapılandırılmış veriler için genel veri kalite modelini tanımlamaktadır.
- **ISO/IEC 23894:2023 — Artificial intelligence — Guidance on risk management:** Yapay zeka sistemlerinde risklerin değerlendirilmesi, düşük güvenli tahminlerin kullanıcıya uyarı ile sunulması ve model sonuçlarının kesin tanı olarak değerlendirilmemesi açısından dikkate alınmıştır. Bu standart, yapay zeka kullanan sistemlerde risk yönetimi için rehberlik sağlamaktadır.
- **ISO/IEC 27001:2022 — Information security management systems:** Kullanıcı görüntülerinin ve sistem çıktılarının güvenli şekilde ele alınması, veri gizliliği ve bilgi güvenliği farkındalığı açısından dikkate alınmıştır. ISO/IEC 27001, bilgi güvenliği yönetim sistemleri için gereklilikleri tanımlayan bir standarttır.

5. Kullandığınız veya dikkate aldığınız gerçekçi kısıtlar nelerdir? Lütfen boşlukları uygun yanıtlarla doldurunuz.

a) Ekonomi

Projede ekonomik kısıtlar dikkate alınmıştır. Derin öğrenme modellerinin eğitimi yüksek işlem gücü gerektirebildiğinden, donanım maliyetini azaltmak için Google Colab ortamı ve mevcut ücretsiz/açık kaynak kütüphaneler kullanılmıştır. Veri setleri de erişilebilir açık kaynak veri setlerinden seçilmiştir. Böylece ek donanım, ücretli veri toplama veya ticari yazılım maliyeti oluşmadan proje geliştirilmeye çalışılmıştır. Mobil uygulama tarafında da sistemin pahalı özel donanımlara ihtiyaç duymadan Android cihazlarda çalışabilecek şekilde tasarlanması hedeflenmiştir. Bu amaçla TensorFlow Lite ve model optimizasyonu gibi yöntemlerin kullanılması planlanmıştır.

b) Çevre sorunları:

Proje doğrudan fiziksel üretim veya çevreye zarar verebilecek bir işlem içermemektedir. Aksine, bitki hastalıklarının erken tespit edilmesine destek olarak gereksiz ilaç kullanımının azaltılmasına ve tarımsal kaynakların daha bilinçli kullanılmasına katkı sağlayabilecek bir yapı sunmaktadır. Bununla birlikte derin öğrenme modellerinin eğitimi enerji tüketimi oluşturduğundan, model eğitimi sırasında gereksiz tekrarların azaltılması, hazır ön eğitilmiş modellerden yararlanılması ve daha verimli mimarilerin tercih edilmesi çevresel açıdan dikkate alınmıştır.

c) Sürdürülebilirlik:

Çalışmada sürdürülebilirlik açısından tarımsal üretimde erken hastalık tespitine katkı sağlamak hedeflenmiştir. Bitki hastalıklarının erken fark edilmesi ürün kayıplarını azaltabilir ve kaynak kullanımını daha verimli hale getirebilir. Yazılım açısından da sistem modüler bir yapıda tasarlanmıştır. Tür tespit modeli, domates hastalık modeli, genel hastalık modeli, öneri modülü ve Grad-CAM++ açıklanabilirlik bileşeni ayrı yapılar olarak ele alınmıştır. Bu sayede ileride yeni bitki türleri, yeni hastalık sınıfları veya yeni modeller sisteme eklenebilir.

d) Üretilirlik:

Projenin üretilirliği yazılım tabanlı olması nedeniyle yüksektir. Model geliştirme sürecinde Python, TensorFlow/Keras, OpenCV ve Android/Kotlin gibi yaygın kullanılan araçlar tercih edilmiştir. Bu teknolojiler sayesinde sistemin farklı bilgisayar ortamlarında tekrar çalıştırılması ve mobil uygulamaya aktarılması mümkündür. Ancak sistemin gerçek kullanıma geçebilmesi için model dosyalarının mobil ortama uygun hale getirilmesi, TensorFlow Lite dönüşümü, arayüz tasarımı ve gerçek cihaz testlerinin yapılması gerekmektedir. Bu nedenle proje araştırma ve prototip düzeyinde üretilirlik olmakla birlikte, tam saha kullanımı için ek testlere ihtiyaç duymaktadır.

e) Etik:

Projede kullanılan görüntüler açık kaynak veri setlerinden ve test amaçlı görüntülerden elde edilmiştir. Veri kullanımı sırasında kaynakların lisans koşullarına dikkat edilmiştir. Sistem yalnızca karar destek amacıyla tasarlanmıştır; kullanıcıya kesin tanı veya kesin tedavi önerisi sunmamaktadır.

Etik açıdan modelin hatalı tahmin yapabileceği dikkate alınmıştır. Bu nedenle düşük güven skoru durumlarında kullanıcıya sonucun kesin kabul edilmemesi ve daha net görüntü ile tekrar deneme yapılması gerektiği belirtilmiştir. Ayrıca öneriler genel bilgilendirme amaçlıdır; kimyasal mücadele veya kesin tarımsal tedavi için uzman görüşü gereklidir.

f) Sağlık:

Proje insan sağlığına doğrudan müdahale eden bir sistem değildir. Ancak tarımda kullanılan hastalık tespit ve öneri sistemleri dolaylı olarak gıda üretimi ve kimyasal mücadele kararlarıyla ilişkili olabilir. Bu nedenle sistemin yanlış yönlendirme yapmaması önemlidir.

Bu kapsamda uygulama, kesin tedavi önerisi vermek yerine hastalık grubuna yönelik genel bakım ve önlem önerileri sunacak şekilde tasarlanmıştır. Pestisit, fungusit veya benzeri uygulamalar için ziraat mühendisi ya da alan uzmanına danışılması gerektiği vurgulanmıştır.

g) Güvenlik:

Güvenlik açısından sistemin hem yazılım hem de kullanım güvenliği dikkate alınmıştır. Kullanıcıdan alınan görüntülerin güvenli şekilde işlenmesi, kişisel veya hassas veri içermemesi ve gerektiğinde yerel cihaz üzerinde çalışabilecek şekilde tasarlanması önemlidir.

Ayrıca model çıktılarının güvenli yorumlanması için güven skoru kullanılmıştır. Modelin emin olmadığı durumlarda kullanıcıya uyarı verilmesi, hatalı kararların doğrudan uygulanmasını önlemeye yardımcı olmaktadır. Böylece sistem, kullanıcıyı yanlış yönlendirme riskini azaltacak şekilde tasarlanmıştır.

h) Sosyal ve politik sorunlar:

Tarımsal üretimde teknoloji kullanımının artması, çiftçilerin ve üreticilerin karar alma süreçlerine katkı sağlayabilir. Ancak yapay zeka tabanlı sistemlerin her kullanıcı tarafından aynı düzeyde anlaşılması mümkün olmayabilir. Bu nedenle sistemin sade, anlaşılır ve kullanıcı dostu olması önemlidir.

Sosyal açıdan, geliştirilen sistem küçük üreticiler için erken uyarı ve ön değerlendirme aracı olarak fayda sağlayabilir. Bununla birlikte sistem uzman görüşünün yerine geçmemelidir. Politik ve tarımsal açıdan ise yerel üretimi destekleyen, verim kaybını azaltmayı amaçlayan ve dijital tarım uygulamalarına katkı sağlayabilecek bir çalışma olarak değerlendirilebilir.